ПРОСТАЯ ЛИНЕЙНАЯ РЕГРЕССИЯ И ОЦЕНИВАНИЕ МНК

От генеральной модели к оценённой линии регрессии

ДАННЫЕ → МОДЕЛЬ → ОЦЕНИВАНИЕ → ПРОВЕРКА → РЕШЕНИЕ

TASHKENT INTERNATIONAL UNIVERSITY

Преподаватель: Azizbek Ilkhomzoda

TASHKENT INTERNATIONAL UNIVERSITY

ЦЕЛИ ЗАНЯТИЯ

01 Различать генеральную модель и ошибку

02 Выводить нормальные уравнения МНК

03 Вручную вычислять наклон и константу

04 Толковать расчётные значения и остатки

05 Разлагать TSS = ESS + RSS

06 Отделять статистическую связь от причинности

Генеральная регрессионная модель

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

ОСНОВНАЯ ИДЕЯ

Наблюдаемый результат содержит систематическую часть и необъяснённый случайный компонент.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Параметры β_0 и β_1 характеризуют генеральную совокупность; u отражает пропущенные факторы.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

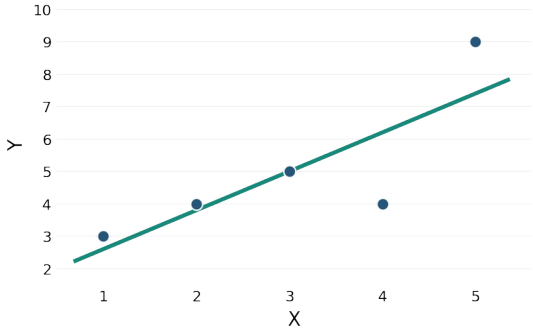
Кафе: X — реклама, Y — выручка. Погода и местоположение входят в u, если не учтены.

Генеральная регрессионная модель

$$u_i = Y_i - (\beta_0 + \beta_1 X_i)$$

ФОРМУЛА И ВЫВОД

Параметры β_0 и β_1 характеризуют генеральную совокупность; u отражает пропущенные факторы.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Кафе: X — реклама, Y — выручка. Погода и местоположение входят в u, если не учтены.

Генеральная совокупность и выборка

$$\beta_1 \qquad \hat{\beta}_1$$

ОСНОВНАЯ ИДЕЯ

Параметр фиксирован, но неизвестен; его оценка меняется от выборки к выборке.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Параметр β_1 относится ко всей генеральной совокупности, а оценка $\hat{\beta}_1$ рассчитывается по конкретной выборке.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

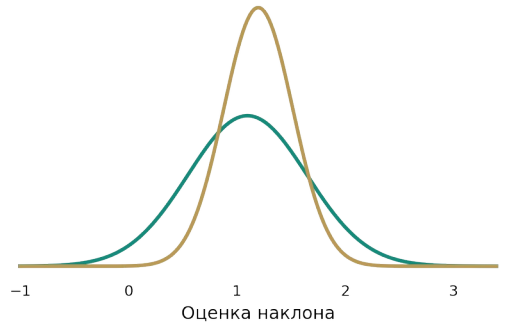
Два набора из 30 магазинов обычно дают разные оценки влияния рекламы.

Генеральная совокупность и выборка

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

ФОРМУЛА И ВЫВОД

Параметр β_1 относится ко всей генеральной совокупности, а оценка $\hat{\beta}_1$ рассчитывается по конкретной выборке.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Два набора из 30 магазинов обычно дают разные оценки влияния рекламы.

Случайная ошибка модели

$$u_i = Y_i - E(Y_i \mid X_i)$$

ОСНОВНАЯ ИДЕЯ

Случайная ошибка отражает отклонение наблюдения от условного математического ожидания.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Она может включать пропущенные факторы, ошибки измерений и случайность.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

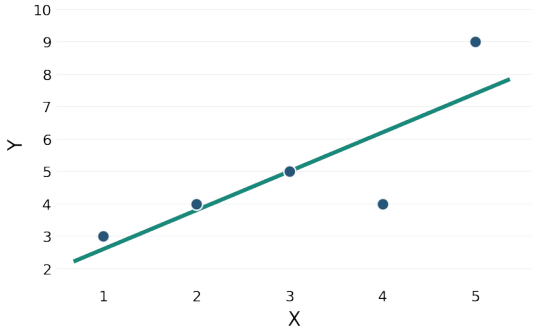
Одинаковые рекламные бюджеты не гарантируют одинаковую выручку у разных магазинов.

Случайная ошибка модели

$$Y_i = E(Y_i \mid X_i) + u_i$$

ФОРМУЛА И ВЫВОД

Она может включать пропущенные факторы, ошибки измерений и случайность.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Одинаковые рекламные бюджеты не гарантируют одинаковую выручку у разных магазинов.

Условное математическое ожидание

$$E(Y \mid X = x) = \beta_0 + \beta_1 x$$

ОСНОВНАЯ ИДЕЯ

Линия регрессии описывает среднее Y среди единиц с заданным X.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Линейность относится к условному среднему, а не к каждому отдельному наблюдению.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

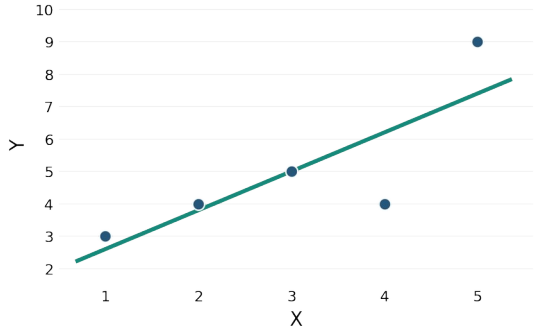
При X = 3 средняя ожидаемая выручка может быть 5, хотя отдельные значения отличаются.

Условное математическое ожидание

$$E(u \mid X) = 0$$

ФОРМУЛА И ВЫВОД

Линейность относится к условному среднему, а не к каждому отдельному наблюдению.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При X = 3 средняя ожидаемая выручка может быть 5, хотя отдельные значения отличаются.

Нулевое условное среднее ошибки

$$E(u_i \mid X_i) = 0$$

ОСНОВНАЯ ИДЕЯ

Средняя ошибка не должна систематически зависеть от X.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Нулевое условное среднее ошибки — основное условие несмещённости МНК при случайной выборке.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

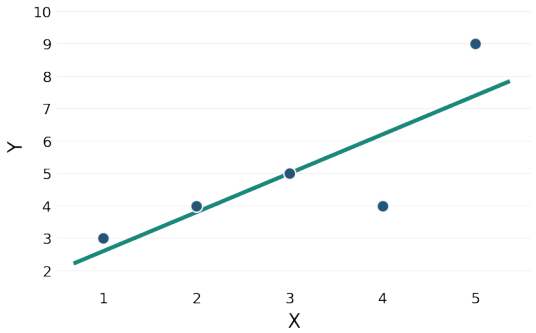
Если богатые магазины больше рекламируются и больше продают по другим причинам, условие нарушается.

Нулевое условное среднее ошибки

$$\mathrm{Cov}(X_i, u_i) = 0$$

ФОРМУЛА И ВЫВОД

Нулевое условное среднее ошибки — основное условие несмещённости МНК при случайной выборке.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Если богатые магазины больше рекламируются и больше продают по другим причинам, условие нарушается.

Оцениватель, оценка и прогноз

$$\hat{\beta}_1 = \hat{\beta}_1(X_1, Y_1, \ldots, X_n, Y_n)$$

ОСНОВНАЯ ИДЕЯ

Оцениватель — правило вычисления; оценка — его результат; подогнанное значение $\hat{Y}$ — оценка условного среднего Y.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Эти три объекта следует различать, чтобы не путать параметры с результатами.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

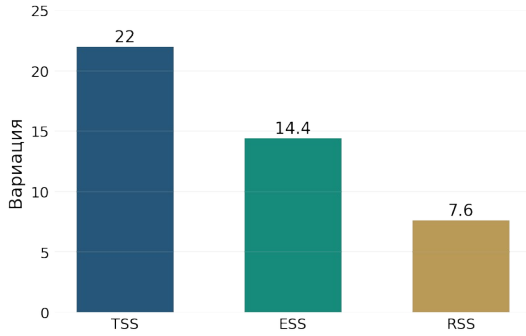
В одной выборке $\hat{\beta}_1 = 1{,}2$; для магазина с $X = 4$ получаем $\hat{Y} = 6{,}2$.

Оцениватель, оценка и прогноз

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

ФОРМУЛА И ВЫВОД

Эти три объекта следует различать, чтобы не путать параметры с результатами.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

В одной выборке $\hat{\beta}_1 = 1{,}2$; для магазина с $X = 4$ получаем $\hat{Y} = 6{,}2$.

Критерий наименьших квадратов

$$S(b_0, b_1) = \sum_{i=1}^{n} (Y_i - b_0 - b_1 X_i)^2$$

ОСНОВНАЯ ИДЕЯ

МНК выбирает прямую с минимальной суммой квадратов вертикальных отклонений.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Квадраты не дают положительным и отрицательным ошибкам взаимно уничтожаться.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

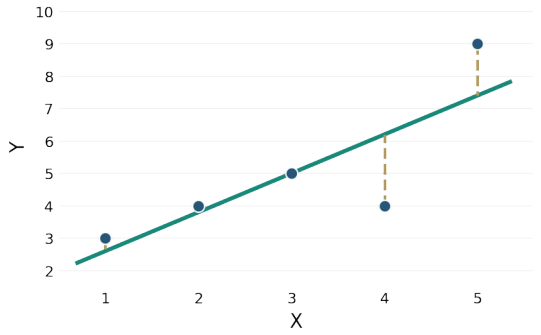
Остаток −2 даёт вклад 4; остаток +1 — вклад 1.

Критерий наименьших квадратов

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg\min_{b_0, b_1} S(b_0, b_1)$$

ФОРМУЛА И ВЫВОД

Квадраты не дают положительным и отрицательным ошибкам взаимно уничтожаться.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Остаток −2 даёт вклад 4; остаток +1 — вклад 1.

Производная по свободному члену

$$\frac{\partial S}{\partial b_0} = -2\sum_i (Y_i - b_0 - b_1 X_i)$$

ОСНОВНАЯ ИДЕЯ

В точке минимума производная функции суммы квадратов равна нулю.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Первое нормальное уравнение означает нулевую сумму остатков при наличии константы.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

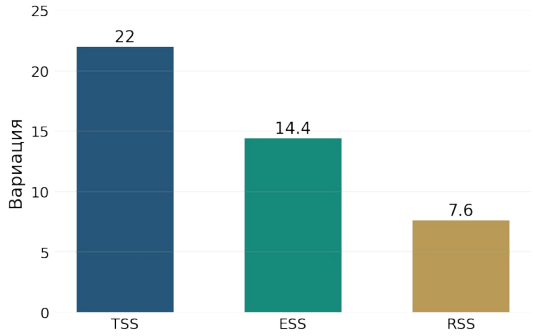
Остатки +2, −1 и −1 дают нуль в сумме, хотя этого недостаточно для МНК.

Производная по свободному члену

$$\sum_i \hat{u}_i = 0$$

ФОРМУЛА И ВЫВОД

Первое нормальное уравнение означает нулевую сумму остатков при наличии константы.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Остатки +2, −1 и −1 дают нуль в сумме, хотя этого недостаточно для МНК.

Производная по угловому коэффициенту

$$\frac{\partial S}{\partial b_1} = -2\sum_i X_i(Y_i - b_0 - b_1 X_i)$$

ОСНОВНАЯ ИДЕЯ

Второе условие первого порядка делает остатки ортогональными X.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Оба нормальных уравнения определяют коэффициенты при наличии вариации X.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

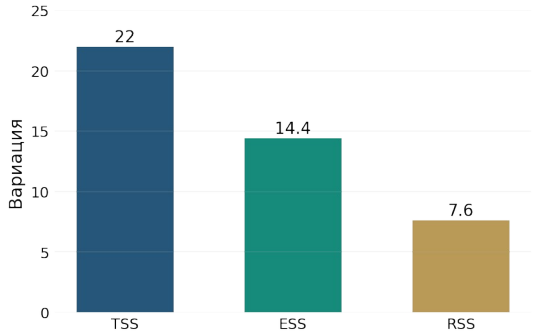
В остатках МНК не остаётся линейной вариации, объясняемой X внутри выборки.

Производная по угловому коэффициенту

$$\sum_i x_i \hat{u}_i = 0$$

ФОРМУЛА И ВЫВОД

Оба нормальных уравнения определяют коэффициенты при наличии вариации X.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

В остатках МНК не остаётся линейной вариации, объясняемой X внутри выборки.

Формула оценки коэффициента наклона МНК

$$\hat{\beta}_1 = \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_i (X_i - \bar{X})^2}$$

ОСНОВНАЯ ИДЕЯ

Числитель измеряет совместные изменения; знаменатель — разброс X.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Знак оценки наклона определяется знаком выборочной ковариации X и Y.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

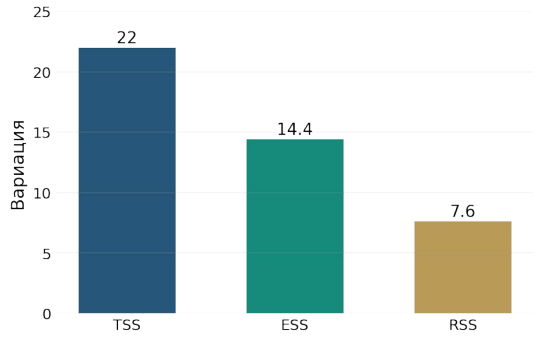
Если Sxy = 12 и Sxx = 10, получаем наклон 1,2.

Формула оценки коэффициента наклона МНК

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$

ФОРМУЛА И ВЫВОД

Знак оценки наклона определяется знаком выборочной ковариации X и Y.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Если Sxy = 12 и Sxx = 10, получаем наклон 1,2.

Формула свободного члена МНК

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

ОСНОВНАЯ ИДЕЯ

При наличии константы прямая МНК проходит через точку выборочных средних.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Константа служит алгебраической опорой; её смысл зависит от реалистичности X = 0.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

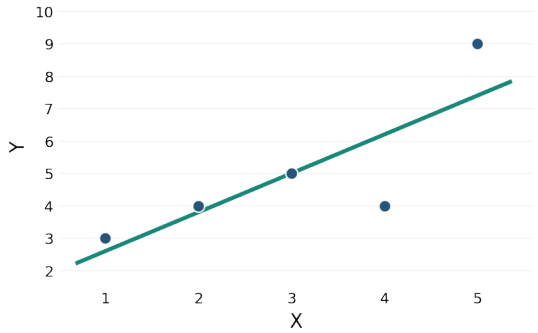
При $\bar{Y} = 5$, $\bar{X} = 3$ и наклоне 1,2 константа равна 1,4.

Формула свободного члена МНК

$$\hat{Y}(\bar{X}) = \bar{Y}$$

ФОРМУЛА И ВЫВОД

Константа служит алгебраической опорой; её смысл зависит от реалистичности X = 0.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При $\bar{Y}$ = 5, $\bar{X}$ = 3 и наклоне 1,2 константа равна 1,4.

Почему X должен изменяться

$$S_{xx} = \sum_i (X_i - \bar{X})^2 > 0$$

ОСНОВНАЯ ИДЕЯ

Невозможно оценить наклон, если у всех наблюдений одинаковое X.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Без вариации X знаменатель формулы МНК равен нулю: наклон не идентифицируется.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

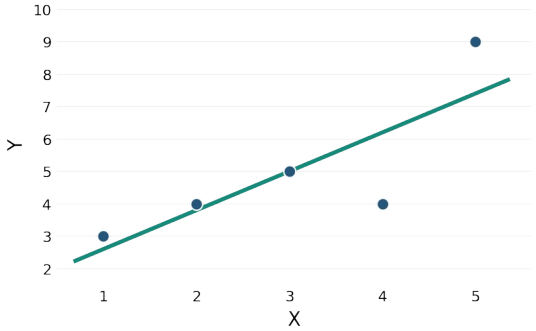
Если пять магазинов тратят по 3 единицы на рекламу, Sxx = 0.

Почему X должен изменяться

$$S_{xx} = 0 \quad \Longrightarrow \quad \frac{S_{xy}}{S_{xx}} = \frac{0}{0}$$

ФОРМУЛА И ВЫВОД

Без вариации X знаменатель формулы МНК равен нулю: наклон не идентифицируется.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Если пять магазинов тратят по 3 единицы на рекламу, Sxx = 0.

Форма через ковариацию и дисперсию

$$\hat{\beta}_1 = \frac{\widehat{\mathrm{Cov}}(X, Y)}{\widehat{\mathrm{Var}}(X)}$$

ОСНОВНАЯ ИДЕЯ

Наклон равен ковариации, делённой на дисперсию регрессора.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Изменение единиц X меняет число для наклона, но не экономическую связь.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

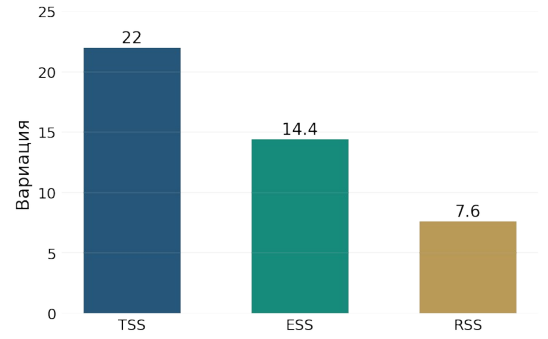
При переходе от миллионов к тысячам коэффициент меняет масштаб.

Форма через ковариацию и дисперсию

$$\operatorname{sign}(\hat{\beta}_1) = \operatorname{sign}(\widehat{\operatorname{Cov}}(X, Y))$$

ФОРМУЛА И ВЫВОД

Изменение единиц X меняет число для наклона, но не экономическую связь.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При переходе от миллионов к тысячам коэффициент меняет масштаб.

МНК в матричной записи

$$y = X\beta + u$$

ОСНОВНАЯ ИДЕЯ

Матричная формула обобщает простой МНК на множество регрессоров.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Обратная матрица существует при полном столбцовом ранге X.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

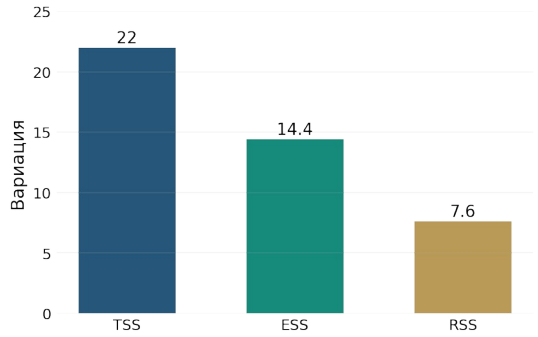
Для константы и одного регрессора столбцы X — единицы и наблюдения x.

МНК в матричной записи

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$

ФОРМУЛА И ВЫВОД

Обратная матрица существует при полном столбцовом ранге X.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Для константы и одного регрессора столбцы X — единицы и наблюдения x.

Подогнанные значения

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

ОСНОВНАЯ ИДЕЯ

Подогнанное значение $\hat{Y}$ лежит на оценённой линии регрессии в точке наблюдаемого X.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Прогноз среднего не гарантирует индивидуальный результат.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

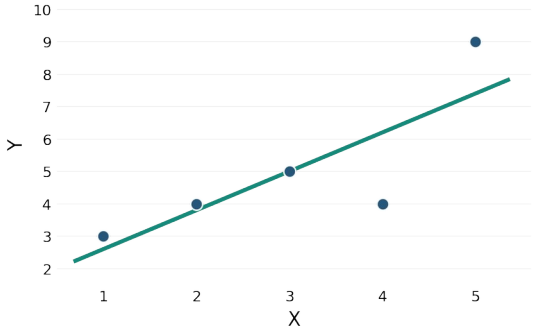
При $\hat{Y} = 1{,}4 + 1{,}2X$ и $X = 4$ получаем $\hat{Y} = 6{,}2$.

Подогнанные значения

$$\hat{y} = X\hat{\beta}$$

ФОРМУЛА И ВЫВОД

Прогноз среднего не гарантирует индивидуальный результат.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При $\hat{Y} = 1{,}4 + 1{,}2X$ и $X = 4$ получаем $\hat{Y} = 6{,}2$.

Остатки и ошибки подгонки

$$\hat{u}_i = Y_i - \hat{Y}_i$$

ОСНОВНАЯ ИДЕЯ

Остаток наблюдаем после оценивания, а генеральная ошибка u — нет.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Положительный остаток означает точку выше линии; отрицательный — ниже.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

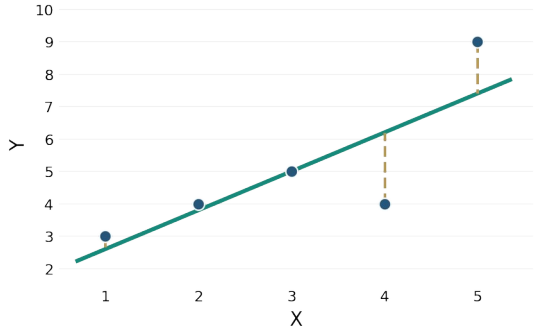
При X = 4, Y = 4, $\hat{Y}$ = 6,2 остаток равен −2,2.

Остатки и ошибки подгонки

$$Y_i = \hat{Y}_i + \hat{u}_i$$

ФОРМУЛА И ВЫВОД

Положительный остаток означает точку выше линии; отрицательный — ниже.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При X = 4, Y = 4, $\hat{Y}$ = 6,2 остаток равен −2,2.

Ортогональность остатков

$$\sum_i \hat{u}_i = 0, \quad \sum_i x_i \hat{u}_i = 0$$

ОСНОВНАЯ ИДЕЯ

При константе остатки МНК имеют нулевое среднее и ковариацию с X.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Тождества выполняются в выборке автоматически и не доказывают причинность.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

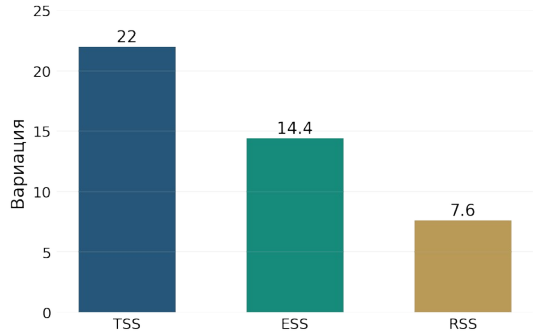
Даже высокий R^2 и ортогональность не исключают пропущенную общую причину.

Ортогональность остатков

$$\frac{1}{n}\sum_{i}\hat{u}_i = 0$$

ФОРМУЛА И ВЫВОД

Тождества выполняются в выборке автоматически и не доказывают причинность.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Даже высокий R^2 и ортогональность не исключают пропущенную общую причину.

Свойство точки средних

$$\bar{\hat{Y}} = \bar{Y}$$

ОСНОВНАЯ ИДЕЯ

При наличии константы среднее рассчитанное Y равно среднему фактическому Y.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Это алгебраическое свойство МНК, а не гарантия правильной модели.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

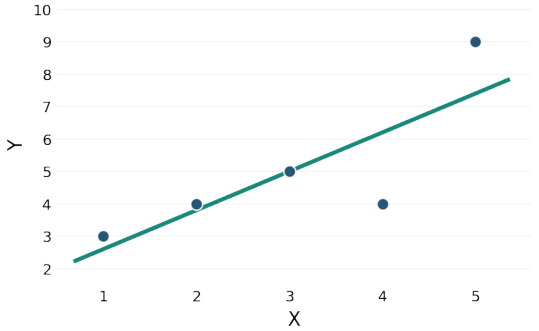
При средних 3 и 5 линия обязательно проходит через (3; 5).

Свойство точки средних

$$\hat{Y}(\bar{X}) = \hat{\beta}_0 + \hat{\beta}_1 \bar{X} = \bar{Y}$$

ФОРМУЛА И ВЫВОД

Это алгебраическое свойство МНК, а не гарантия правильной модели.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При средних 3 и 5 линия обязательно проходит через (3; 5).

Данные из пяти наблюдений

$$X = (1, 2, 3, 4, 5), \quad Y = (3, 4, 5, 4, 9)$$

ОСНОВНАЯ ИДЕЯ

Пошагово рассчитаем МНК для пяти магазинов.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Пусть X — реклама в млн сумов, Y — дневная выручка в млн сумов.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

Средние получаем делением сумм пяти значений на пять.

Данные из пяти наблюдений

$$\bar{X} = 3, \qquad \bar{Y} = 5$$

ФОРМУЛА И ВЫВОД

Пусть X — реклама в млн сумов, Y — дневная выручка в млн сумов.

i	1	2	3	4	5
X	1	2	3	4	5
Y	3	4	5	4	9
$\hat{Y}$	2.6	3.8	5.0	6.2	7.4

ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Средние получаем делением сумм пяти значений на пять.

Расчёт Sxx и Sxy

$$S_{xx} = \sum (X_i - 3)^2 = 10$$

ОСНОВНАЯ ИДЕЯ

Сначала вычитаем выборочное среднее, затем умножаем или возводим в квадрат.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Отклонения X равны −2, −1, 0, 1, 2; квадраты дают 10.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

Попарные произведения 4 + 1 + 0 − 1 + 8 дают 12.

Расчёт Sxx и Sxy

$$S_{xy} = \sum (X_i - 3)(Y_i - 5) = 12$$

ФОРМУЛА И ВЫВОД

Отклонения X равны −2, −1, 0, 1, 2; квадраты дают 10.

i	1	2	3	4	5
X	1	2	3	4	5
Y	3	4	5	4	9
Ŷ	2.6	3.8	5.0	6.2	7.4

ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Попарные произведения 4 + 1 + 0 − 1 + 8 дают 12.

Оценивание линии регрессии

$$\hat{\beta}_1 = 12/10 = 1{,}2$$

ОСНОВНАЯ ИДЕЯ

Константа равна 5 − 1,2 × 3 = 1,4.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Рост X на 1 млн сумов связан с ростом расчётной дневной выручки на 1,2 млн.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

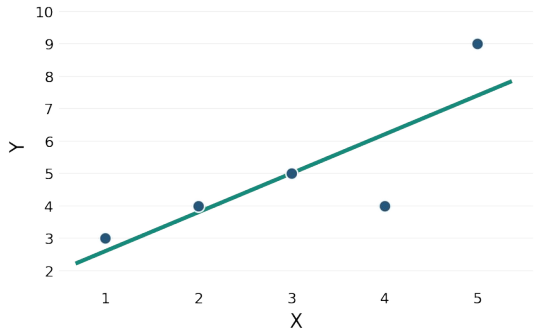
Константа относится к X = 0; вне диапазона выборки её нужно трактовать осторожно.

Оценивание линии регрессии

$$\hat{Y} = 1{,}4 + 1{,}2X$$

ФОРМУЛА И ВЫВОД

Рост X на 1 млн сумов связан с ростом расчётной дневной выручки на 1,2 млн.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Константа относится к X = 0; вне диапазона выборки её нужно трактовать осторожно.

Таблица подогнанных значений и остатков

$$\hat{Y} = (2{,}6,\ 3{,}8,\ 5{,}0,\ 6{,}2,\ 7{,}4)$$

ОСНОВНАЯ ИДЕЯ

Подставьте X в оценённое уравнение и вычтите прогноз из факта.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Проверьте тождество МНК: сумма пяти остатков равна нулю.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

Наибольший отрицательный остаток −2,2 наблюдается при X = 4.

Таблица подогнанных значений и остатков

$$\hat{u} = (0{,}4,\ 0{,}2,\ 0,\ -2{,}2,\ 1{,}6)$$

ФОРМУЛА И ВЫВОД

Проверьте тождество МНК: сумма пяти остатков равна нулю.

i	1	2	3	4	5
X	1	2	3	4	5
Y	3	4	5	4	9
Ŷ	2.6	3.8	5.0	6.2	7.4

ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Наибольший отрицательный остаток −2,2 наблюдается при X = 4.

Остаточная сумма квадратов

$$RSS = \sum_i \hat{u}_i^2$$

ОСНОВНАЯ ИДЕЯ

Остаточная сумма квадратов (RSS) характеризует необъяснённую моделью вариацию Y.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Крупные ошибки имеют больший вес из-за возведения в квадрат.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

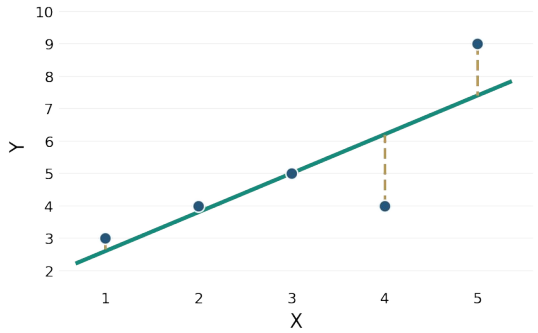
Один остаток −2,2 даёт 4,84 из 7,6 RSS.

Остаточная сумма квадратов

$$RSS = 0{,}16 + 0{,}04 + 0 + 4{,}84 + 2{,}56 = 7{,}6$$

ФОРМУЛА И ВЫВОД

Крупные ошибки имеют больший вес из-за возведения в квадрат.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Один остаток −2,2 даёт 4,84 из 7,6 RSS.

Общая вариация Y

$$TSS = \sum_i (Y_i - \bar{Y})^2$$

ОСНОВНАЯ ИДЕЯ

TSS измеряет общий разброс Y относительно среднего без учёта X.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Модель только с константой служит базой сравнения.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

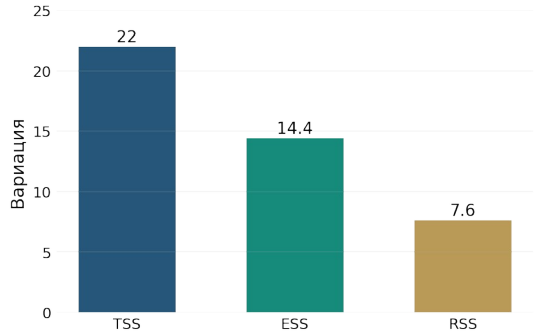
В примере отклонения от $\bar{Y} = 5$ дают TSS = 22.

Общая вариация Y

$$TSS = 4 + 1 + 0 + 1 + 16 = 22$$

ФОРМУЛА И ВЫВОД

Модель только с константой служит базой сравнения.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

В примере отклонения от $\bar{Y} = 5$ дают TSS = 22.

Объяснённая сумма квадратов

$$ESS = \sum_i (\hat{Y}_i - \bar{Y})^2$$

ОСНОВНАЯ ИДЕЯ

При наличии константы МНК делит вариацию на объяснённую и остаточную.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Тождество следует из ортогональности рассчитанных отклонений и остатков.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

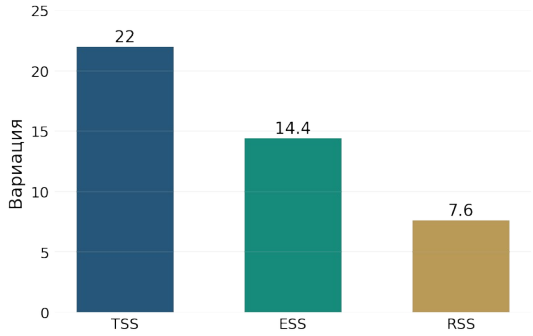
В примере ESS = 22 − 7,6 = 14,4.

Объяснённая сумма квадратов

$$TSS = ESS + RSS$$

ФОРМУЛА И ВЫВОД

Тождество следует из ортогональности рассчитанных отклонений и остатков.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

В примере ESS = 22 − 7,6 = 14,4.

Коэффициент детерминации

$$R^2 = 1 - \frac{RSS}{TSS}$$

ОСНОВНАЯ ИДЕЯ

R^2 показывает долю общей выборочной вариации Y, объяснённую регрессией с константой.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Это не вероятность истинности модели и не мера причинного эффекта.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

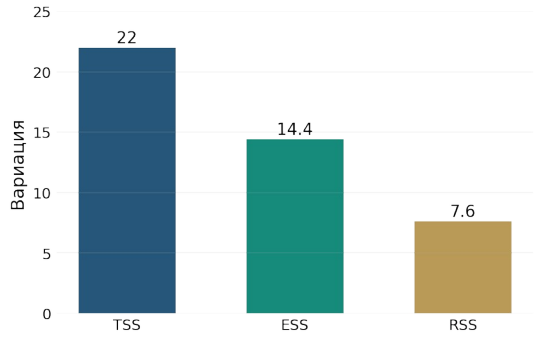
$R^2 \approx 65{,}5\%$ означает объяснение 65,5% вариации относительно $\bar{Y}$.

Коэффициент детерминации

$$R^2 = 1 - 7{,}6/22 \approx 0{,}655$$

ФОРМУЛА И ВЫВОД

Это не вероятность истинности модели и не мера причинного эффекта.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

$R^2 \approx 65{,}5\%$ означает объяснение 65,5% вариации относительно $\bar{Y}$.

Корреляция и регрессия

$$\hat{\beta}_1 = r_{XY}\frac{s_Y}{s_X}$$

ОСНОВНАЯ ИДЕЯ

Корреляция не зависит от единиц; наклон регрессии зависит от масштаба.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

В простой регрессии с константой квадрат корреляции равен R^2.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

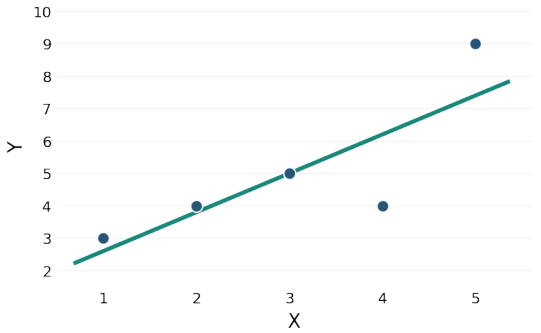
При $R^2 \approx 0{,}655$ положительная корреляция равна $\sqrt{0{,}655} \approx 0{,}809$.

Корреляция и регрессия

$$R^2 = r_{XY}^2$$

ФОРМУЛА И ВЫВОД

В простой регрессии с константой квадрат корреляции равен R^2.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При $R^2 \approx 0{,}655$ положительная корреляция равна $\sqrt{0{,}655} \approx 0{,}809$.

Экономический смысл коэффициента

$$\Delta \hat{Y} = \hat{\beta}_1 \Delta X$$

ОСНОВНАЯ ИДЕЯ

Коэффициент наклона показывает изменение подогнанного Y при увеличении X на единицу.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Всегда указывайте единицы, выборку и характер связи.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

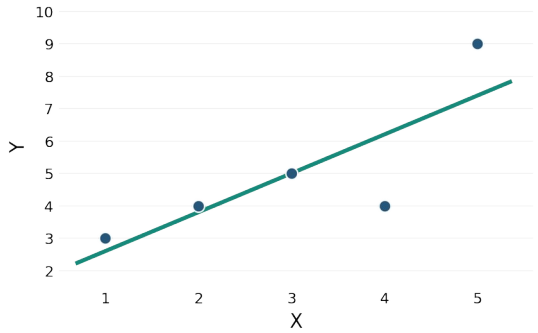
При росте X на 2 млн сумов расчётное Y растёт на 2,4 млн при наклоне 1,2.

Экономический смысл коэффициента

$$\frac{\partial E(Y \mid X)}{\partial X} = \beta_1$$

ФОРМУЛА И ВЫВОД

Всегда указывайте единицы, выборку и характер связи.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При росте X на 2 млн сумов расчётное Y растёт на 2,4 млн при наклоне 1,2.

Логарифмические спецификации

$$\ln Y = \beta_0 + \beta_1 \ln X + u$$

ОСНОВНАЯ ИДЕЯ

В модели log–log коэффициент β_1 — эластичность: увеличение X на 1% связано примерно с изменением Y на β_1%.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

В log-level модели $100\beta_1$ — приблизительный процентный отклик на +1 единицу X.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

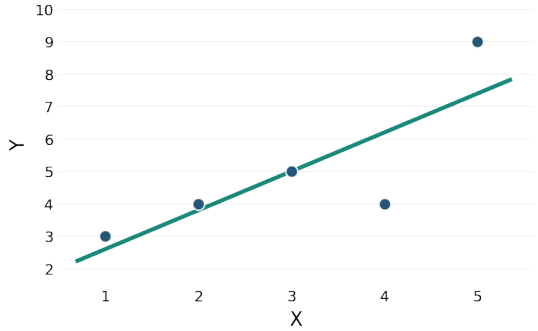
Наклон 0,6: рост X на 10% связан примерно с ростом Y на 6%.

Логарифмические спецификации

$$\frac{\partial \ln Y}{\partial \ln X} = \beta_1$$

ФОРМУЛА И ВЫВОД

В log-level модели $100\beta_1$ — приблизительный процентный отклик на +1 единицу X.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Наклон 0,6: рост X на 10% связан примерно с ростом Y на 6%.

Прогноз и экстраполяция

$$\hat{Y}(x_0) = \hat{\beta}_0 + \hat{\beta}_1 x_0$$

ОСНОВНАЯ ИДЕЯ

Прогноз внутри наблюдаемого диапазона X обычно надёжнее дальней экстраполяции.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Структурные сдвиги и нелинейность делают дальний линейный прогноз опасным.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

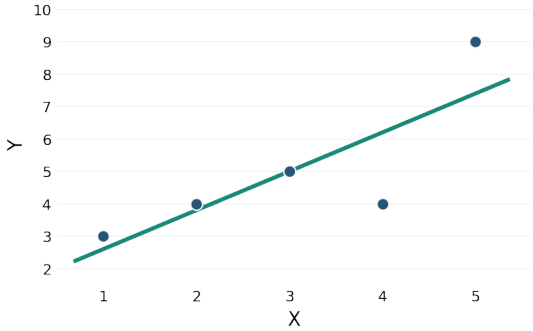
В выборке X = 1,...,5. Прогноз при X = 50 — сильная экстраполяция.

Прогноз и экстраполяция

$$x_0 < \min_i X_i \quad ; \quad x_0 > \max_i X_i$$

ФОРМУЛА И ВЫВОД

Структурные сдвиги и нелинейность делают дальний линейный прогноз опасным.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

В выборке X = 1,...,5. Прогноз при X = 50 — сильная экстраполяция.

Смещение из-за пропущенных факторов

$$Y = \beta_0 + \beta_1 X + \gamma Z + v$$

ОСНОВНАЯ ИДЕЯ

Пропуск значимого Z, коррелирующего с X, смещает оценённый наклон.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Смещение из-за пропущенной переменной возникает, когда Z влияет на Y и коррелирует с X (при остальных условиях модели).

ЭКОНОМИЧЕСКИЙ ПРИМЕР

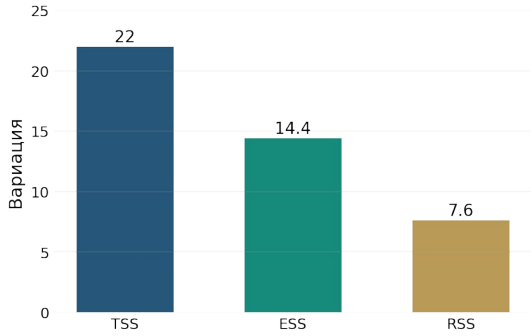
Реклама и расположение магазина могут быть связаны; расположение влияет на продажи.

Смещение из-за пропущенных факторов

$$\operatorname{plim} \hat{\beta}_1 = \beta_1 + \gamma \frac{\operatorname{Cov}(X, Z)}{\operatorname{Var}(X)}$$

ФОРМУЛА И ВЫВОД

Смещение из-за пропущенной переменной возникает, когда Z влияет на Y и коррелирует с X (при остальных условиях модели).



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Реклама и расположение магазина могут быть связаны; расположение влияет на продажи.

Связь ещё не означает причинность

$$\Delta E(Y \mid X) \equiv \text{ATE}$$

ОСНОВНАЯ ИДЕЯ

Оценка МНК отражает связь между X и Y; для причинной интерпретации требуются дополнительные предпосылки.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Обратная причинность, отбор и пропущенные переменные могут искажать наклон.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

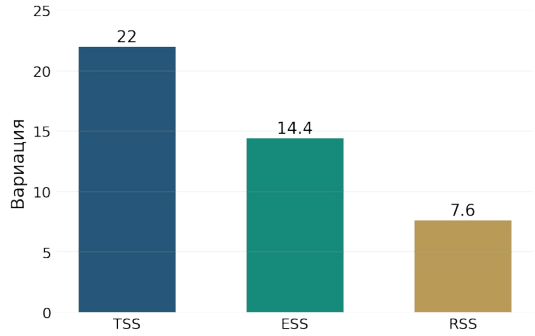
Компании с высокими продажами могут больше рекламироваться: направление причинности неясно.

Связь ещё не означает причинность

$$\mathrm{Cov}(X, u) \neq 0$$

ФОРМУЛА И ВЫВОД

Обратная причинность, отбор и пропущенные переменные могут искажать наклон.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Компании с высокими продажами могут больше рекламироваться: направление причинности неясно.

ГЛАВНЫЕ ФОРМУЛЫ ЗАНЯТИЯ

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

$$RSS = \sum_i \hat{u}_i^2$$

$$R^2 = 1 - \frac{RSS}{TSS}$$

КЛЮЧЕВОЙ ВЫВОД

МНК оценивает параметры по данным, но хорошая подгонка сама по себе не доказывает причинность.

ЗАДАЧИ ДЛЯ АУДИТОРИИ

01 ДАННЫЕ: X = (0,1,2), Y = (1,2,2). Найдите $\bar{X}$, $\bar{Y}$, Sxx и Sxy.

02 Найдите $\hat{\beta}_1$ и $\hat{\beta}_0$ из нормальных уравнений.

03 Рассчитайте $\hat{Y}$ при X = 3. Это интерполяция или экстраполяция?

04 Почему наклон регрессии ещё не является причинным эффектом?

ОТВЕТЫ И ИНТЕРПРЕТАЦИЯ

01 $\bar{X} = 1$, $\bar{Y} = 5/3$, $Sxx = 2$, $Sxy = 1$.

02 $\hat{\beta}_1 = 1/2$, $\hat{\beta}_0 = 7/6$. Уравнение: $\hat{Y} = 7/6 + X/2$.

03 $\hat{Y}(3) = 8/3 \approx 2{,}667$. $X = 3$ вне диапазона $X \in [0,2]$.

04 Для причинного вывода нужны экзогенность и обоснованный дизайн.

Далее: свойства оценок МНК и статистические выводы