ПРЕДПОСЫЛКИ МНК, НЕОПРЕДЕЛЁННОСТЬ И СТАТИСТИЧЕСКИЙ ВЫВОД

От оценки коэффициента к обоснованному статистическому выводу

ДАННЫЕ → МОДЕЛЬ → ОЦЕНИВАНИЕ → ПРОВЕРКА → РЕШЕНИЕ

TASHKENT INTERNATIONAL UNIVERSITY

Преподаватель: Azizbek Ilkhomzoda

TASHKENT INTERNATIONAL UNIVERSITY

ЦЕЛИ ЗАНЯТИЯ

01 Проверять классические предпосылки МНК

02 Выводить несмещённость и дисперсию

03 Вычислять σ^2, SE и t-статистику

04 Строить доверительные и прогнозные интервалы

05 Понимать p-значения и F-тест

06 Распознавать гетероскедастичность и эндогенность

Почему оценки меняются от выборки к выборке

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_i (X_i - \bar{X}) u_i}{S_{xx}}$$

ОСНОВНАЯ ИДЕЯ

Истинный наклон фиксирован, но новая случайная выборка даёт новую оценку.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Выборочная неопределённость связана с распределением оценивателя по возможным выборкам.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

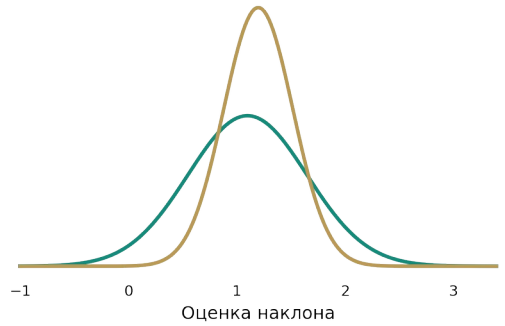
В двух случайных выборках по 30 магазинов наклоны обычно различаются.

Почему оценки меняются от выборки к выборке

$$\hat{\beta}_1 - \beta_1 = \frac{\sum_i (X_i - \bar{X}) u_i}{S_{xx}}$$

ФОРМУЛА И ВЫВОД

Выборочная неопределённость связана с распределением оценивателя по возможным выборкам.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

В двух случайных выборках по 30 магазинов наклоны обычно различаются.

Предпосылка: случайная выборка

$$(X_i, Y_i) \overset{iid}{\sim} F_{XY}$$

ОСНОВНАЯ ИДЕЯ

В базовой теории МНК наблюдения обычно независимы и одинаково распределены.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Временные ряды, кластеры и повторы требуют других поправок.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

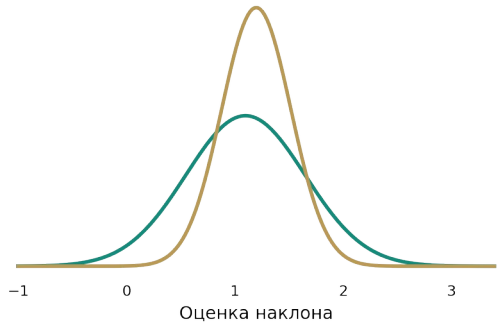
Десять лет данных одного магазина не равны десяти независимым магазинам.

Предпосылка: случайная выборка

$$E(\bar{Y}) = E(Y)$$

ФОРМУЛА И ВЫВОД

Временные ряды, кластеры и повторы требуют других поправок.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Десять лет данных одного магазина не равны десяти независимым магазинам.

Предпосылка: линейность по параметрам

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

ОСНОВНАЯ ИДЕЯ

Линейная регрессия означает линейность по β, не обязательно по X.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Квадрат X можно включить в модель, оцениваемую МНК.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

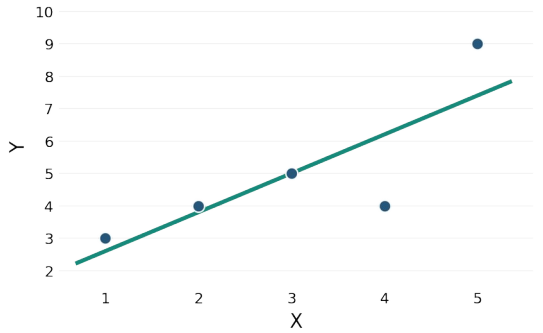
Квадратичная модель задаёт изменяющийся эффект $\beta_1 + 2\beta_2 X$.

Предпосылка: линейность по параметрам

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + u_i$$

ФОРМУЛА И ВЫВОД

Квадрат X можно включить в модель, оцениваемую МНК.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Квадратичная модель задаёт изменяющийся эффект $\beta_1 + 2\beta_2 X$.

Предпосылка: отсутствие точной мультиколлинеарности

$$S_{xx} = \sum_i (X_i - \bar{X})^2 > 0$$

ОСНОВНАЯ ИДЕЯ

Регрессоры должны иметь достаточно независимой вариации для оценки коэффициентов.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

При точной линейной зависимости матрица X^TX необратима.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

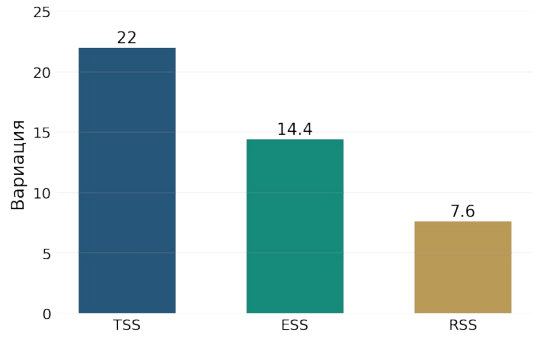
При одинаковом рекламном бюджете во всех наблюдениях наклон не определить.

Предпосылка: отсутствие точной мультиколлинеарности

$$\operatorname{rank}(\mathbf{X}) = k$$

ФОРМУЛА И ВЫВОД

При точной линейной зависимости матрица X^TX необратима.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При одинаковом рекламном бюджете во всех наблюдениях наклон не определить.

Предпосылка: экзогенность

$$E(u_i \mid X_i) = 0$$

ОСНОВНАЯ ИДЕЯ

Нулевое условное математическое ожидание ошибки обеспечивает несмещённость МНК при выполнении остальных условий.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Оно не следует из механической ортогональности выборочных остатков.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

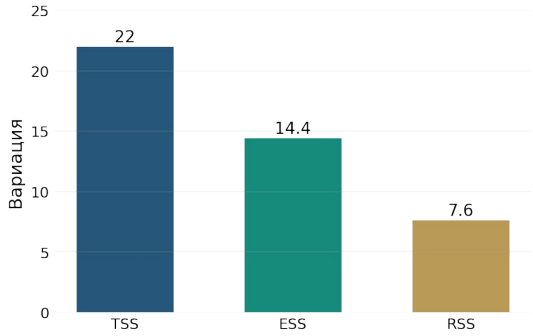
Пропуск размера магазина нарушит условие, если размер связан с рекламой и продажами.

Предпосылка: экзогенность

$$E(\hat{\beta}_1 \mid X) = \beta_1$$

ФОРМУЛА И ВЫВОД

Оно не следует из механической ортогональности выборочных остатков.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Пропуск размера магазина нарушит условие, если размер связан с рекламой и продажами.

Предпосылка: гомоскедастичность

$$\mathrm{Var}(u_i \mid X_i) = \sigma^2$$

ОСНОВНАЯ ИДЕЯ

Гомоскедастичность: условная дисперсия ошибки одинакова при каждом X.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Гомоскедастичность при прочих классических предпосылках позволяет применять обычные формулы дисперсий оценок МНК.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

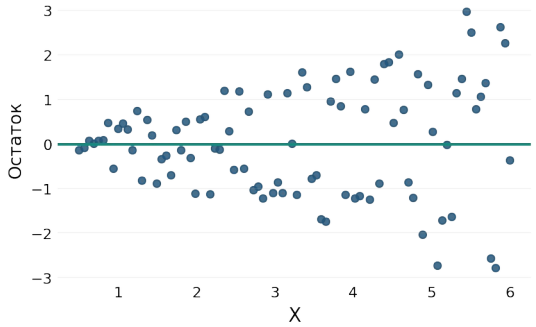
В крупных магазинах разброс продаж может быть больше: гетероскедастичность.

Предпосылка: гомоскедастичность

$$\mathrm{Var}(u_i \mid X_i = x) = \sigma^2 \quad \forall x$$

ФОРМУЛА И ВЫВОД

Гомоскедастичность при прочих классических предпосылках позволяет применять обычные формулы дисперсий оценок МНК.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

В крупных магазинах разброс продаж может быть больше: гетероскедастичность.

Нормальность нужна не всегда

$$u_i \mid X_i \sim N(0, \sigma^2)$$

ОСНОВНАЯ ИДЕЯ

Нормальность ошибок даёт точное t-распределение в конечной выборке.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

В больших выборках центральная предельная теорема при подходящих условиях позволяет проводить приближённые тесты без нормальности ошибок.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

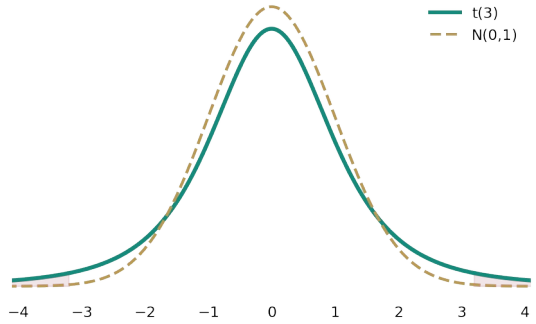
При n = 5 предпосылки распределения важнее, чем при n = 500.

Нормальность нужна не всегда

$$\frac{\hat{\beta}_1 - \beta_1}{se(\hat{\beta}_1)} \sim t_{n-2}$$

ФОРМУЛА И ВЫВОД

В больших выборках центральная предельная теорема при подходящих условиях позволяет проводить приближённые тесты без нормальности ошибок.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При n = 5 предпосылки распределения важнее, чем при n = 500.

Алгебра несмещённости

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_i (X_i - \bar{X}) u_i}{S_{xx}}$$

ОСНОВНАЯ ИДЕЯ

Подстановка истинной модели отделяет наклон от части, связанной с ошибками.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

При нулевом условном среднем математическое ожидание шумового члена равно нулю.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

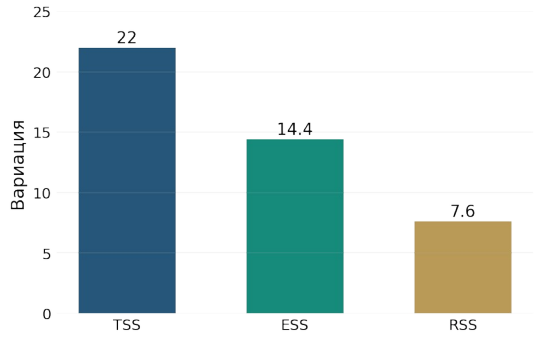
Несмещённость не означает точного совпадения каждой оценки с параметром.

Алгебра несмещённости

$$E(\hat{\beta}_1 \mid X) = \beta_1$$

ФОРМУЛА И ВЫВОД

При нулевом условном среднем математическое ожидание шумового члена равно нулю.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Несмещённость не означает точного совпадения каждой оценки с параметром.

Выборочная дисперсия наклона

$$\mathrm{Var}(\hat{\beta}_1 \mid X) = \frac{\sigma^2}{S_{xx}}$$

ОСНОВНАЯ ИДЕЯ

Шум σ^2 увеличивает неопределённость; вариация X уменьшает её.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Формула требует гомоскедастичности и независимых ошибок.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

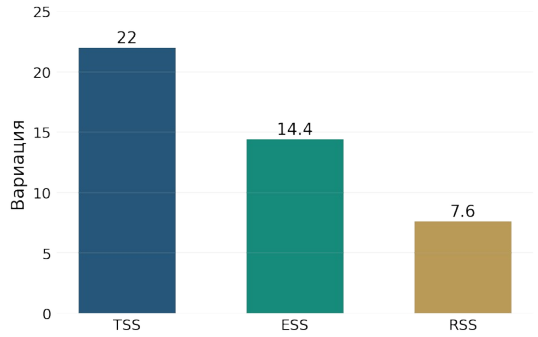
Удвоение Sxx при том же σ^2 уменьшает дисперсию наклона вдвое.

Выборочная дисперсия наклона

$$\mathrm{SD}(\hat{\beta}_1 \mid X) = \frac{\sigma}{\sqrt{S_{xx}}}$$

ФОРМУЛА И ВЫВОД

Формула требует гомоскедастичности и независимых ошибок.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Удвоение Sxx при том же σ^2 уменьшает дисперсию наклона вдвое.

Оценка дисперсии ошибок

$$s^2 = \frac{RSS}{n-2}$$

ОСНОВНАЯ ИДЕЯ

В простой регрессии оцениваются два параметра, поэтому степени свободы n − 2.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Деление на n давало бы в среднем заниженную оценку при классических условиях.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

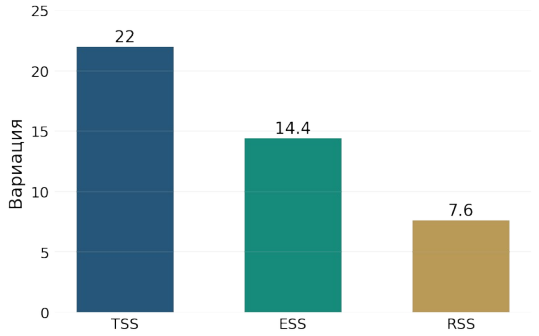
При RSS = 7,6 и n = 5 получаем $s^2 = 7{,}6 / 3 \approx 2{,}533$.

Оценка дисперсии ошибок

$$RSS = \sum_i \hat{u}_i^2$$

ФОРМУЛА И ВЫВОД

Деление на n давало бы в среднем заниженную оценку при классических условиях.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При RSS = 7,6 и n = 5 получаем $s^2 = 7{,}6 / 3 \approx 2{,}533$.

Стандартная ошибка наклона

$$se(\hat{\beta}_1) = \sqrt{\frac{s^2}{S_{xx}}}$$

ОСНОВНАЯ ИДЕЯ

Стандартная ошибка оценивает стандартное отклонение оценивателя наклона.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Малая стандартная ошибка указывает на более точную оценку.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

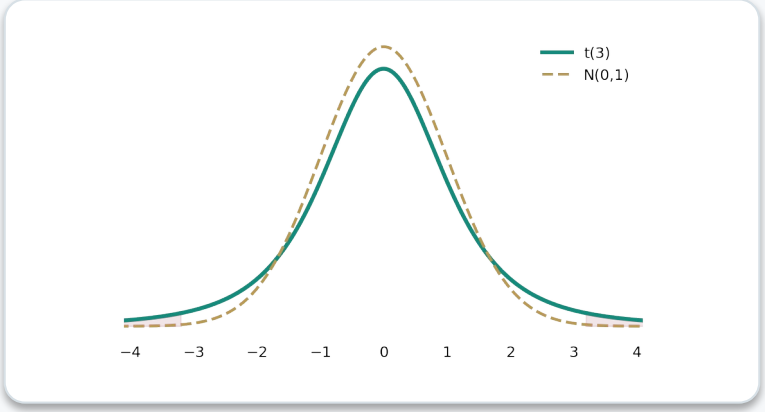
Для пяти магазинов наклон 1,2 имеет стандартную ошибку около 0,503.

Стандартная ошибка наклона

$$se = \sqrt{2{,}533/10} \approx 0{,}503$$

ФОРМУЛА И ВЫВОД

Малая стандартная ошибка указывает на более точную оценку.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Для пяти магазинов наклон 1,2 имеет стандартную ошибку около 0,503.

Стандартная ошибка константы

$$\mathrm{Var}(\hat{\beta}_0 \mid X) = \sigma^2\left(\frac{1}{n} + \frac{\bar{X}^2}{S_{xx}}\right)$$

ОСНОВНАЯ ИДЕЯ

Неопределённость константы растёт, когда среднее X далеко от нуля.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

При центрировании X свободный член соответствует ожидаемому Y в точке среднего X; его стандартная ошибка уменьшается.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

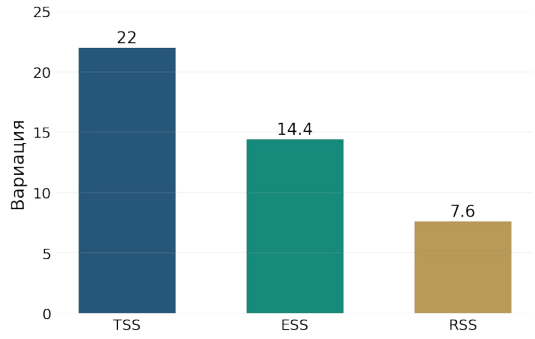
При n = 5, $\bar{X}$ = 3, Sxx = 10 и $s^2 \approx 2{,}533$: SE константы ≈ 1,669.

Стандартная ошибка константы

$$se(\hat{\beta}_0) = s\sqrt{\frac{1}{n} + \frac{\bar{X}^2}{S_{xx}}}$$

ФОРМУЛА И ВЫВОД

При центрировании X свободный член соответствует ожидаемому Y в точке среднего X; его стандартная ошибка уменьшается.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При n = 5, $\bar{X}$ = 3, Sxx = 10 и $s^2 \approx 2{,}533$: SE константы ≈ 1,669.

Теорема Гаусса—Маркова

$$\hat{\beta}_{OLS} \quad \text{BLUE}$$

ОСНОВНАЯ ИДЕЯ

При предпосылках теоремы Гаусса—Маркова оценки МНК имеют минимальную дисперсию среди линейных несмещённых оценивателей.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

BLUE — «наилучший линейный несмещённый оцениватель»; нормальность ошибок для теоремы не требуется.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

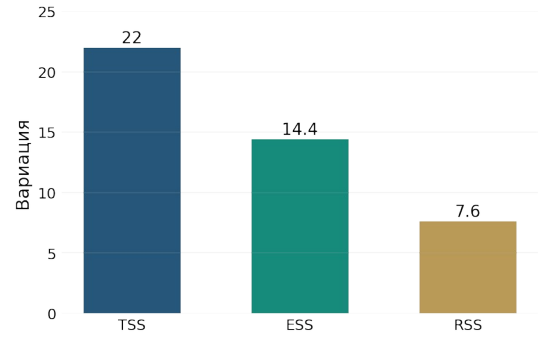
Гетероскедастичность устраняет стандартную гарантию эффективности.

Теорема Гаусса—Маркова

$$\mathrm{Var}(\tilde{\beta}_1 \mid X) \geq \mathrm{Var}(\hat{\beta}_1 \mid X)$$

ФОРМУЛА И ВЫВОД

BLUE — «наилучший линейный несмещённый оцениватель»; нормальность ошибок для теоремы не требуется.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Гетероскедастичность устраняет стандартную гарантию эффективности.

t-распределение и степени свободы

$$T = \frac{\hat{\beta}_1 - \beta_1}{se(\hat{\beta}_1)}$$

ОСНОВНАЯ ИДЕЯ

t-распределение похоже на нормальное, но при малой выборке имеет более тяжёлые хвосты.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Степени свободы учитывают оценивание двух коэффициентов.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

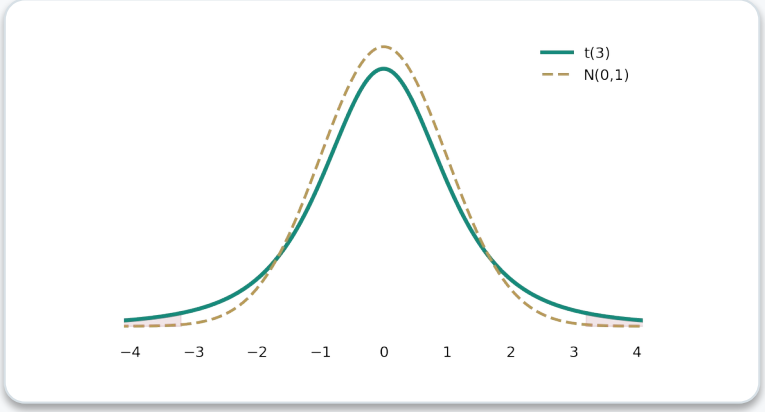
Для пяти магазинов классический t-тест использует 3 степени свободы.

t-распределение и степени свободы

$$T \sim t_{n-2}$$

ФОРМУЛА И ВЫВОД

Степени свободы учитывают оценивание двух коэффициентов.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Для пяти магазинов классический t-тест использует 3 степени свободы.

Нулевая и альтернативная гипотезы

$$H_0 : \beta_1 = 0$$

ОСНОВНАЯ ИДЕЯ

Нулевая гипотеза задаёт проверяемое значение параметра, альтернативная — конкурирующее утверждение.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Неотклонение H_0 не доказывает её истинность; данных может быть мало.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

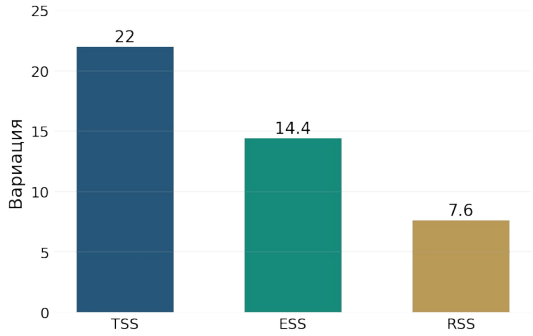
Проверка рекламы: H_0 утверждает, что генеральная связь равна нулю.

Нулевая и альтернативная гипотезы

$$H_1 : \beta_1 \neq 0$$

ФОРМУЛА И ВЫВОД

Неотклонение H_0 не доказывает её истинность; данных может быть мало.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Проверка рекламы: H_0 утверждает, что генеральная связь равна нулю.

Двусторонний и односторонний тест

$$H_1 : \beta_1 > 0 \quad ; \quad H_1 : \beta_1 < 0$$

ОСНОВНАЯ ИДЕЯ

Двусторонний тест выявляет оба знака; односторонний — выбранное направление.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Альтернативу следует выбрать до анализа данных, а не после результата.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

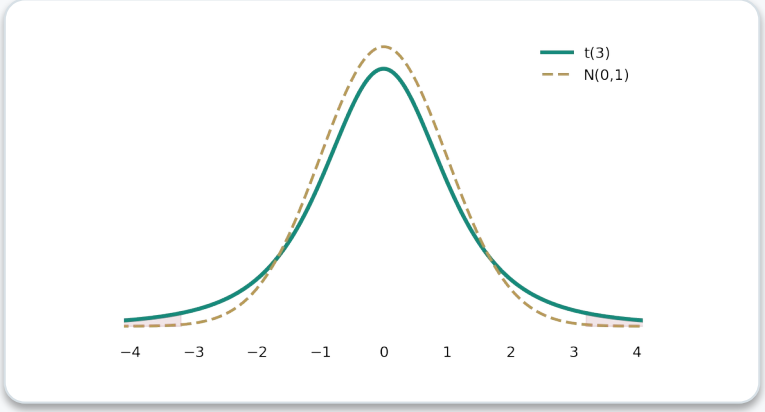
Для утверждения «реклама увеличивает продажи» подходит H_1: $\beta_1 > 0$.

Двусторонний и односторонний тест

$$H_1 : \beta_1 \neq 0$$

ФОРМУЛА И ВЫВОД

Альтернативу следует выбрать до анализа данных, а не после результата.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Для утверждения «реклама увеличивает продажи» подходит H_1: $\beta_1 > 0$.

Как рассчитать t-статистику

$$t = \frac{\hat{\beta}_1 - \beta_{1,0}}{se(\hat{\beta}_1)}$$

ОСНОВНАЯ ИДЕЯ

t-статистика — расстояние от нулевой гипотезы в единицах стандартной ошибки.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Одинаковый коэффициент может быть значимым или нет в зависимости от точности.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

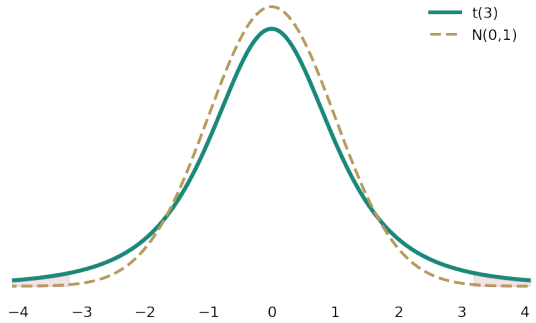
Для пяти магазинов t ≈ 2,384 и df = 3 не хватает для двустороннего теста 5%.

Как рассчитать t-статистику

$$t = \frac{1{,}2 - 0}{0{,}503} \approx 2{,}384$$

ФОРМУЛА И ВЫВОД

Одинаковый коэффициент может быть значимым или нет в зависимости от точности.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Для пяти магазинов t ≈ 2,384 и df = 3 не хватает для двустороннего теста 5%.

p-значение

$$p = P(|T| \geq |t_{obs}| \mid H_0)$$

ОСНОВНАЯ ИДЕЯ

p-значение — вероятность при верной H_0 получить тестовую статистику не менее экстремальную, чем наблюдаемая.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Это не вероятность того, что нулевая гипотеза истинна.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

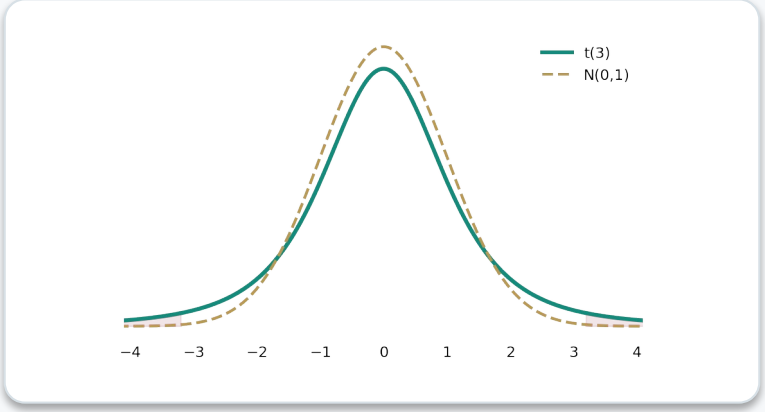
Например, p = 0,03 означает вероятность 3% получить столь же или более экстремальную статистику при H_0.

p-значение

$$p_{two-sided} = 2P(T_{df} \geq |t_{obs}|)$$

ФОРМУЛА И ВЫВОД

Это не вероятность того, что нулевая гипотеза истинна.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Например, p = 0,03 означает вероятность 3% получить столь же или более экстремальную статистику при H_0.

Критические значения и решения

$$|t_{obs}| > t_{1-\alpha/2,\,n-2}$$

ОСНОВНАЯ ИДЕЯ

Двусторонний тест 5% отклоняет H_0 при выходе t за критические границы.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Критические значения зависят от уровня значимости и степеней свободы.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

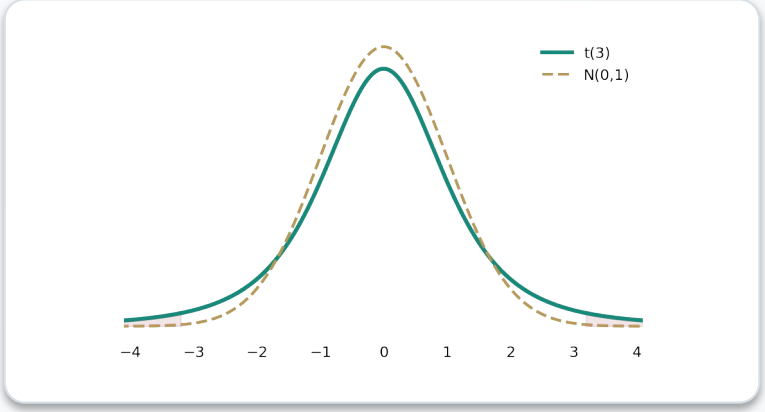
Так как |2,384| < 3,182 при df = 3, H_0 на уровне 5% не отклоняем.

Критические значения и решения

$$t_{0,975,\,3} \approx 3{,}182$$

ФОРМУЛА И ВЫВОД

Критические значения зависят от уровня значимости и степеней свободы.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Так как $|2{,}384| < 3{,}182$ при $df = 3$, H_0 на уровне 5% не отклоняем.

95%-й доверительный интервал

$$CI = \hat{\beta}_1 \pm t_{0,975,\,n-2} se(\hat{\beta}_1)$$

ОСНОВНАЯ ИДЕЯ

Доверительный интервал характеризует неопределённость оценки параметра, а не вероятность истинности гипотезы.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Процедура 95% покрывает истинный параметр в 95% повторных выборок при выполнении условий.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

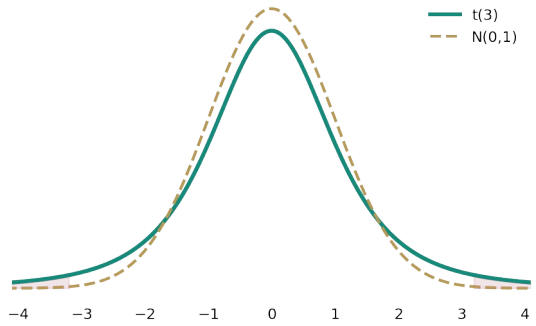
Широкий интервал включает нуль: пять наблюдений дают малую точность.

95%-й доверительный интервал

$$1{,}2 \pm 3{,}182(0{,}503) \approx [-0{,}401,\ 2{,}801]$$

ФОРМУЛА И ВЫВОД

Процедура 95% покрывает истинный параметр в 95% повторных выборок при выполнении условий.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Широкий интервал включает нуль: пять наблюдений дают малую точность.

Тест и интервал: эквивалентность

$$0 \notin CI_{95\%} \iff p_{two-sided} < 0{,}05$$

ОСНОВНАЯ ИДЕЯ

При согласованных предпосылках двусторонний тест и соответствующий доверительный интервал приводят к одному решению.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Неотклонение означает недостаток доказательств, а не отсутствие реального эффекта.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

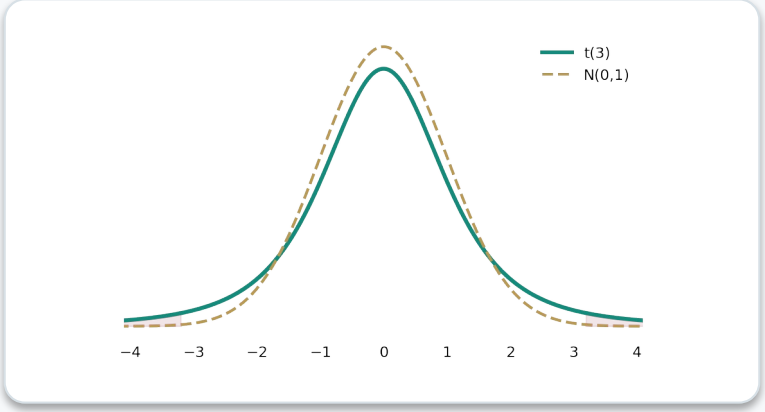
Наш интервал включает 0 — как и решение t-теста на уровне 5%.

Тест и интервал: эквивалентность

$$0 \in [-0{,}401,\ 2{,}801]$$

ФОРМУЛА И ВЫВОД

Неотклонение означает недостаток доказательств, а не отсутствие реального эффекта.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Наш интервал включает 0 — как и решение t-теста на уровне 5%.

Практическая и статистическая значимость

$$|\hat{\beta}_1| \equiv p$$

ОСНОВНАЯ ИДЕЯ

В большой выборке даже малый эффект значим; в маленькой большой эффект может быть неточным.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Указывайте единицы измерения эффекта, доверительный интервал, p-значение и экономическую значимость.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

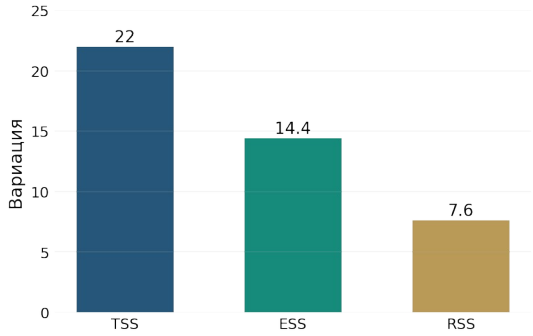
Прирост 0,01 сума может быть статистически очевиден, но экономически ничтожен.

Практическая и статистическая значимость

$$\Delta \hat{Y} = \hat{\beta}_1 \Delta X$$

ФОРМУЛА И ВЫВОД

Указывайте единицы измерения эффекта, доверительный интервал, p-значение и экономическую значимость.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Прирост 0,01 сума может быть статистически очевиден, но экономически ничтожен.

Стандартная ошибка и размер выборки

$$se(\hat{\beta}_1) \propto 1/\sqrt{n}$$

ОСНОВНАЯ ИДЕЯ

При сходном разбросе X и стабильной дисперсии точность растёт с n.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Чтобы примерно вдвое снизить SE, часто нужно увеличить n примерно в четыре раза.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

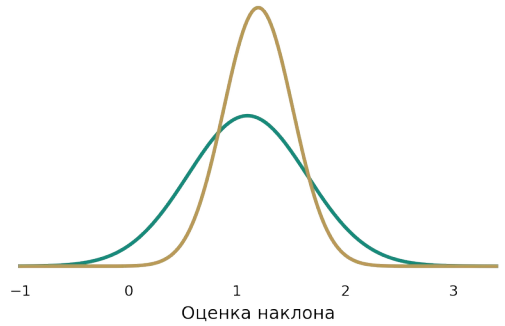
При сходных условиях n = 400 даёт примерно вдвое меньшую SE, чем n = 100.

Стандартная ошибка и размер выборки

$$\mathrm{Var}(\hat{\beta}_1 \mid X) = \sigma^2 / S_{xx}$$

ФОРМУЛА И ВЫВОД

Чтобы примерно вдвое снизить SE, часто нужно увеличить n примерно в четыре раза.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При сходных условиях n = 400 даёт примерно вдвое меньшую SE, чем n = 100.

F-тест в простой регрессии

$$F = \frac{ESS/1}{RSS/(n-2)}$$

ОСНОВНАЯ ИДЕЯ

При одном регрессоре общий F-тест равен квадрату t-теста наклона.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

F сравнивает улучшение подгонки и остаточный шум с учётом степеней свободы.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

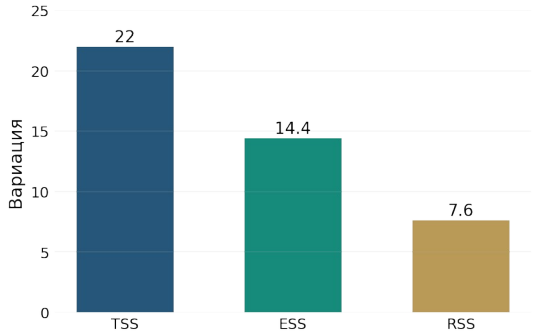
В примере $F = 14{,}4/(7{,}6/3) \approx 5{,}684$ и $t^2 \approx 5{,}684$.

F-тест в простой регрессии

$$F = t^2_{\hat{\beta}_1}$$

ФОРМУЛА И ВЫВОД

F сравнивает улучшение подгонки и остаточный шум с учётом степеней свободы.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

В примере $F = 14{,}4/(7{,}6/3) \approx 5{,}684$ и $t^2 \approx 5{,}684$.

Средний отклик и прогноз отдельного Y

$$se_{mean}(x_0) = s\sqrt{\frac{1}{n} + \frac{(x_0 - \bar{X})^2}{S_{xx}}}$$

ОСНОВНАЯ ИДЕЯ

Прогнозный интервал для отдельного Y шире интервала для условного среднего: он включает будущую случайную ошибку.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Интервал прогноза не уже доверительного интервала среднего при том же X.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

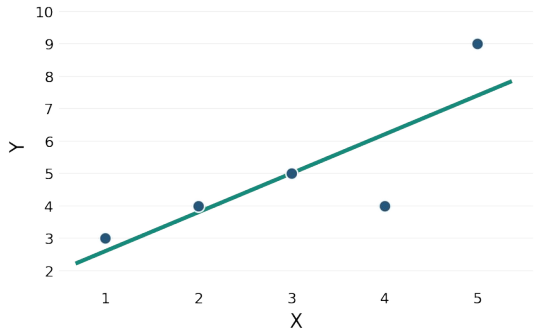
Среднюю выручку магазинов с X = 3 оцениваем точнее выручки одного конкретного магазина.

Средний отклик и прогноз отдельного Y

$$se_{pred}(x_0) = s\sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{S_{xx}}}$$

ФОРМУЛА И ВЫВОД

Интервал прогноза не уже доверительного интервала среднего при том же X.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Среднюю выручку магазинов с X = 3 оцениваем точнее выручки одного конкретного магазина.

Интервал для прогнозной выручки

$$\hat{Y}(x_0) \pm t_{1-\alpha/2,\,n-2} se_{pred}(x_0)$$

ОСНОВНАЯ ИДЕЯ

Прогнозная неопределённость включает ошибку оценки коэффициентов и будущий шум.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Интервал расширяется по мере удаления x_0 от среднего X.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

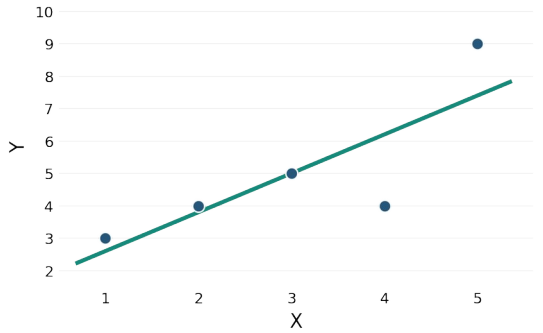
Прогноз при X = 15 менее надёжен, чем при X = 3, если данные лежат от 1 до 5.

Интервал для прогнозной выручки

$$x_0 = \bar{X} \Rightarrow se_{pred} = s\sqrt{1 + 1/n}$$

ФОРМУЛА И ВЫВОД

Интервал расширяется по мере удаления x_0 от среднего X.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Прогноз при X = 15 менее надёжен, чем при X = 3, если данные лежат от 1 до 5.

Что доказывает и не доказывает R^2

$$R^2 = 1 - \frac{RSS}{TSS}$$

ОСНОВНАЯ ИДЕЯ

Качество подгонки и достоверность причинного вывода — разные вещи.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Высокое R^2 может быть обусловлено общим трендом, пропущенными факторами либо механической взаимосвязью.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

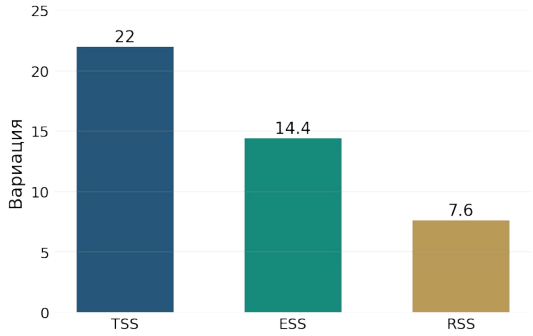
Два трендовых макроряда могут дать высокий R^2 без причинной связи.

Что доказывает и не доказывает R^2

$$R^2 \Rightarrow E(u \mid X) = 0$$

ФОРМУЛА И ВЫВОД

Высокое R^2 может быть обусловлено общим трендом, пропущенными факторами либо механической взаимосвязью.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Два трендовых макроряда могут дать высокий R^2 без причинной связи.

Асимптотическое приближение

$$\sqrt{n}(\hat{\beta}_1 - \beta_1) \xrightarrow{d} N(0, V)$$

ОСНОВНАЯ ИДЕЯ

Состоятельность — сходимость к параметру; асимптотическая нормальность описывает масштаб ошибок.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Нужны условия регулярности и экзогенность; большой n не исправляет смещение.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

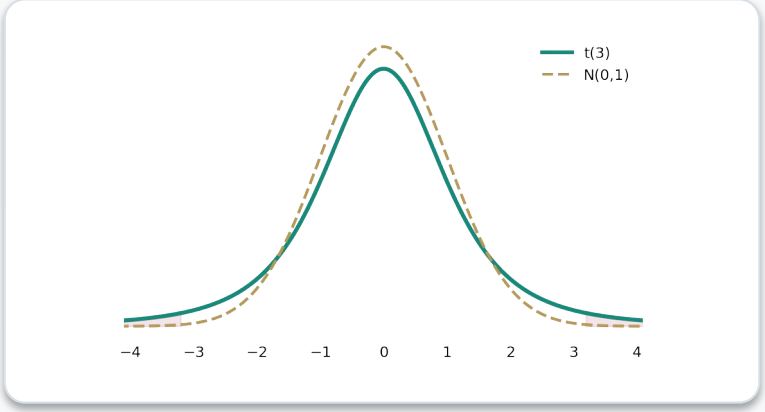
Точная оценка по смещённым данным может быть уверенно неверной.

Асимптотическое приближение

$$\hat{\beta}_1 \xrightarrow{p} \beta_1$$

ФОРМУЛА И ВЫВОД

Нужны условия регулярности и экзогенность; большой n не исправляет смещение.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Точная оценка по смещённым данным может быть уверенно неверной.

Гетероскедастичность: последствия

$$\mathrm{Var}(u_i \mid X_i) = \sigma_i^2$$

ОСНОВНАЯ ИДЕЯ

При гетероскедастичности обычная оценка стандартной ошибки может быть некорректна, хотя МНК остаётся несмещённым при экзогенности.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

При экзогенности МНК может оставаться несмещённым, но терять эффективность.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

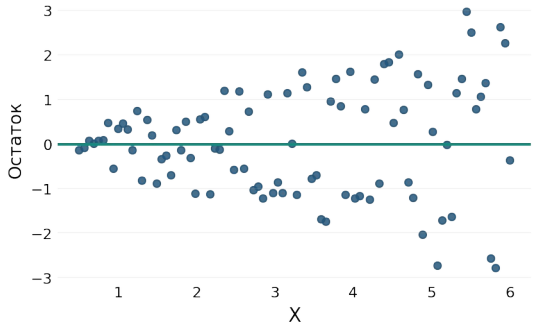
Веерообразные остатки указывают на рост дисперсии с прогнозной выручкой.

Гетероскедастичность: последствия

$$\operatorname{Var}(\hat{\beta}_1 \mid X) = \frac{\sum_i (x_i - \bar{x})^2 \sigma_i^2}{s_{xx}^2}$$

ФОРМУЛА И ВЫВОД

При экзогенности МНК может оставаться несмещённым, но терять эффективность.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Веерообразные остатки указывают на рост дисперсии с прогнозной выручкой.

Робастные стандартные ошибки

$$\widehat{\mathrm{Var}}_{HC0}(\hat{\beta}) = (X^T X)^{-1} X^T \mathrm{diag}(\hat{u}_i^2) X (X^T X)^{-1}$$

ОСНОВНАЯ ИДЕЯ

Робастная «сэндвич»-оценка ковариационной матрицы учитывает неодинаковые условные дисперсии ошибок.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Робастные стандартные ошибки корректируют статистический вывод, но не сами оценки коэффициентов МНК.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

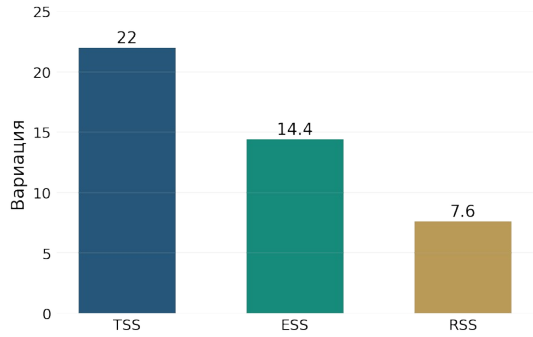
При небольшом объёме выборки используют поправки HC1 или HC3, учитывая ограничения асимптотического приближения.

Робастные стандартные ошибки

$$\widehat{\mathrm{Var}}_{HC1} = \frac{n}{n-k}\widehat{\mathrm{Var}}_{HC0}$$

ФОРМУЛА И ВЫВОД

Робастные стандартные ошибки корректируют статистический вывод, но не сами оценки коэффициентов МНК.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При небольшом объёме выборки используют поправки HC1 или HC3, учитывая ограничения асимптотического приближения.

Эндогенность и пропущенные переменные

$$\mathrm{Cov}(X, u) \neq 0$$

ОСНОВНАЯ ИДЕЯ

Эндогенность искажает интерпретацию и может сделать оценку несостоятельной.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Робастная SE исправляет дисперсию, но не смещение от эндогенности.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

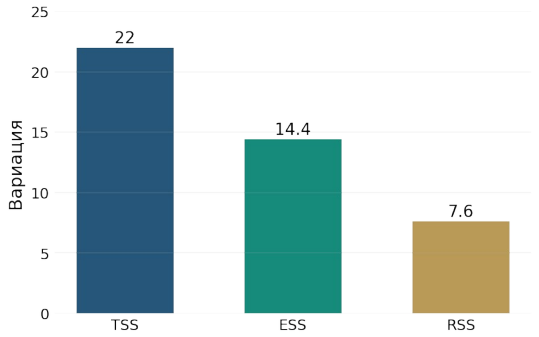
Обратная причинность: успешные магазины рекламируются больше из-за продаж.

Эндогенность и пропущенные переменные

$$\operatorname{plim} \hat{\beta}_1 \neq \beta_1$$

ФОРМУЛА И ВЫВОД

Робастная SE исправляет дисперсию, но не смещение от эндогенности.



ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

Обратная причинность: успешные магазины рекламируются больше из-за продаж.

Как грамотно оформить результат регрессии

$$\hat{Y} = 1{,}4 + 1{,}2X, \quad R^2 = 0{,}655, \quad n = 5$$

ОСНОВНАЯ ИДЕЯ

Сообщайте модель, единицы, коэффициенты, неопределённость и ограничения вместе.

ОБОСНОВАНИЕ И ИНТЕРПРЕТАЦИЯ

Уточняйте: это статистическая связь или обоснованный причинный эффект.

ЭКОНОМИЧЕСКИЙ ПРИМЕР

При n = 5 оценка наклона равна 1,2, стандартная ошибка — 0,503, а 95%-й доверительный интервал включает нуль.

Как грамотно оформить результат регрессии

$$\hat{\beta}_1 = 1{,}2, \quad se = 0{,}503, \quad CI_{95\%} = [-0{,}401, 2{,}801]$$

ФОРМУЛА И ВЫВОД

Уточняйте: это статистическая связь или обоснованный причинный эффект.

i	1	2	3	4	5
X	1	2	3	4	5
Y	3	4	5	4	9
Ŷ	2.6	3.8	5.0	6.2	7.4

ИНТЕРПРЕТАЦИЯ НА ПРИМЕРЕ

При n = 5 оценка наклона равна 1,2, стандартная ошибка — 0,503, а 95%-й доверительный интервал включает нуль.

ГЛАВНЫЕ ФОРМУЛЫ ЗАНЯТИЯ

$$\mathrm{Var}(\hat{\beta}_1 \mid X) = \frac{\sigma^2}{S_{xx}}$$

$$se(\hat{\beta}_1) = \sqrt{\frac{s^2}{S_{xx}}}$$

$$t = \frac{\hat{\beta}_1 - \beta_{1,0}}{se(\hat{\beta}_1)}$$

$$CI = \hat{\beta}_1 \pm t^* se(\hat{\beta}_1)$$

КЛЮЧЕВОЙ ВЫВОД

Представляйте оценки коэффициентов вместе со стандартными ошибками, предпосылками и интервалами неопределённости.

ЗАДАЧИ ДЛЯ АУДИТОРИИ

01 Пусть $\hat{\beta}_1 = 0{,}8$, SE = 0,2, n = 102. Проверьте H_0: $\beta_1 = 0$.

02 Постройте 95%-й доверительный интервал: t крит. = 1,984 (100 степеней свободы).

03 Как меняется статистический вывод при гетероскедастичности?

04 Почему робастная SE не устраняет смещение пропущенных факторов?

TASHKENT INTERNATIONAL UNIVERSITY

ОТВЕТЫ И ИНТЕРПРЕТАЦИЯ

01 t = 0,8/0,2 = 4,0; при 100 степенях свободы H_0 отклоняется (двусторонний тест, 5%).

02 95%-й ДИ = 0,8 ± 1,984 × 0,2 = [0,4032; 1,1968].

03 Используйте робастные стандартные ошибки и проверьте предпосылки.

04 Эндогенность смещает коэффициенты; робастные стандартные ошибки корректируют лишь оценку дисперсии.

Далее: множественная регрессия и контроль других факторов