

Ташкентский международный университет · Факультет экономики Данные, методология исследований и описательная статистика

Неделя 1 · Лекции 1 и 2

Ташкентский международный университет · Факультет экономики

2025/2026 учебный
год



Почему именно этот курс? Каждое эмпирическое утверждение основано на статистическом выводе.


В 2019 году газета написала:

«Урожайность пшеницы в Узбекистане резко возросла после обретения независимости — сельскохозяйственные реформы увенчались успехом».

Это предложение содержит четыре статистических утверждения:

- ▶ «урожайность» — как она измерялась?
- ▶ «резко возросла» — насколько? За какой период?
- ▶ «успешно» — где основание для сравнения?
- ▶ «из-за реформ» — причинно-следственное утверждение

Вопрос аудитории: Какое из четырех утверждений подтверждает этот график?



Источник: FAOSTAT / Our World in Data

Цели обучения на 1-ю неделю

К концу этой недели вы сможете:

1. Объяснить структуру таблицы данных: единица наблюдения и переменная.
2. Классифицировать переменные по типу.
3. Различать наблюдательное исследование и эксперимент; выявлять мешающие факторы.
4. Вычислять меры центральной тенденции и дисперсии и обосновывать, когда каждая из них уместна.
5. Выбирать правильный график в зависимости от типа переменной.
6. Определять мешающий график и объяснять его ошибку.

Результат обучения CLO1. Обобщите и визуализируйте данные с помощью соответствующих описательных показателей и графиков (Блум: Примените).

Набор данных за сегодня.
central-asia-yield.csv — Урожайность пяти культур в Узбекистане, Казахстане, Кыргызстане, Таджикистане и Туркменистане, 1992–2018 гг. (135 строк, реальные данные).

Карта семестра: Где мы находимся



Мы здесь

Почему эта неделя важна. Описательная статистика — это алфавит на следующие 15 недель. Вы не сможете понять центральную предельную теорему или регрессию, не понимая среднего значения и стандартного отклонения.

Распространенная ошибка. Но будьте осторожны: описательная статистика описывает, а не делает выводы. «Среднее значение в этой выборке равно 4,6» $\neq$ «среднее значение в популяции равно 4,6». Это различие становится центральной темой на 7-й неделе.

**Что такое
информация?**

Анатомия таблицы данных

страна	год	пшеница	картофель	ячмень
Узбекистан	1992	1.662	8.51	1.410
Узбекистан	2018	4.126	24.42	1.703
Казахстан	2018	1.116	19.79	1.232
Таджикистан	2018	3.147	27.90	2.013

→Строка =


одна единица наблюдения
↓ Столбец = одна переменная

Определение Единица наблюдения — объект, о котором собирается информация. Здесь: состояние одной страны в одном году.

Переменная — характеристика, измеряемая в единицах наблюдения.

Наблюдение — все значения переменных для одной единицы (одной строки).

Вопрос аудитории: Если единицей наблюдения является «страна», сколько строк осталось в таблице и что означает столбец «пшеница»?



Распространенная ошибка. Ловушка. То, что переменная записана как число, не делает ее числом. Почтовый индекс 100 000 — это не число, а номинальная метка. Вычисление его среднего значения бессмысленно.

Определение. Почему это важно? Тип переменной определяет все последующие решения: какой индикатор, какой график, какой тест.

Тип переменной? Подходящий индикатор?

Результат теста студента (0-100)

Регион проживания студента


Количество автомобилей в
семье

Кредитный рейтинг (A, B, C,
D)

Время ожидания в очереди в банке

Номер телефона

Вопрос для аудитории. Последние два
пункта наиболее спорны. Почему?




Определение Параметр — числовая характеристика популяции (μ, σ, N). Обычно неизвестен.

Определение Статистика — число, вычисленное на основе выборки ($\bar{x}, s, n$). Результат получается разным для каждой выборки.

Распространенная ошибка: греческие буквы → популяция; латинские буквы → выборка. Это правило не меняется на протяжении всего курса.

Методология исследования

Откуда берутся данные?



Наши данные. Данные о производительности являются наблюдательными. Никто случайным образом не присваивал странам статус «реформы» или «без реформ».

Распространенная ошибка. Поэтому вывод о том, что «реформы повысили производительность», не следует из этих данных. Мы вернемся к этому вопросу более подробно на 13-й неделе.

Простая случайная Стратифицированная Кластерная Систематическая



Идея метода Когда предпочтительнее

Простая случайная Каждая единица выбирается с равной вероятностью Когда список полный
Стратифицированная Множество делится на однородные группы, и из каждой выбирается одна Когда разница между группами велика

Кластерная Целые группы выбираются случайным образом Когда географически рассредоточены
Систематическая Каждая k-я единица выбирается Когда существует ранжированный порядок

Определение Смещение выборки — систематическое искажение выборки населения.


Три классических типа:

- ▶ Смещение по удобству — опрашивается тот, кто находится близко.
- ▶ Смещение из-за неответа — те, кто ответил на опрос, систематически отличаются от тех, кто не ответил.
- ▶ Смещение из-за выживших — показаны только «выжившие».

Распространенная ошибка Смещение большой выборки не исправляет. В опросе Literary Digest 1936 года, в котором приняли участие 2,4 миллиона респондентов, было неверно предсказано исход выборов в США. Причина: список был составлен на основе данных о владельцах телефонов и автомобилей.

Увеличение n уменьшает случайную ошибку, а не систематическую погрешность. Это различие постоянно встречается в ходе курса.

Фактор, искажающий результаты. Почему данные наблюдений не доказывают причинно-следственную связь.



Определение. Фактор, искажающий результаты — третья переменная, которая влияет как на □, так и на □. Она создает не причинно-следственную связь между □ и □.

Вопрос аудитории. Какие другие факторы влияют как на реформу, так и на урожайность? Назовите как минимум три.

Случайное распределение «разъединяет» □ и □ — в среднем □ одинаков в обеих группах.

Четыре обязательства при сборе данных:

1. Информированное согласие — респондент должен знать, зачем собираются данные.
2. Конфиденциальность — персональные данные защищены.
3. Анонимизация — удаления имени недостаточно; несколько переменных вместе могут раскрыть личность.
4. Неиспользование за пределами предполагаемой цели — информация, собранная для одной цели, не передается для другой.

Распространенная ошибка: повторная идентификация. Почтового индекса + даты рождения + пола может быть достаточно для однозначной идентификации большинства людей — даже если имя не совпадает.

В рамках семестрового проекта вы должны открыто сообщить об источнике данных, методе их получения и вопросе конфиденциальности. Это оценивается.

Измерения центра

Определение Среднее значение

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Медиана — среднее значение в отсортированном множестве.

Мода — наиболее часто встречающееся значение.

Какое значение и когда?

Среднее значение Симметричное распределение; необходимо для дальнейших вычислений Медиана Асимметричное распределение; есть выбросы Мода Категориальная переменная; «наиболее типичное» значение

Распространенная ошибка Для категориальной переменной имеет значение только мода. Не существует понятия «средний размах».

Важное свойство. $\sum (x_i - \bar{x}) = 0$ — сумма отклонений от среднего значения всегда равна нулю. Вот почему существует определение дисперсии: отклонения нельзя просто сложить.

Давайте вручную рассчитаем урожайность пшеницы в Узбекистане (т/га), 2010–2018 гг.

Год	
2010	4,600
2011	4,556
2012	4,710
2013	4,739
2014	4,782
2015	4,818
2016	4,802
2017	4,316
2018	4,126
$n = 9 \quad \sum x_i = 41,449$	

1. Среднее значение

$$\bar{x} = \frac{41449}{9} = 4,605 \text{ т/га}$$

2. Медиана — сортировка:

4,126 4,316 4,556 4,600 4,710 4,739 4,782 4,802 4,818

$n = 9$ нечетное $\Rightarrow$ 5-е значение: Медиана = 4,710

3. Сравнение

$$\bar{x} = 4,605 < \text{Медиана} = 4,710$$

Распространенная ошибка: среднее значение меньше медианы — распределение смещено влево. Причина: Низкие значения в 2017–2018 годах снижают среднее значение.

Почему медиана стабильна? Давайте попробуем изменить одно значение.

Изменим значение за 2015 год с 4,818 на 12,0 (например, единица измерения была введена неправильно):

С исходной ошибкой

Среднее 4,605 5,403
Медиана 4,710 4,710


Изменение — $\Delta \bar{x} = +0,798$
 $\Delta Med = 0,000$

Определение. Устойчивость — низкая чувствительность индикатора к выбросам.

Медиана стабильна, среднее значение нестабильно.

Вопрос аудитории: Если значение 12,0 не является ошибкой, а реальным значением, какой показатель вы бы указали? Почему?

Практическое правило. Рассчитайте оба значения. Сама разница является информацией о форме распределения.



n 2467 Среднее
значение 35,8 млн
долл. США Медиана
22,0 млн долл. США
s 37,4 млн долл.
США K1 10,0 K3 50,0

Это типичная форма распределения доходов, богатства, численности населения города и размера фирмы.

Вопрос аудитории: В компании 9 сотрудников зарабатывают 5 миллионов сумов в месяц, а директор — 100 миллионов сумов.

(а) Какова средняя зарплата? (б) Какова медианная зарплата? (в) Какое число используется в рекламе компании? Какое число должен знать соискатель работы?

Вопрос аудитории: «средняя зарплата»

Вопрос аудитории: В компании 9 сотрудников зарабатывают 5 миллионов сумов в месяц, а директор — 100 миллионов сумов.

(а) Какова средняя зарплата? (б) Какова медианная зарплата? (в) Какое число используется в рекламе компании? Какое число должен знать соискатель работы?


Решение

$$\bar{x} = \frac{9 \times 5 + 100}{10} = \frac{145}{10} = 14,5 \text{ МИЛЛИОНОВ}$$

Медиана: В ранжированном списке 5-е и 6-е значения равны 5 $\Rightarrow$ Медиана = 5 миллионов.

Распространенное заблуждение заключается в том, что 9 из 10 сотрудников зарабатывают меньше «среднего». Статистика не является ложной — но выбранные статистические данные вводят в заблуждение.

Меры по рассеиванию



В обоих случаях $\bar{x} = 5$

Три меры дисперсии

Определение: Диапазон = $\max - \min$ — простой, но основан всего на двух значениях.

Межквартильный диапазон IQR = $Q_3 - Q_1$ — стабильный.

Стандартное отклонение

$$s = \sqrt{\frac{1}{n-1} \sum (x_i - \bar{x})^2}$$

Вопрос аудитории: В двух провинциях одинаковый средний доход, но $\bar{x}$ различается. В какой провинции неравенство выше? Какое число важнее для политики?

Дисперсия: почему в квадрате, почему $n-1$?

Шаг 1 — отклонения

$$d_i = x_i - \bar{x}, \quad \sum_{i=1}^n d_i = 0$$

Следовательно, их нельзя просто сложить.

Шаг 2 — возведение в квадрат

$$\sum d_i^2 \geq 0$$

Возведение в квадрат: (i) теряет знак, (ii) усиливает большие отклонения, (iii) дифференцируема — необходима для следующей теории.

Шаг 3 — усреднение

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Теорема Почему $n-1$? Отклонения берутся от выборочного среднего, а не от среднего значения генеральной совокупности. Поскольку $\bar{x}$ вычисляется на основе данных, отклонения «слишком малы».

Условие $\sum d_i = 0$ теряет одну степень свободы: если известны $n-1$ отклонения, последнее определяется автоматически.

Деление на $n-1$ делает s^2 несдвинутой оценкой для σ^2 — мы докажем это на 9-й неделе.

Давайте рассчитаем вручную: $\sum x^2$
и $\sum$ Эти 9 значений, $\sum = 4,605$

Год	$\sum x = \sum$	$\sum x^2$	$\sum$
2010	4,600	-0,005	0,0000
2011	4,556	-0,049	0,0024
2012	4,710	+0,105	0,0110
2013	4,739	+0,134	0,0179
2014	4,782	+0,177	0,0313
2015	4,818	+0,213	0,0452
2016	4,802	+0,197	0,0387
2017	4,316	-0,289	0,0836
2018	4,126	-0,479	0,2296
		$\approx 0,000$	0,4599

$$s^2 = \frac{0,4599}{9 - 1} = \frac{0,4599}{8} = 0,0575$$

$$s = \sqrt{0,0575} = 0,240 \text{ т/га}$$

Коэффициент вариации

$$CV = \frac{s}{\bar{x}} = \frac{0,240}{4,605} = 0,052 = 5,2\%$$

CV безразмерен — поэтому он полезен для сравнения переменных в разных единицах измерения.

Распространенная ошибка заключается в том, что $\sum x^2$ не равен нулю — это ошибка округления. Округляйте в конце вычислений.

Сравнение: какая страна «стабильна»?

Урожайность пшеницы, 1992-2018 гг., $n = 27$


Страна	Med	s	IQR	CV, %
--------	-----	---	-----	-------

Узбекистан	3,605	4,126	1,179	1,938	32,7	Таджикистан	1,991	1,987	0,853	1,805	42,8
Туркменистан	1,906	1,600	0,808	1,277	42,4	Кыргызстан	2,235	2,317	0,277	0,315	12,4
Казахстан	1,027	1,076	0,260	0,359	25,3						

Распространенная ошибка. Важное предупреждение. Казахстан имеет самый низкий урожай, но является крупнейшим экспортером пшеницы в регионе. Урожайность (т/га) $\neq$ общий урожай (тонны). Всегда проверяйте, что измеряет показатель.

**Форма
распространения**

Левосторонняя асимметрия Симметричная Правосторонняя асимметрия




Соотношение форм

Левосторонняя асимметрия $\bar{x} < \text{Med}$
Симметричная $\bar{x} \approx \text{Med}$
Правосторонняя асимметрия $\bar{x} > \text{Med}$

Распространенная ошибка. Это не правило, а тенденция. Существуют искусственные примеры, где $\bar{x} < \text{Med}$ имеет сильную асимметрию. Окончательный вывод о форме делается на основе графика.

Модальность. Бимодальное распределение часто указывает на то, что в данных смешаны две разные группы — проверьте это.

Пятиточечная сводка и диаграмма размаха



Правило для выбросов ($1,5 \times \text{IQR}$)

$$\square 1 - 1,5 \text{ IQR} = 4,556 - 0,339 = 4,217$$

$$\square 3 + 1,5 \text{ IQR} = 4,782 + 0,339 = 5,121$$

$4,126 < 4,217 \Rightarrow 2018$ — определено.

Распространенная ошибка: «Выброс» $\neq$ «ошибка». 2018 год был годом засухи — это реальное значение. Удаление этого значения приведет к искажению данных.

Правило — это утверждение о намерениях, а не суждение. Всегда спрашивайте «почему».


Визуализация

Какой график мне выбрать?



Основное правило. Тип графика определяется типом переменной, а не его красотой. Для двух категориальных переменных: столбчатая диаграмма с пропорциями или таблица частот (это приводит к критерию хи-квадрат на 11 неделе).

Гистограмма и ящичная диаграмма: что они показывают?



Узбекистан, 1992–2018 (n= 27)

Гистограмма показывает:


- ▶ форму (здесь: два пика)
- ▶ пробелы и кластеры
- ▶ все распределение

Ящичная диаграмма показывает:

- ▶ вывод по квинтилям
- ▶ выбросы
- ▶ сравнение групп

Распространенная ошибка:
Ящичная диаграмма скрывает два пика. Когда важна форма, важна гистограмма.

Вопрос: почему распределение имеет два пика?
Подсказка: это временной ряд.



Не начинается с 0 — разница в 6 раз больше

Кажется

2. Прямая ось



Те же данные — реальная разница невелика

Три классических приема:

1. Перекрышенная ось y — небольшая разница выглядит большой.

2. Неправильное агрегирование — объединение групп и вывод противоположного результата (парадокс Симпсона, неделя 13).

3. Две оси y — вы можете выбрать масштаб и установить любое желаемое «соотношение».

Распространенная ошибка. Этическое правило. На столбчатой диаграмме ось y всегда начинается с нуля. В линейном графике это не обязательно, но масштаб должен быть четко указан.

Краткое
содержание

Заблуждение Почему это неправильно

«Среднее значение — лучшая мера центральной тенденции». В асимметричном распределении среднее значение не представляет собой типичное значение. В выборке из 10 человек 9 человек набрали баллы ниже «среднего».

«Вы должны исключить выброс». Выброс — это следствие правила $1,5 \times \text{IQR}$, а не суждение. Засуха 2018 года — реальное событие.

«Большая выборка всегда лучше». Увеличение n уменьшает случайную ошибку, а не смещение. Literary Digest: 2,4 миллиона ответов и неверное предсказание.

«В числовом виде это означает, что это числовая переменная». Почтовый индекс и номер телефона — это номинальные обозначения. Их среднее значение бессмысленно.

« p велико — значит, данные плохие». p — мера естественной изменчивости, а не оценка качества. Высокое значение p может быть значимым результатом (например, неравенство).

« r , по-видимому, является корреляцией — значит, причина найдена». В наблюдательных данных всегда возможно смешение факторов. Неделя 13 посвящена именно этому.

1. Тип переменной определяет все последующие решения: индикатор, график, тест.

2. Способ сбора данных определяет, какие выводы можно из них сделать. Наблюдение → ассоциация; эксперимент → причинно-следственная связь.

3. Укажите центр, дисперсию и форму вместе. Среднее значение само по себе является неполным отчетом.

4. Для данных с асимметричным распределением предпочтительнее медиана и межквартильный размах; для симметричных данных — $\bar{x}$ и s .

5. Выберите график, исходя из типа переменной; не пересекайте ось y .

6. Для каждого индикатора задайте себе вопрос: что он на самом деле измеряет? Урожайность $\neq$ урожайность.

На следующей неделе, Неделя 2 — Основы теории вероятностей. Мы переходим от описательной статистики к языку неопределенности: элементарное пространство событий, аксиомы, правила сложения и умножения, независимость.

Содержание задания Срок сдачи

Обязательное чтение: IMS 2e, главы 1-2 (Привет, данные; Дизайн исследования); Newbold, главы 1-2 до лекции 2

Лабораторная работа W01 — R или Python (оба языка предоставлены) В лаборатории Домашнее задание W01 — 6 задач, 40 баллов Неделя 2, понедельник Задания 1 MT1 предоставлены Сдать: Проект недели 2 Этап 1 Проверенный исследовательский вопрос (150 слов) Неделя 2, пятница Задание по SI Проанализируйте SI описательно и найдите в нем ошибку Неделя 2, пятница

Распространенные ошибки Академическая честность. Домашнее задание — индивидуальное. Если вы используете искусственный интеллект, укажите в конце: какой инструмент, какой запрос, как вы проверили результат. Разглашение информации не наказуемо; сокрытие информации наказуемо.

1. Четинкая-Рундел, М. и Хардин, Дж. (2024). Введение в современную статистику, 2-е изд. OpenIntro. Главы 1-2. openintro-ims2.netlify.app
2. Ньюболд, П., Карлсон, У. и Торн, Б. Статистика для бизнеса и экономики. Pearson. Главы 1-2.
3. МакКлейв, Дж. Т. и Синчич, Т. (2018). Статистика, 13-е изд. Pearson. Главы 1-2.
4. Хьюманн, К., Шомакер, М. и Шалабх (2016). Введение в статистику и анализ данных. Springer. Главы 2-3.
5. Анскомб, Ф. Дж. (1973). Графики в статистическом анализе. Американский статистик, 27(1), 17-21.
6. Розенбаум, П. Р. (2017). Наблюдение и эксперимент. Издательство Гарвардского университета. Глава 1.
7. Ссылка: Ричи, Х., Росадо, П. и Розер, М. Сельскохозяйственное производство: урожайность. Наш мир в данных (основной источник: FAOSTAT). ourworldindata.org
8. Интерактивный курс: Теория зрения, Университет Брауна — seeing-theory.brown.edu