

Ташкентский международный университет · Факультет экономики
Условная вероятность и теорема Байеса

Неделя 3 · Лекции 1 и 2

Ташкентский международный университет · Экономический
факультет

2025/2026 учебный
год



На прошлой неделе мы вычислили два числа в реальных данных:

$$P(\square | \text{Ужас}) = \frac{154}{208} = 0,7404$$

$$P(\text{Ужас} | \square) = \frac{154}{1115} = 0,1384$$

Картинка та же. Знаменатель другой. Результат отличается более чем в пять раз.

Распространенная ошибка. Но в большинстве случаев у нас есть только одно направление.

Врач знает $P(\text{положительный} | \text{больной})$ — он проверил тест на пациентах.

А пациенту нужно $P(\text{больной} | \text{положительный})$.

Вопрос этой недели: Как вычислить другое значение, если известно одно направление?

Цели обучения на 3-ю неделю

К концу этой недели вы сможете:

1. Проиллюстрировать условную вероятность с помощью древовидной диаграммы и применить правило умножения в виде цепочки.
2. Определить понятие деления и применить полную формулу вероятности.
3. Вывести и применить теорему Байеса.
4. Объяснить влияние базовой ставки и определить ошибку базовой ставки.
5. Решить задачи диагностического тестирования и кредитного скоринга.
6. Распознать и исправить ошибку обвинения.

Результат обучения CLO2. Примените правила теории вероятностей, включая условную вероятность и теорему Байеса, к экономическим задачам (Блум: Применение и анализ).

Сегодняшняя сильная сторона. Мы проверим теорему Байеса на реальных данных: ответ, полученный по формуле, должен быть точно таким же, как ответ, полученный прямым подсчетом. Если это не так, мы допустили ошибку.

Древовидная диаграмма и правило умножения


Условная вероятность: сужение пространства

Определение

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, P(B) > 0$$

Новость о том, что произошло событие A , сужает все пространство до B . Теперь B — это новый «мир».


Распространенная ошибка. При вычислении условной вероятности меняется знаменатель. Студенты часто меняют картину и забывают о знаменателе.



$$P(R|Ужас) = \frac{154}{\text{знаменатель } 208} = R$$

$$P(Ужас | R) = \frac{154}{\text{знаменатель } 1113} = R$$

Древовидная диаграмма: Язык условной вероятности



Правила дерева. Умножайте вдоль ветви; складывайте вдоль ветвей. Сумма вероятностей от каждого узла равна 1.


Вопрос аудитории: $0.0627 + 0.3901 = 0.4528$. Какое это число? Почему получилось именно так?

Полная формула вероятности

Определение События $\omega_1, \omega_2, \dots, \omega_k$ называются разбиением пространства Ω , если:

►они не пересекаются парами: $\omega_i \cap \omega_j = \emptyset$ ►объединение охватывает все пространство: $\bigcup \omega_i = \Omega$

То есть каждый исход попадает ровно в одно пространство ω_i .



Ω делится на части: $\Omega = \bigcup (\omega_i \cap \Omega)$

Полная формула вероятности

$$P(\Omega) = \sum_{i=1}^k P(\omega_i | \Omega) P(\Omega)$$

Доказательство. $\omega_i \cap \omega_j$ не пересекаются попарно, их объединение равно Ω . Согласно аксиоме А3, вероятности складываются; мы применяем правило умножения к каждому члену. $\square$

В реальных данных: жанры образуют разделение

Жанр	$\sum P(\text{жанр})$	$\sum (P(\text{жанр}) \cdot P(\text{жанр} \text{жанр}))$	$P(\text{жанр} \text{жанр})$	$P(\text{жанр} \text{жанр})$	$P(\text{жанр})$
Боевик	358	0.1456	174	0.4860	0.0708
Приключения	363	0.1477	14	0.0386	0.0057
Комедия	600	0.2441	292	0.4867	0.1188
Драма	929	0.3779	479	0.5156	0.1949
Ужас	208	0.0846	154	0.7404	0.0627
Всего	2458	1.0000	1	113	0.4528

Проверка. Прямой расчет:

$$P(\square) = \frac{1113}{2458} = 0,452807$$

Полная формула вероятности: 0.452807. ✓

Разница = 0 — это тоже не ошибка округления.

Распространенная ошибка. Проверьте условие делимости. $358 + 363 + 600 + 929 + 208 = 2458$. Если сумма не совпадает — это не делитель, формула не работает. Это самая распространенная ошибка.

Теорема Байеса

Теорема Байеса: триномиальная индукция

Шаг 1. Определение условной вероятности:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Шаг 2. Правило умножения изображений:

$$P(A \cap B) = P(A|B) P(B)$$


Шаг 3. Формула для полной вероятности в знаменателе:

$$P(A) = \sum_i P(A|B_i) P(B_i)$$

Теорема Байеса

$$P(B_i|A) = \frac{P(A|B_i) P(B_i)}{\sum_j P(A|B_j) P(B_j)}$$

Теорема Байеса не является новым правилом. Это комбинация определения, правила умножения и формулы полной вероятности. Ее не нужно запоминать; ее нужно вывести.



Априорная уверенность до появления доказательств. Часто базовая вероятность представляет собой долю популяции. Уверенность: насколько вероятно увидеть эти доказательства, если θ истинно. Апостериорная уверенность после рассмотрения доказательств — это то число, которое нам нужно.

Байесовский классификатор = обновление уверенности. Априорная вероятность × сила доказательств = апостериорная вероятность.

Проверка байесовского классификатора на реальных данных. Фильм имеет рейтинг R. Какова вероятность того, что это фильм ужасов?

По Байесу:

$$\begin{aligned} P(\square|\square) &= P(\square|\square) P(\square) \\ &= 0,7404 \times 0,0846 \\ &= \frac{0,0627}{0,4528} = \mathbf{0,1384} \end{aligned}$$

Прямым
вычислением:

$$P(\square|\square) = \frac{154}{1113} = \mathbf{0,1384} \quad \checkmark$$

Почему это важно? Здесь было два способа — поэтому мы смогли проверить формулу.

В реальных задачах прямой расчет невозможен: нет списка пациентов. Поэтому мы доверяем формуле — но сначала проверили ее в проверенном месте.

Общая ошибка составляет $0,7404 \rightarrow 0,1384$. Не два одинаковых фильма — одни и те же 154 фильма, два разных знаменателя.

Как доказательства влияют на уверенность? Для трех жанров: предыдущий → следующий



Жанр предыдущий следующий коэффициент

Ужасы 0.0846 0.1384 $\times 1.64$ Приключения
0.1477 0.0126 $\times 0.09$ Драма 0.3779 0.4304
 $\times 1.14$

Доказательства работают в обе стороны. Рейтинг R увеличивает вероятность того, что это фильм ужасов, но уменьшает вероятность того, что это приключенческий фильм, в 12 раз. Приключенческие фильмы почти никогда не получают рейтинг R.

Базовая ставка

Чувствительность теста: $P(+ | \square) = 0,99$.

Специфичность теста: $P(- | \square\square) = 0,95$,
следовательно, $P(+ | \square\square) = 0,05$.


Вопрос аудитории: Ваш тест дал положительный результат. Какова вероятность того, что у вас есть это заболевание? Запишите свой ответ.

Распространенная ошибка: Что говорит большинство людей? Наиболее распространенные ответы в опросах медицинских работников составляют 95% или 99%.

То есть люди используют $P(+ | \square)$ вместо $P(\square | +)$. Это логическая ошибка в этом направлении.

Правильный ответ находится на следующих двух слайдах.

Решение с использованием частот: 10 000 человек



$$P(\square|+) = \frac{9,9}{509,4} = 0,0194$$

Распространенная ошибка: что 98% тех, кто получил положительный результат, здоровы: здоровых людей так много, что 5% из них составляют больше, чем все больные.

Тот же результат с формулой Байеса

Знаменатель — полная формула вероятности:

$$\begin{aligned} P(+) &= P(+ | \square) P(\square) + P(+ | \square\square) P(\square\square) \\ &= 0,99(0,001) + 0,05(0,999) = 0,05094 \end{aligned}$$


$$\begin{aligned} P(\square | +) &= \frac{0,99 \times 0,001}{0,05094} = \frac{0,00099}{0,05094} = \mathbf{0,0194} \end{aligned}$$

Для отрицательного результата: $P(\square\square | -) = 0,999989$.

Два способа — один ответ. Решение с использованием частот более интуитивно понятно; решение с помощью формулы более универсально. На экзамене вы должны знать оба способа.

Практический совет. Если вы запутались в задаче Байеса, нарисуйте таблицу из 10 000 человек. Этот метод почти никогда не позволяет жульничать.

Все зависит от базовой частоты



$P(+)$	$P(+ +)$
0,001	1,94%
0,01	16,67%
0,05	51,03%
0,10	68,75%

Общая ошибка. Тест не изменился. Чувствительность и специфичность остались прежними. Изменилась только базовая частота — и результат увеличился с 1,94% до 68,75%.

Вот почему массовый скрининг является избирательным. Тестирование всего населения на редкое заболевание привело бы к потоку ложноположительных результатов.

Ошибка базовой частоты

Определение. Ошибка базовой частоты — сосредоточение внимания на ясном и наглядном доказательстве и игнорирование общей частоты события (базовой частоты).

Распространенная ошибка. Почему это естественная ошибка? Данные нам числа (0,99, 0,95) ясны и очевидны. Базовая частота (0,001) кажется «фоновой информацией». На самом деле, это самое важное число.

Контрмера: частотная форма. Вместо « $P(+ | \square\square) = 0,05$ » скажите: «499 из 10 000 здоровых людей получили положительный результат теста».

Исследования показывают, что люди значительно лучше справляются с решением одной и той же задачи, когда она представлена в частотной форме.

Вопрос аудитории: Где проявляется ошибка базовой вероятности? Назовите как минимум две области.

**Экономическое
применение**

Гипотетическая модель банка. Уровень неплатежей в портфеле составляет $P(\square) = 0,03$.

Модель выявляет 90% неплательщиков: $P(\text{flag} | \square) = 0,90$.

Она ошибочно выявляет 10% добросовестных клиентов: $P(\text{flag} | \square\square) = 0,10$.

$$P(\text{флаг}) = 0,90(0,03) + 0,10(0,97) = 0,1240$$

$$P(\square | \text{флаг}) = \frac{0,027}{0,1240} = 0,2177$$

Распространенная ошибка: 78,2% заявок с флагом фактически не приводят к дефолту. Хотя модель рекламируется как «90% точная».

Другая сторона:

$$P(\square | \text{нет флага}) = 0,003 \quad \quad \quad \frac{0,003}{0,876} = 0,0034$$

Только 0,34% заявок без флага приводят к дефолту — модель очень надежна в отклонении заявок.

Какое решение требует это число?

Вопрос аудитории: Из 100 отмеченных заявок 22 являются дефолтными, а 78 — добросовестными клиентами.

(а) Что теряет банк, если отклоняет все отмеченные заявки?

(б) Какая дополнительная информация улучшит качество решения?

(в) Справедливо ли это по отношению к этим 78 клиентам?

Статистика не принимает решений. Она подсчитывает только последствия. Решение об отказе требует сравнения затрат и выгод — это будет обсуждаться на 10-й неделе, когда мы будем обсуждать ошибки первого и второго типа.

Распространенная этическая ошибка. Если базовая ставка различается в разных группах, одна и та же модель будет по-разному влиять на разные группы. Это вопрос алгоритмической справедливости.

Монти Холл

Задача Монти Холла


Три двери: одна с машиной, две с козой.

1. Вы выбираете одну дверь.

2. Ведущий открывает две другие двери с козой (он знает).

3. Вы меняете выбор?

Вопрос от аудитории: Стоит ли менять выбор? Есть ли разница?



Вероятность выигрыша при переключении = $2/3$.
Моделирование (100 000 игр): остаться 0,3326,
переключиться 0,6674.

Распространенная ошибка. Ключевое условие: инициатор знает и всегда раскрывает козу. Если она открывается случайно — ответ $1/2$.

Краткое
содержание

Распространенная ошибка. Ошибка прокурора. В суде: «Вероятность случайного совпадения доказательств составляет один на миллион. Следовательно, вероятность невинности обвиняемого составляет один на миллион».

Это приравнивает два совершенно разных числа:

$$P(\text{доказательства} \mid \text{невинность}) \neq P(\text{невинность} \mid \text{доказательства})$$

Байес показывает, что последнее также зависит от базовой вероятности — то есть от размера пула подозреваемых.

С числами. Население города составляет 2 миллиона человек; случайное совпадение доказательств наблюдается у одного человека из миллиона.

Виновный точно совпадает: 1 человек.
Ожидаемое количество совпадений из оставшихся 2 000 000 — 1 человек: ≈ 2 человека.
Всего совпадений: ≈ 3 .

$$P(\text{виновен} \mid \text{соответствие}) \approx \frac{1}{3} = 0,33$$

Не «один на миллион» — один на три.

Распространенная ошибка. Эта ошибка приводила к неправомерным обвинительным приговорам в реальных судебных делах. Цена статистической ошибки — человеческая судьба.

Заблуждение Почему это неправильно

«Тест точен на 99% — поэтому, если я получу положительный результат, я на 99% болен». Это читается как $P(+|\square)$ как $P(\square|+)$. Если базовая частота равна 0,001, ответ — 1,94%.

«Базовая частота — это просто фоновая информация». Напротив, это наиболее впечатляющее число. Если распространенность меняется с 0,001 до 0,10, ответ меняется с 1,94% до 68,75%.

«Формула абсолютной вероятности может быть применена к любому количеству событий». Только к делению. Проверьте сумму: $358 + 363 + 600 + 929 + 208 = 2458$.

«Теорема Байеса — это уникальная формула, которую стоит запомнить». Она представляет собой комбинацию определения + правила умножения + формулы полной вероятности. Выведите ее.

«Следующая вероятность всегда больше предыдущей». Для Adventure $0,1477 \rightarrow 0,0126$: доказательство уменьшило уверенность в 12 раз.

«В Монти-холле осталось две двери — так что шансы 50/50». Стартер открывает их не случайным образом. Его знания добавляют информацию; подстановка дает $2/3$.

«Модель точна на 90% — значит, 90% флагов верны». $P(\square|\text{flag}) = 0,2177$. 78,2% флагов являются ложными срабатываниями.

1. Диаграмма дерева — наиболее надежный инструмент для решения задач на условную вероятность: умножайте вдоль ветви, складывайте вдоль ветви.

2. Полная формула вероятности применима только к делению — всегда проверяйте сумму.

3. Теорема Байеса — не новое правило; это комбинация трех хорошо известных правил.

4. Последующая вероятность зависит как от базовой вероятности, так и от силы доказательств. Опускать любой из этих факторов — ошибка.

5. Если вы запутались, составьте частотную таблицу для 10 000 человек.

6. Путаница между $P(A|B)$ и $P(B|A)$ может нанести реальный вред в медицинских, юридических и кредитных ситуациях.

На следующей неделе, Неделя 4 — Случайные величины и дискретные распределения. Мы переходим от событий к числам: функция вероятностной массы, математическое ожидание, дисперсия; распределения Бернулли, биномиальное и Пуассона.

Содержание задания Срок сдачи

КОНТРОЛЬНАЯ РАБОТА 1 Оценивается. Недели 1–3, 45 минут на этой неделе. Обязательное чтение: Ньюболд, глава 3; МакКлейв, глава 3; Хьюманн, глава 6. Перед лекцией 1. Лабораторная работа W03-lab — Байесовский классификатор, деревья, Монти Холл. В лаборатории. Домашнее задание W03-homework — 6 задач, 40 баллов. Неделя 4, понедельник. Набор задач 2. MT2 сдается на этой неделе. Этап проекта 3. Идентификация переменных. Неделя 4, пятница. Задание по СИ. Найдите байесовские ошибки СИ. Неделя 4, пятница.

Распространенная ошибка. Контрольная работа 1. Запоминания формулы недостаточно: определите пространство, определите события, проверьте деление, затем произведите вычисления.

1. Ньюболд, П., Карлсон, У. и Торн, Б. Статистика для бизнеса и экономики. Pearson. Глава 3 — Условная вероятность, полная формула вероятности, теорема Байеса.

2. МакКлейв, Дж. Т. и Синчич, Т. (2018). Статистика, 13-е изд. Pearson. Глава 3.

3. Хьюманн, К., Шомакер, М. и Шалабх (2016). Введение в статистику и анализ данных. Springer. Глава 6.

4. Четинкая-Рундель, М. и Хардин, Дж. (2024). Введение в современную статистику, 2-е изд. OpenIntro — Условная вероятность и таблицы сопряженности.

5. Гигеренцер, Г. и Хоффрейдж, У. (1995). Как улучшить байесовское рассуждение без инструкций: частотные форматы. *Psychological Review*, 102(4), 684–704.

6. Канеман, Д. и Тверски, А. (1973). О психологии прогнозирования. *Psychological Review*, 80(4), 237–251 — ошибка базовой частоты.

7. Томпсон, У. К. и Шуман, Э. Л. (1987). Интерпретация статистических данных в уголовных процессах. *Law and Human Behavior*, 11(3), 167–187 — ошибка обвинения.

8. Интерактивный курс: Теория зрения, Брауновский университет, кафедра теоремы Байеса — seeing-theory.brown.edu