

Ташкентский международный университет · Факультет экономики
Случайные величины и дискретные распределения

Неделя 4 · Лекции 1 и 2

Ташкентский международный университет · Факультет
экономики

2025/2026 учебный
год



Недели 1–3. Мы работали с событиями: «Драма», «Рейтинг R», «Положительный тест». Это множества.

Множества можно складывать, умножать и обуславливать. Но их нельзя усреднять.

Распространенная ошибка. Нам нужны другие вопросы.

«Сколько из 10 фильмов имеют рейтинг R?»
«Сколько заявок обрабатывает банк за час?» «Сколько выплачивает страховая компания?»

Ответ на эти вопросы — число, а не событие.



На этой неделе язык теории вероятностей обращается к арифметике. Центральная предельная теорема на 7-й неделе опирается на этот аппарат.

Цели обучения на 4-ю неделю

К концу этой недели вы сможете:

1. Определить случайную величину как функцию и отличить её от события.
2. Построить функцию вероятностной массы и функцию распределения и объяснить взаимосвязь между ними.
3. Вывести и вычислить математическое ожидание и дисперсию из определения.
4. Применить свойства линейности E и Var .
5. Распознать распределения Бернулли, биномиальное и Пуассона и проверить их условия.
6. Оценить пригодность модели перед её выбором.

Результат обучения CLO3. Работа со случайными величинами и стандартными распределениями, а также вычисление математического ожидания и дисперсии (Блум: Применение).

Требования к математике. На этой неделе вы должны свободно работать со знаком суммы $\sum$. Сумма геометрических прогрессий также представляет собой сложную задачу (MATH102).


Случайная сумма

Определение Случайная величина — это функция, которая отображает набор элементарных событий в действительные числа:

$$X : S \rightarrow \mathbb{R}$$

Каждому исходу присваивается одно число.

Распространенное заблуждение Несмотря на свое название, случайная величина не является ни случайной величиной, ни величиной — это функция. Случайность заключается в исходе, а не в функции.



Мы выбираем два фильма. X — количество фильмов с рейтингом R среди них. $\{\square\square, \square\square\}$ оба отображаются на $\square = 1$.

Определение функции вероятностного распределения

$$p(x) = P(X=x)$$

Условия: $p(x) \geq 0$ и $\sum p(x) = 1$.

Кумулятивная функция распределения


$$P(x) = P(X \leq x) = \sum_{t \leq x} p(t)$$

Свойства P :

► неубывающая ► $P(-\infty) = 0$, $P(+\infty) = 1$ ► ступенчатый; высота прыжка = $p(x)$

Распространенная ошибка заключается в том, что $P(X < x)$ и $P(X \leq x)$ не одинаковы в дискретных случаях. Разница равна точно $p(x)$. В непрерывном случае (неделя 5) разница исчезает.

Случайная величина из реальных данных 2 Мы случайным образом выбираем 10 фильмов из 458



$\square$ = Количество фильмов с рейтингом R из 10 выбранных фильмов.

$$P(R) = \frac{1113}{2458}$$

$= 0,4528$ — это знакомо из 2-й недели.

x	$p(x)$	$F(x)$
2	0,0742	0,0965
3	0,1636	0,2601
4	0,2370	0,4971
5	0,2353	0,7324
6	0,1623	0,8947

Наиболее вероятный исход — $\square = 4$, но $E[\square] = 4,53$. Мода и математическое ожидание не совпадают.

Математическое ожидание и дисперсия

Определение математического ожидания

$$E[\square] = \sum_x x p(x)$$

Это средневзвешенное значение.

Распространенная ошибка заключается в том, что $E[\square]$ не является «математическим ожиданием». В нашем примере $E[\square] = 4,53$, но $\square$ никогда не равен 4,53 — это целое число.

Правильная интерпретация: если мы повторим эксперимент много раз, среднее значение результатов будет стремиться к 4,53 (закон больших чисел).

Ручной расчет. $\square$: 0, 1, 2, 3; p : 0,10; 0,35; 0,40; 0,15.

$$E[\square] = 0(0,10) + 1(0,35) + 2(0,40) + 3(0,15)$$

$$= 0 + 0,35 + 0,80 + 0,45 = 1,60$$

Линейность

$$E[\square + \square] = \square E[\square] + \square$$

$$\text{В примере: } E[3\square + 2] = 3(1,60) + 2 = 6,80.$$

Дисперсия: от определения к формуле расчета

Определение. Среднеквадратичное отклонение от среднего значения:

$$\text{Var}(X) = E[(X - \mu)^2] = \sum_x (x - \mu)^2 p(x)$$

Выводим:

$$\begin{aligned}\text{Var}(X) &= E[X^2 - 2\mu X + \mu^2] \\ &= E[X^2] - 2\mu E[X] + \mu^2 \\ &= E[X^2] - 2\mu^2 + \mu^2 \\ &= E[X^2] - (\mu)^2\end{aligned}$$

В том же примере.

$$E[X^2] = 0 + 0.35 + 1.60 + 1.35 = 3.30$$

$$\text{Var}(X) = 3.30 - (1.60)^2 = 3.30 - 2.56 = 0.74$$

$$\text{SD}(X) = \sqrt{0.74} = 0.86$$

Даже если мы рассчитаем по определению, получим 0.74. ✓

Дисперсионные свойства

$$\text{Var}(aX + b) = a^2 \text{Var}(X)$$

a обращается в нуль: сдвиг не изменяет дисперсию. В примере:
 $\text{Var}(3X + 2) = 9(0.74) = 6.66$.


Бернулли и биномиальное распределение

Определение распределения Бернулли: $X \sim \text{Bern}(p)$ принимает только значения 0 или 1.

$$p(1) = p, \quad p(0) = 1 - p$$

$$E[X] = p, \quad \text{Var}(X) = p(1 - p)$$

Доказательство. $E[X] = 0(1 - p) + 1(p) = p$. $E[X^2] = 0^2(1 - p) + 1^2(p) = p$, следовательно, $\text{Var} = p - p^2 = p(1 - p)$. $\square$



Дисперсия максимальна при $p = 0,5$

Неопределенность максимальна при $p = 0,5$; Поскольку результат почти наверняка достигается при $p \rightarrow 0$ или $p \rightarrow 1$, дисперсия стремится к нулю.

Биномиальные условия — BINS
B — два исхода (успех / неудача)
I — испытания независимы
N — количество испытаний не
предопределено
S — вероятность успеха фиксирована

Теорема

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

$$E(X) = np, \text{Var}(X) = np(1-p)$$

Откуда взялась формула? Вероятность ровно одной успешной последовательности в $\binom{n}{k}$ равна $\binom{n}{k} p^k (1-p)^{n-k}$ (независимая).

Число таких последовательностей ($\binom{n}{k}$) — это комбинация на 2-й неделе.

Поскольку они не совпадают, вероятности складываются.

Распространенная ошибка

($\binom{n}{k}$) — Комбинаторика со 2-й недели. Если вы научились считать две недели назад, вам не нужно запоминать биномиальную формулу.

Проверяем биномиальное распределение на реальных данных

Теоретически $X \sim \text{Bin}(10; 0.4528)$:

$$E[X] = np = 10(0.4528) = 4.5281$$

$$\text{Var}(X) = np(1 - p) = 2.4777$$

Также вычисляем по сумме:

$$E[X] = \sum np^k(1-p)^{n-k} = 4.5281 \checkmark$$

$$E[X^2] = 22.9812$$

$$\text{Var} = 22.9812 - 4.5281^2 = 2.4777 \quad \checkmark$$

Моделирование (200 000 выборок, реальные без замены):

$$\bar{x} = 4,5335 \quad s^2 = 2,4718$$

Очень близко к теоретическим значениям.

Распространенная ошибка. Но мы нарушили условие. При выборке без замены тесты не являются независимыми.

$\bar{p} - 1 = 0,9963$ — всего 0,37%. Если $p < 0,05$, биномиальное распределение дает хорошее приближение.

Распределение Пуассона

Определение распределения Пуассона: $X \sim \text{Pois}(\lambda)$ — количество событий в заданном интервале.

$$P(X = x) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x = 0, 1, 2, \dots$$

$$E[X] = \lambda, \text{Var}(X) = \lambda$$

Условия распределения Пуассона: События независимы; средняя частота не изменяется; никакие два события не происходят одновременно.

Общая ошибка Примечание:
 $E[X] = \text{Var}(X) = \lambda$.

Это проверяемое условие. Если отношение $\frac{\text{Var}(X)}{E(X)}$ в данных далеко от 1, распределение Пуассона неприменимо.

Типичные области применения: количество клиентов, посещающих отделение банка, страховые случаи, производственные дефекты, запросы на веб-сайте.

Один набор данных, два подсчета — один подходит, другой нет

НЕ подходит: дистрибьюторы $\square$ = количество фильмов, выпущенных одним дистрибьютором (168).

$$\bar{x} = 14,51 \quad s^2 = 1672,79 \quad \frac{s^2}{\bar{x}} = \mathbf{115,3}$$

Должно быть 1. Некоторые студии выпускают сотни фильмов, некоторые всего один — темпы не постоянны.

Подходит: фильмы ужасов за год

$\square$ = количество фильмов ужасов, выпущенных за год (2000–2018).

$$\bar{x} = 10,95 \quad s^2 = 10,39 \quad \frac{s^2}{\bar{x}} = \mathbf{0,949}$$

Очень близко к 1 — модель Пуассона является разумной.

Вопрос от аудитории: Оба являются «подсчетами» и взяты из одного и того же набора данных. Почему один следует модели Пуассона, а другой нет?

Урок: Распределение определяется условиями процесса, а не типом данных. Проверьте условия, прежде чем выбирать модель.

Предел Пуассона — биномиальный предел

n большой, p малый, $np = \lambda$ константа:

$$\text{Bin}(n, p/n) \rightarrow \text{Pois}(\lambda)$$

λ P($\lambda = 3$) разность		
10	0,1172	0,0232
50	0,1386	0,0018
100	0,1396	0,0008
1 000	0,1403	0,0001
10 000	0,1404	0,00001
Pois(5) 0.1404 —		

Почему это полезно? (10000 3) сложно вычислить. Формула Пуассона состоит из трех операций.

Практическое правило: Если $\lambda \geq 20$ и $p \leq 0,05$, приближение Пуассона достаточно точное.

Историческая справка: Пуассон (1837) вывел это распределение именно таким, какое оно есть — как большое количество повторений событий с низкой вероятностью.

**Экономическое
применение**

Математические ожидания как инструмент принятия решений Страхование — гипотетические числа

Условия Годовая премия: 1 200 000 сумов.
Выплата в случае убытка: 90 000 000 сумов.
Вероятность убытка в течение года: $P = 0,008$.

Прибыль страховщика Π :

$$E[\Pi] = 1,2 \text{ млн} - 0,008(90 \text{ млн}) = 480 \text{ 000 сумов}$$

Это отрицательное ожидание для клиента: -480 000 сумов .

Вопрос аудитории Если ожидания отрицательные, почему люди покупают страховку?

Ответ: дисперсия. Убыток в 90 миллионов сумов катастрофичен для клиента. Это обмен небольшого, гарантированного убытка на большой, неопределенный убыток.

Ожидаемая стоимость — это не вся история. Дисперсия также важна — она является основой управления рисками в финансах.

Объединение рисков: почему страхование работает

Единичный полис:

$$SD(\square) = \sqrt{0,008(0,992)} \times 90 \text{ миллионов} = 8,02 \text{ миллиона}$$

Ожидалось 0,48 миллиона, но дисперсия 8,02 миллиона — в 17 раз больше.

10 000 несвязанных полисов:

$$E = 4,8 \text{ миллиарда, } SD = 0,80 \text{ миллиарда}$$

$$\frac{SD}{E} = 0,167$$

Относительная дисперсия уменьшается в $\sqrt{n}$ раз.


$SD / E = 16,7$ для одного полиса; 0,167 для 10 000 полисов — в сто раз меньше.

Распространенная ошибка. Условие: полисы должны быть независимыми. Объединение не работает, если землетрясение или кризис одновременно затрагивают все полисы — один из уроков финансового кризиса 2008 года.

Этот $\sqrt{n}$ — не совпадение. На 7-й неделе он возвращается как $SE = \square / \sqrt{n}$ и становится основой всего статистического вывода.

Краткое
содержание

Какое распределение нам следует выбрать?



Заблуждение Почему это неправильно

« $E[\bar{X}]$ — наиболее вероятное значение». В нашем примере мода равна $\bar{x} = 4$, математическое ожидание равно 4,53. $E[\bar{X}]$ — это взвешенное среднее, а не мода; это также может быть значение, которое вообще невозможно.

«Количество — это данные, поэтому это распределение Пуассона». В распределении количества $\bar{x}^2/\bar{x} = 115$. Распределение определяется условиями процесса, а не типом данных.

« $\text{Var}(\bar{X} + \bar{X}) = \text{Var}(\bar{X}) + \bar{X}$ ». Сдвиг не меняет дисперсию: $\text{Var}(\bar{X} + \bar{X}) = 2\text{Var}(\bar{X})$. $\bar{X}$ просто исчезает.

«Биномиальное распределение может быть применено к любому χ^2 тесту». Требуются условия BINS. В нерегрессионной выборке нарушается независимость — аппроксимация допустима только если $n < 0,05\bar{x}$.

« $P(\bar{x} < 3)$ и $P(\bar{x} \leq 3)$ одинаковы». В дискретном случае разница составляет $\bar{p}(3) = 0,1636$ — немалое число.

«Если математическое ожидание положительно, решение правильное». В страховании математическое ожидание отрицательно для клиента, но решение разумное — потому что дисперсия также важна.

«Проверять $\sum \bar{p}(\bar{x})$ не обязательно». Это самый быстрый способ найти ошибку. Если она не равна 1, значит, где-то есть ошибка.

1. Случайная величина — это функция. Она преобразует события в числа и открывает путь для арифметических вычислений.

2. $E[\square] = \sum \square \square(\square)$ и $\text{Var}(\square) = E[\square^2] - (E[\square])^2$ — оба выражения должны быть выведены, а не запомнены.

3. E является линейной функцией, а Var — нет: $\text{Var}(\square\square + \square) = \square^2 \text{Var}(\square)$.

4. Биномиальное распределение — $\binom{n}{k} p^k (1-p)^{n-k}$ (неделя 2) и независимость (неделя 2) вместе.

5. Перед выбором распределения проверьте условие: BINS или $\square^2/\square \approx 1$.

6. Математическое ожидание составляет половину решения; другая половина — дисперсия. Закон $\sqrt{\square}$ возвращается на 7-й неделе.

Следующая неделя — 5-я неделя — Непрерывные распределения и нормальные распределения. Мы переходим от суммы к интегралу: функция плотности, равномерное и экспоненциальное распределения, нормальное распределение, оценка $\square$ и Q-Q-график.

Содержание задания Срок сдачи

Обязательное чтение: Ньюболд, глава 4; МакКлейв, глава 4; Хьюман, глава 7
Перед лекцией 1 Лабораторная работа W04-lab — Функция вероятностного распределения, биномиальное и пуассоновское соответствие Проверка в лаборатории

Домашнее задание W04-homework — 6 задач, 40 баллов Неделя 5, понедельник Набор задач 3 MT3 (дискретные распределения) Срок сдачи: Неделя 5 Этап проекта 4 Получение информации — Контрольная точка 1. Источник, объем, метод получения

Неделя 5,
пятница

Задание SI Найдите ошибки в выборе распределения SI Неделя 5, пятница

Контрольная точка проекта. Этот этап не оценивается, но является обязательным: если у вас нет информации, проект будет остановлен с 6-й недели. Если вы не можете найти источник, немедленно свяжитесь с преподавателем.

1. Ньюболд, П., Карлсон, У. и Торн, Б. Статистика для бизнеса и экономики. Pearson. Глава 4 — Дискретные случайные величины и распределения вероятностей.
2. МакКлейв, Дж. Т. и Синчич, Т. (2018). Статистика, 13-е изд. Pearson. Глава 4.
3. Хьюманн, К., Шомакер, М. и Шалабх (2016). Введение в статистику и анализ данных. Springer. Глава 7 — Случайные величины; Глава 8 — Распределения.
4. ДеГрут, М. и Шервиш, М. (2012). Вероятность и статистика, 4-е изд. Главы 3–4 (расширенные).
5. Пуассон, С. Д. (1837). Исследования вероятности суждений — первоисточник распределений.
6. Вулдридж, Дж. М. (2019). Введение в эконометрику, 7-е изд. Приложение В — Вероятность для экономистов.
7. Интерактивный ресурс: Seeing Theory, Университет Брауна, раздел «Вероятностные распределения» — seeing-theory.brown.edu
8. Видео: MIT OCW 18.05, лекции 5–7; StatQuest, «Биномиальное распределение» и «Распределение Пуассона».