

Ташкентский международный университет · Факультет экономики
Непрерывные распределения и нормальное распределение

Неделя 5 · Лекции 1 и 2

Ташкентский международный университет · Экономический
факультет

2025/2026 учебный
год



Неделя 4. Было подсчитано значение X : 0, 1, 2, ...
Каждое значение имело свою вероятность:

$$E[X] = \sum_x x p(x)$$

Таких значений нет. Вероятность каждого конкретного значения равна нулю.

Дискретная $\square(\square)$
 $= P(\square = \square)$

Непрерывная $\square(\square)$
— плотность

Вероятность =
площадь под
кривой

$$\Sigma \rightarrow \int$$

На этой неделе вступает в игру определенный интеграл из MATH102. Идея не меняется — только сумма становится интегралом.

Цели обучения на 5-ю неделю

К концу этой недели вы сможете:

1. Определить функцию плотности и объяснить, почему $P(X = x) = 0$.

2. Вычислить вероятность в виде поверхности; показать взаимосвязь между P и f .

3. Работать с равномерным и экспоненциальным распределениями.

4. Стандартизировать нормальное распределение и использовать оценку z .

5. Оценить нормальность с помощью Q-Q-графика.

6. Аппроксимировать биномиальное распределение нормальным и применить поправку на непрерывность.

Результат обучения CLO3. Работа со случайными величинами и стандартными распределениями (Блум: Применение и анализ).

Распространенные ошибки

Требования к математике. Определенный интеграл $\int_a^b f(x) dx$ — MATH102, Глава 5. Если вы забыли, повторите перед занятием.

Функция плотности


Определение функции плотности
 $f(x)$:

$$P(a \leq x \leq b) = \int_a^b f(x) dx$$

Условия:

$$f(x) \geq 0, \quad \int_{-\infty}^{\infty} f(x) dx = 1$$

Распространенное заблуждение заключается в том, что $f(x)$ не является вероятностью. Она может быть больше 1. Вероятность — это всего лишь поверхность.



$$P(x = x) = \int_x^x f(t) dt = 0$$

Следовательно, в непрерывном случае $P(x < a) = P(x \leq a)$.

Равномерное распределение: простейшая непрерывная модель

$$f(x) = \frac{1}{b-a}, \quad a \leq x \leq b$$


$$E[\square] = \square^2, \quad \text{Var}(\square) = (\square - \square)^2$$

Пример. $\square \sim \text{Unif}(10, 25)$:

$$f(x) = \frac{1}{15} = 0,0667$$

$$E[\square] = 17,5, \quad \text{Var} = 18,75, \quad \text{SD} = 4,33$$

$$P(12 < \square < 18) = \frac{18-12}{15} = 0,400$$



Вопрос аудитории: Чему равно $P(\square = 15)$? Как это выглядит на графике?

**Нормальное
распределение**


Определение
 $X \sim N(\mu, \sigma^2)$:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$


μ — центр, σ^2 — дисперсия.

Свойства:

- ▶ Симметрично относительно μ
- ▶ Колоколообразная форма, однопиковая ▶ μ = медиана = мода
- ▶ Определяется по целочисленной оси



Правило 68-95-99,7



Точная вероятность интервала

$\mu \pm 1\sigma$	0,682689
$\mu \pm 2\sigma$	0,954500
$\mu \pm 3\sigma$	0,997300

Распространенная ошибка. Необходимо также обратное направление: для 95%-ной уверенности $z = 1,960$, а не 2. Для 99%-ной уверенности $z = 2,576$.

Эти числа регулярно появляются в доверительных интервалах, начиная с 9-й недели.

Определение Стандартная оценка (z-оценка)

$$Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1)$$

z — показывает, на сколько стандартных отклонений наблюдение отклоняется от среднего значения.

Зачем это нужно? Одной таблицы (или одной функции) достаточно для всех нормальных распределений.

$\Phi(z) = P(Z \leq z)$

−1,960	0,0250
−1,645	0,0500
−1,000	0,1587
0,000	0,5000
1,000	0,8413
1,645	0,9500
1,960	0,9750
2,576	0,9950

Распространенная ошибка заключается в том, что z безразмерна. Поэтому суммы, тонны и точки сравниваются по одной и той же шкале.

Проверка нормальности

Одна и та же переменная, две страны, два разных ответа

Асимметрия $-0,649$; Q-Q $\hat{\rho} = 0,9405$;
Шапиро-Уилк $\hat{\rho} = 0,866$, $\hat{p} = 0,0025$.

Причина: распределение бимодальное (неделя 1).

Близко к нормальному распределению:
Кыргызстан

$n = 27$; $\bar{x} = 2,235$, $s = 0,277$.


Асимметрия $-0,655$; Q-Q $\hat{\rho} = 0,9660$;
Шапиро-Уилк $\hat{\rho} = 0,929$, $\hat{p} = 0,0640$.

Здесь применима нормальная модель.

Вопрос аудитории: Оба распределения имеют почти одинаковую асимметрию ($-0,65$), но одно из них нормальное, а другое нет. Какой показатель продемонстрировал разницу?

Одного числа недостаточно — посмотрите на график.

Q-Q-график: визуальная проверка на нормальность



Узбекистан: точки систематически отклоняются от линии



Как читать:

- Точки на линии $\Rightarrow$ нормальное распределение
- S-образная форма $\Rightarrow$ асимметрия
- Восходящие концы $\Rightarrow$ тяжелые хвосты
- Лестница $\Rightarrow$ дискретность или группировка

Распространенная ошибка. Будьте осторожны с малыми значениями n . При $n = 27$ точки естественным образом «скачут». Q-Q-график для нормальных данных также не является идеальной линией.

Логарифмическая подстановка. Бюджеты фильмов: $n = 2467$

Бюджет (млн долл.) $\ln(\text{бюджет})$ Бюджет $\ln(\text{бюджет})$



Асимметрия +1,618 -0,738
Q-Q $\square$ 0,9007 0,9799 $\square$ 35,81
2,939 Med 22,00 3,091

Логарифм значительно уменьшил
асимметрию вправо: $\square$ 0,90 $\rightarrow$ 0,98.

Где работает нормальная модель, а где она дает сбой

Бюджет	оценка	Нормальная модель	Прогноз	Фактический процентиль
10 миллионов долларов	-0,484	31,4%	28,7%	50 миллионов долларов
долларов +0,741	77,0%	76,5%	150 миллионов долларов	+1,577
	94,3%	98,5%		

Модель отлично работает в центре. При 50 миллионах долларов ошибка составляет всего 0,5 процентных пункта.

Распространенная ошибка заключается в том, что она дает сбой в хвосте. При 150 миллионах долларов модель утверждает, что 5,7% фильма стоит столько же; на самом деле это 1,5%. Ошибка почти в четыре раза больше.

Почему это важно? В управлении рисками, страховании и финансах решения принимаются в хвостовой части распределения. Тот факт, что нормальная модель хороша в центре, не означает, что ей можно доверять в хвостовой части.

Экспоненциальное распределение

$$f(t) = \lambda e^{-\lambda t}, \quad t \geq 0$$

$$F(t) = 1 - e^{-\lambda t}$$

$$E[\square] = \frac{1}{\lambda}, \quad SD(\square) = \frac{1}{\lambda}$$

Ссылка на 4-ю неделю. Если количество событий равно $\text{Pois}(\lambda)$, то время между ними равно $\text{Exp}(\lambda)$. Два представления одного и того же процесса.

Пример (из 4-й недели). $\lambda = 10,95$ фильмов ужасов в год.

$$E[\square] = \frac{1}{10,95} = 0,0913 \text{ лет} = 33,3 \text{ дня}$$

$$\text{Медиана} = \frac{\ln 2}{\lambda} = 0,0633 \text{ лет} = 23,1 \text{ дня}$$

$$P(\square > E[\square]) = e^{-1} = 0,368$$

Время ожидания больше среднего значения в 36,8% случаев.

Свойство отсутствия памяти

$$P(X > s + t | X > s) = P(X > t)$$

Доказательство.

$$P(X > s + t) = P(X > s) \cdot P(X > t) = e^{-\lambda s} \cdot e^{-\lambda t} = e^{-\lambda(s+t)}$$

Проверка ($\lambda = 10.95$, $\mu = 0.05$):


$\lambda P(X > s + t X > s) - P(X > t)$		
0,05	0,578469	0,578469
0,10	0,578469	0,578469
0,20	0,578469	0,578469

Смысл. Независимо от того, как долго вы ждете, распределение оставшегося времени ожидания не меняется. Процесс «не помнит, сколько времени прошло».

Распространенная ошибка. Поэтому эта модель часто неверна. Чем дольше человек стоит в очереди, тем меньше у него терпения. Чем дольше работает машина, тем выше вероятность поломки.

Потеря памяти — это удобство, а не закон природы.

Нормальная аппроксимация биномиального распределения



$\text{Bin}(100; 0.4528)$ и $\mathcal{N}(45.28; 4.982)$

Теорема Если $np \geq 10$ и $n(1-p) \geq 10$:

$$\text{Bin}(n, p) \approx \mathcal{N}(np, np(1-p))$$

Распространенная ошибка. Требуется корректировка непрерывности: мы заменяем дискретную величину непрерывной моделью.

$$P(a \leq x \leq b) \approx \Phi\left(\frac{b+0.5-\mu}{\sigma}\right) - \Phi\left(\frac{a-0.5-\mu}{\sigma}\right)$$

Насколько важна коррекция непрерывности?

	$n = 10$	$n = 30$	$n = 100$
Условие $n\pi \geq 10$, $n(1 - \pi) \geq 10$ не выполнено	0.798231	0.536146	0.311549
Условие выполнено	0.796051	0.536577	0.311877
Точное биномиальное распределение + коррекция	0.659302	0.417623	0.236626
Нормальное распределение без коррекции	0.0022	0.0004	0.0003
Общая ошибка. Нескорректированная ошибка	0.1389	0.1185	0.0749

Коррекция уменьшила ошибку в 63 раза при $\pi = 10$ — даже если условие не было выполнено.

Общая ошибка. Нескорректированная ошибка остается равной 0,075 даже при $\pi = 100$ — увеличение π не компенсирует корректировку.

Краткое
содержание

Заблуждение Почему это неправильно

« $P(x)$ — это вероятность x ». $p(x)$ — это плотность распределения; она может быть больше 1. Вероятность — это просто площадь под кривой.

«Много данных — значит, это нормальное распределение». 2467 бюджетов фильмов Q-Q $p = 0,90$: не нормальное распределение. Размер n не делает форму кривой нормальной.

«Асимметрия близка к нулю — значит, это нормальное распределение». У Узбекистана и Кыргызстана почти одинаковая асимметрия ($-0,65$), но одно из них нормальное, а другое — нет. Посмотрите на график.

«Логарифм всегда восстанавливает нормальность». Асимметрия бюджета изменилась с $+1,62$ до $-0,74$ — улучшение, но обратное.

«Если нормальная модель работает в центре, она работает везде». При 50 миллионах долларов ошибка составляет 0,5 процентных пункта; при 150 миллионах долларов — 4,2 процентных пункта. Модель дает сбой в хвосте — именно там, где принимаются решения.

« $P(x < y)$ и $P(x \leq y)$ — разные величины». В непрерывном случае разницы нет, потому что $P(x = y) = 0$. В дискретном случае разница есть — не путайте их.

«Коррекция непрерывности — это необязательный тонкий момент». При $n = 10$ погрешность уменьшается с 0,139 до 0,002. Нормальное приближение без поправки практически бесполезно.

1. Непрерывная вероятность — это поверхность. Точечная вероятность равна нулю.

2. $Z = (X - \mu) / \sigma$ сводит любое нормальное распределение к одной стандартной шкале.

3. Нормальность — это предположение, которое можно проверить. Q-Q-график показывает не только одно число.

4. Подстановка (например, $\ln$) помогает, но не гарантирует совершенства.

5. Нормальная модель надежна в центре, а не на хвостах.

6. Если вы заменяете дискретное распределение непрерывным, добавьте поправку на непрерывность.

На следующей неделе, Неделя 6 — Совместные распределения, ковариация и корреляция. Как две случайные переменные ведут себя вместе; дисперсия портфеля; квартет Анскомба. Контрольная работа 2, Неделя 6 (Недели 4-6).

Содержание задания Срок сдачи

Обязательное чтение: Ньюболд, глава 5; МакКлейв, глава 5; Хьюман, глава 8
Перед лекцией 1 Лабораторная работа W05 — плотность, оценка $\hat{p}$, Q-Q-график, нормальная аппроксимация В лаборатории Домашнее задание W05 — 6 задач, 40 баллов Неделя 6, понедельник Задачи 3 MT3 сдаются на этой неделе Задачи 4 MT4 сдаются: Неделя 6 Шаг проекта 5 Очистка данных: пропущенные значения, выбросы Неделя 6, пятница

Задание SI Найти ошибки SI относительно нормальности Неделя 6, пятница

Распространенная ошибка на неделе 6 Контрольная работа 2 — материал недель 4–6 (случайные величины, дискретные и непрерывные распределения).

1. Ньюболд, П., Карлсон, У. и Торн, Б. Статистика для бизнеса и экономики. Pearson. Глава 5 — Непрерывные случайные величины и нормальное распределение.
2. МакКлейв, Дж. Т. и Синчич, Т. (2018). Статистика, 13-е изд. Pearson. Глава 5.
3. Хьюманн, К., Шомакер, М. и Шалабх (2016). Введение в статистику и анализ данных. Springer. Глава 8.
4. Четинкая-Рундель, М. и Хардин, Дж. (2024). Введение в современную статистику, 2-е изд. OpenIntro — Нормальное распределение и Q-Q-графики.
5. ДеГрут, М. и Шервиш, М. (2012). Вероятность и статистика, 4-е изд. Глава 5 (подробно).
6. Лимперт, Э., Стахель, В. и Аббт, М. (2001). Логарифмически нормальные распределения в науках. BioScience, 51(5), 341–352.
7. Интерактивное видео: Seeing Theory, Университет Брауна, «Вероятностные распределения» — seeing-theory.brown.edu
8. Видео: 3Blue1Brown, «Почему π находится в нормальном распределении»; StatQuest, «Нормальное распределение, ясно объяснено».