

Ташкентский международный университет · Факультет экономики Совместные
распределения, ковариация и корреляция

Неделя 6 · Лекции 1 и 2

Ташкентский международный университет · Экономический
факультет

2025/2026 учебный
год



От одной переменной к двум


Недели 4–5. Одна случайная переменная: $E[\cdot]$, $\text{Var}(\cdot)$, распределение, выбор модели.

Распространенная ошибка. Но экономические вопросы почти всегда касаются двух переменных.

Бюджет и доход. Инфляция и безработица. Два актива вместе.

Вопрос этой недели: Как две случайные переменные ведут себя вместе — и какие решения это требует?

Ответ сводится к одному числу: корреляции. Но это число скрывает многое — как мы увидим.



Цели обучения на 6-ю неделю

К концу этой недели вы сможете:

1. Построить совместные и маргинальные распределения.
2. Проверить независимость случайных величин.
3. Вывести и рассчитать ковариацию на основе определения.
4. Интерпретировать корреляцию и показать ее ограничения.
5. Применить $\text{Var}(X+Y)$ и количественно оценить диверсификацию.
6. Показать на основе данных, что корреляция не подразумевает причинно-следственную связь.

Результат обучения CLO4. Анализ совместных распределений, ковариации и корреляции (Блум: Анализ).

Распространенные ошибки. Контрольная работа 2 на этой неделе. Материал недель 4–6: случайные величины, дискретные и непрерывные распределения, ковариация и корреляция.

**Совместное
распределение**

Определение совместного распределения

$$P(\square, \square) = P(\square = \square, \square = \square)$$

Маргинальное распределение

$$p_X(x) = \sum_y p(x, y)$$

Маргинальные распределения — это суммы, записанные на полях таблицы. Отсюда и название.

□: Узбекистан находится выше медианы; □: Казахстан находится выше медианы (□ = 27)

	$y = 0$	$y = 1$	$p_X(x)$
$x = 0$	0,3333	0,1852	0,5185
$x = 1$	0,1852	0,2963	0,4815
$p_Y(y)$	0,5185	0,4815	1,0000

Распространенная ошибка: Маргинальные распределения не восстанавливают совместность. Существуют совместные таблицы с одинаковыми полями, но совершенно разными.

Определение. X и Y называются независимыми, если для всех x, y выполняется равенство.

$$p(x, y) = p_X(x) p_Y(y)$$

Эквивалентно: $p(y|x) = p_Y(y)$.

Распространенная ошибка — «Для всех x, y » — это важно. Тот факт, что равенство выполняется в одной ячейке, не доказывает независимость; его нарушение в одной ячейке опровергает ее.

Проверяем ($\square = 1, \blacksquare = 1$):

$$p(1, 1) = 0,2963$$

$$p\square(1) p\blacksquare(1) = 0.4815 \times 0.4815 = 0.2318$$

$$0.2963 \neq 0.2318 \Rightarrow \text{связано}$$

В условной форме:

$$P(\square = 1 | \blacksquare = 1) = \frac{0.2963}{0,4815} = 0,6154$$

$$\text{против } P(\blacksquare = 1) = 0.4815$$

В годы, когда урожай в Узбекистане хороший, вероятность хорошего урожая в Казахстане также увеличивается — общая погода условия.

Ковариация

Определение ковариации

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])]$$

Формула расчета:

$$\begin{aligned}\text{Cov}(X, Y) &= E[XY - XE[Y] - YE[X] + E[X]E[Y]] \\ &= E[XY] - E[X]E[Y] - E[Y]E[X] + E[X]E[Y] \\ &= E[XY] - E[X]E[Y]\end{aligned}$$

Для выборки: $\text{Cov}(X, Y) = \frac{1}{n-1} \sum (X_i - \bar{X})(Y_i - \bar{Y})$

Значение обозначения. Если оба значения выше среднего (или оба ниже), произведение положительное.

Если одно значение выше, а другое ниже — отрицательное.

Теорема: X и Y независимы $\Rightarrow \text{Cov}(X, Y) = 0$.

Обратное утверждение неверно: даже если $\text{Cov} = 0$, может существовать взаимосвязь — просто не линейная.

Давайте рассчитаем вручную Узбекистан 2010–2018: $\bar{x}$ = пшеница, $\bar{y}$ = ячмень (т/га)

Год	$\bar{x}$	$\bar{y}$	$\bar{x} - \bar{x}$	$\bar{y} - \bar{y}$	произведение
2010	4,600	1,914	−0,005	+0,391	−0,0021
2011	4,556	1,282	−0,049	−0,241	+0,0119
2012	4,710	1,658	+0,105	+0,135	+0,0141
2013	4,739	1,496	+0,134	−0,027	−0,0036
2014	4,782	1,514	+0,177	−0,009	−0,0016
2015	4,818	1,631	+0,213	+0,108	+0,0229
2016	4,802	1,625	+0,197	+0,102	+0,0200
2017	4,316	1,349	−0,289	−0,174	+0,0504
2018	4,126	1,239	−0,479	−0,284	+0,1362
$\bar{x}=4,6054$		$\bar{y}=1,5231$		0,2482	

$$s_{xy} = \frac{0,2482}{9 - 1} = \mathbf{0,03103}$$

$$s_x = 0,23976, \quad s_y = 0,21301$$

$$r = \frac{0,03103}{0,23976 \times 0,21301} = \mathbf{0,6076}$$

$$r^2 = 0,3691$$

2017 и 2018 годы — засушливые годы — внесли наибольший вклад (0,0504 и 0,1362). Урожайность обеих культур снизилась одновременно.

Корреляция

Распространенная ошибка. Проблема с ковариацией: единица. В приведенном выше примере единицей измерения cov является $(\text{т/га})^2$. Для бюджета и дохода это (миллион долларов)².

Величины нельзя сравнивать.

Определение корреляции

$$r = \frac{\text{Cov}(X, Y)}{SD(X) SD(Y)}$$

Это стандартизированная ковариация.

Свойства:

- ▶ $-1 \leq r \leq 1$ всегда
- ▶ безразмерная величина
- ▶ нечувствительна к масштабу ▶ $|r| = 1 \Leftrightarrow$ точно линейная зависимость
- ▶ симметричная: $r_{XY} = r_{YX}$

Распространенная ошибка заключается в том, что r измеряет только линейные зависимости. В сильных, но асимметричных зависимостях r может быть близок к нулю.

Матрица корреляции: урожайность пшеницы в пяти странах, 1992-2018 гг.

УЗБ КЫРГ КАЗ ТАДЖ ТУРК

Узбекистан	1,000	-0,096	0,407	0,917	-0,213
Кыргызстан	1,000	0,343	0,012	0,156	
Казахстан	1,000	0,399	-0,133		
Таджикистан	1,000	-0,392			
Туркменистан	1,000				

Сильнейшие: Узбекистан-Таджикистан $\rho = 0,917$.
Рядом аналогичная ирригационная система.

Распространенная ошибка. Наиболее отрицательное значение: Таджикистан-Туркменистан $\rho = -0,392$. Это наиболее ценная пара для диверсификации — мы увидим это позже.

Вопрос аудитории: $\rho = 0,917$ не означает, что Узбекистан влияет на Таджикистан. Что это значит? Ответ мы увидим в последнем разделе.

«Корреляция» — одно слово, три разных числа

Бюджет фильма и мировые кассовые сборы, $n = 2467$ (реальные данные)

Показатель. Что он измеряет

Коэффициент корреляции Пирсона $r = 0,6995$ (линейная корреляция) Коэффициент корреляции Пирсона r (в логарифмическом масштабе) $0,5961$ (линейность в логарифмическом масштабе) Коэффициент корреляции Спирмена $s = 0,7340$ (монотонная корреляция по цвету) Коэффициент корреляции Кендалла $\tau = 0,5478$ (доля сопоставленных пар)

Коэффициент Спирмена выше, чем коэффициент Пирсона ($0,734 > 0,700$): корреляция монотонная, но не идеально линейная.

Распространенная ошибка заключается в том, что предложение «Корреляция $0,70$ » является неполным. Какая мера? По какой шкале? Напишите это в своем отчете.

Дисперсия популяции

Теорема

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

Если он независим, последний член исчезает:

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

Распространенная ошибка Внимание: $\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y) - 2\text{Cov}(X, Y)$. В разность также добавляются дисперсии.

Числовая проверка (X =Узбекистан, Y =Казахстан, $\rho = 0,5$):

$$\text{Var}(X) = 1,3912 \quad \text{Var}(Y) = 0,0676$$

$$\text{Cov}(X, Y) = 0,1248$$


$$\text{Var}(0,5X + 0,5Y) = 0,4271 \text{ (прямой)}$$

$$0,3478 + 0,0169 + 0,0624 = 0,4271 \checkmark$$

Распространенная ошибка. При допущении независимости: 0,3647 — заниженная оценка на 14,6%.

Портфель и диверсификация

Диверсификация по цифрам
Таджикистан и Туркменистан: $\rho = -0,392$



Стандартное отклонение (только Таджикистан) 0,8528
Стандартное отклонение (только Туркменистан) 0,8080
Стандартное отклонение (минимальный портфель) 0,4574


$w^* = 0,4806$ Прибыль 43,4%

$$w^* = \frac{\text{Var}(w) - \text{Cov} \text{Var}(w) + \text{Var}(w) - 2 \text{Cov}}{\text{Cov} = 0,481}$$

Практически равная
доля.

Предполагая общую ошибку $\rho = 0$, стандартное отклонение портфеля составляет 0,5874 — вместо истинного 0,4582 (завышение на 28,2%). Но обратите внимание: это на уровнях ρ , и в обеих линиях наблюдается тренд — именно это и проверяется в данном случае.

Что скрывает корреляция?



Множество $\begin{bmatrix} 9000 & 3317 & 7501 & 2032 \\ 3317 & 7501 & 2032 & 0,8162 \\ 7500 & 2030 & 0,8163 & 2,031 \end{bmatrix}$

I 9000 3317 7501 2032 0,8164 II 9000
3317 7501 2032 0,8162 III 9000 3317
7500 2030 0,8163 IV 9000 3317 7,501
2,031 0,8165

Их графики совершенно разные.

I. Истинная линейная зависимость. II. Определенная асимметричная зависимость — $\square$ ее не видит. III. Один выброс искажил линию. IV. Одна точка создала всю зависимость.

Правило. Постройте диаграмму рассеяния перед вычислением $\square$. Всегда.

Анскомб (1973) создал эти наборы именно для этой цели: чтобы показать, что числовые измерения не могут заменить графики.

Вопрос аудитории В наборе IV 10 из 11 точек имеют одинаковое значение $\square$. Что измеряет $\square$ в данных такого типа?

Ложная корреляция: в реальных данных

Урожайность пшеницы в Узбекистане и Таджикистане:

$$r = 0,9167$$

Очень сильная. Но одна не влияет на другую.

Общая причина — время:

$$\rho(\text{год, Узбекистан}) = 0,9076$$

$$\rho(\text{год, Таджикистан}) = 0,9624$$

После обретения независимости оба показателя росли в одном направлении.

Удаляем тренд. Вычитаем линейный тренд из каждой строки и вычисляем корреляцию остатков: $\rho_{\text{остаток}} = 0,3786$.

Стандартная ошибка составила $0,917 \rightarrow 0,379$.
Большая часть корреляции обусловлена общей тенденцией.

Оставшиеся $0,379$, вероятно, являются истинным общим фактором (погода, региональные условия).

Переход к 13-й неделе. Два временных ряда, растущих в одном направлении, почти всегда демонстрируют сильную корреляцию — наиболее распространенную форму искажающего фактора.

Краткое
содержание

Заблуждение Почему это неправильно

«Ковариация = 0 означает отсутствие корреляции». Верно только обратное. Ковариация = 0 означает отсутствие линейной зависимости; может существовать асимметричная зависимость (Анскоб II).

«Ковариация велика — связь сильная». Ковариация равна единице. 3 816 (млн долларов)² кажется большим, но $\rho = 0,70$. Сравнивать можно только ρ .

« $\rho = 0,92$ — значит, одно влияет на другое». После удаления тренда он упал до 0,38. Общий временной тренд поднял обе линии.

« $\text{Var}(X - Y) = \text{Var}(X) - \text{Var}(Y)$ ». $\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y) - 2$. Ковариации аддитивны, а не субтрактивны.

«Можно с уверенностью предположить, что портфель независим». В нашем примере это привело к завышению стандартного отклонения на 28,2%; в обратном направлении это может привести к занижению риска.

« r достаточно для описания данных». В четырех наборах данных Анскомба r одинаково, но графики совершенно разные. Сначала постройте график, затем рассчитайте.

«Маргинальные распределения являются совместными». Это не так. Имеются таблицы с одинаковыми маргинальными значениями, но разными корреляциями.

1. Совместное распределение не восстанавливается по ребрам — связь является дополнительной информацией.
2. $\text{Cov} = E[\bar{X}\bar{Y}] - E[\bar{X}]E[\bar{Y}]$; знак указывает направление, а величина — зависимость от единицы.
3. ρ — стандартизированная ковариация; измеряет только линейную связь.

4. Не забудьте член $2\rho\sigma_X\sigma_Y$ в $\text{Var}(\bar{X} + \bar{Y})$ — разница в 14,6% в нашем примере.

5. Отрицательная корреляция является самым сильным источником диверсификации (прирост 43,4%).
6. Сначала нарисуйте, затем рассчитайте. Анскомб и ложная корреляция доказывают это.

На следующей неделе - Неделя 7 — Выборочные распределения и центральная предельная теорема. Наконец, закон $\sqrt{n}$ полностью объясняется, и мы переходим к статистическому выводу.

Содержание задания Срок сдачи

КОНТРОЛЬНАЯ РАБОТА 2 Оценивается. Недели 4–6, 45 минут на этой неделе. Обязательное чтение: Ньюболд 4.4–4.7 и 5.7; МакКлейв, глава 6; Глава 9 Хеймана. Перед лекцией 1. Лабораторная работа W06-lab — ковариация, корреляционная матрица, портфель, Анскомб. В лаборатории.

Домашнее задание W06-homework — 6 задач, 40 баллов. Неделя 7, понедельник. Набор задач 4 MT4. Срок сдачи на этой неделе. Этап проекта 6. Описательный анализ: центр, дисперсия, форма. Неделя 7, пятница. Задание SI. Найдите ошибки корреляции SI. Неделя 7, пятница.

Распространенные ошибки. Подготовка к контрольной работе 2. Вам предлагается проверить условия, а не запоминать формулы: какое распределение, почему и что произойдет, если условие нарушено.

1. Ньюболд, П., Карлсон, У. и Торн, Б. Статистика для бизнеса и экономики. Pearson. 4.4–4.7 (совместные распределения, ковариация, портфель) и 5.7.

2. МакКлейв, Дж. Т. и Синчич, Т. (2018). Статистика, 13-е изд. Pearson. Глава 6.

3. Хьюманн, К., Шомакер, М. и Шалабх (2016). Введение в статистику и анализ данных. Springer. Глава 9.

4. Анскомб, Ф. Дж. (1973). Графики в статистическом анализе. Американский статистик, 27(1), 17–21. — первоисточник квартета, всего 5 страниц.

5. Марковиц, Х. (1952). Выбор портфеля. Журнал финансов, 7(1), 77–91. — основа теории диверсификации.

6. Матейка, Й. и Фитцморис, Г. (2017). Одна и та же статистика, разные графики. CHI '17 — современное продолжение работы Анскомба («Датазаурус»).

7. Интерактив: игра «Угадай корреляцию»; раздел «Регрессионный анализ» в книге «Теория».

8. Видео: StatQuest, «Ковариация и корреляция, ясно объяснено».