

Ташкентский международный университет ·
Факультет экономики Проверка гипотез I

Неделя 10 · Средние значения и пропорции · Лекции 1
и 2

Ташкентский международный университет · Экономический
факультет

2025/2026 учебный
год



Второй вопрос

На что ответили на 9-й неделе?

«Сколько равно $\square$?»

Ответ: $[4,4600; 4,8100]$ — оценка и её неопределённость вместе.


Что спрашивается на 10-й неделе?

«Равно ли $\square$ такому-то числу?»

Это другой вопрос: теперь ответ — не число, а решение. И любое решение может быть неверным.

Проверка гипотез — не новая идея. Это другой способ взглянуть на доверительный интервал. Мы докажем это на первом слайде.

Распространенная ошибка. Однако **p-значение** — наиболее неправильно понимаемое понятие в статистике. Половина этой недели посвящена ему.



Цели обучения на 10-ю неделю

К концу этой недели вы сможете:

1. Сформулировать нулевую и альтернативную гипотезы до просмотра данных.
2. Вычислить значение p с помощью моделирования — без формулы — и сформулировать его определение.
3. Провести t-тест для среднего значения и z-тест для доли.
4. Вычислить ошибку первого типа, ошибку второго типа и мощность.
5. Численно отклонить неверные интерпретации значения p .
6. Вы научитесь распознавать и измерять p -хакинг.
7. Вы научитесь различать статистическую значимость и практическую значимость.

Что именно это означает — и что это не означает?

CLO7 — Формулировать гипотезы, проверять их и правильно интерпретировать значение p . Уровень Блума: Анализ / Оценка.

Метод остается тем же: мы знаем исходный набор данных, поэтому ошибка каждого метода не указывается, а подсчитывается. На этой неделе мы даже смоделируем мир, где H_0 верна, — и посмотрим, что там произойдет.

Интервал и тест — это одно и то же

Пример данных за 9-ю неделю: урожайность пшеницы в Узбекистане 2009–2018 гг., $\bar{x} = 10$, $s^2 = 4,6350$, $n = 0,2446$, $SE = 0,0774$. 95%-ный интервал: $[4,4600; 4,8100]$.

Находится ли μ_0 μ $\mu = 0,05$ в этом интервале?

4.30 4.331 0.0019 отклонено нет 4.40 3.038 0.0141
отклонено нет 4.460019 2.262157 0.050000
граница граница 4.50 1.745 0.1149 не отклонено
да 4.635 0.000 1.0000 не отклонено да 4.809981
–2.262157 0.050000 граница граница 4.90 –3.426
0.0076 отклонено нет

Теорема. Точно, а не приблизительно. На неокругленном конце интервала μ равен ровно 0.050000. При округленном значении 4,4600, $\mu = 0,049980$ — формально отклонено.

Доверительный интервал = множество всех μ_0 , которые не могут быть отклонены. Ничего больше.

Две гипотезы — не равны

H_0 — нулевая гипотеза: «ничего», «разница равна нулю», « $\mu = \mu_0$ ». Всегда с равенством.

H_1 — альтернатива: то, что исследователь хочет показать. $\neq$, $<$ или $>$.

Распространенная ошибка

Асимметрия преднамеренна. Как и в суде: обвиняемый считается невиновным, и только веские доказательства могут это изменить.

Поэтому «мы не смогли опровергнуть H_0 » никогда не означает « H_0 верна» — так же, как «невиновен» не означает «невиновен».

Три жестких правила

1. Гипотезы касаются параметров (μ , σ), а не статистики. « $H_0: \bar{x} = 4.5$ » бессмысленно.

2. Направление (одностороннее или двустороннее) выбирается до просмотра данных. Затем выбор — это χ -хакинг.

3. α также предопределено.

Вопрос аудитории


Вопрос. Мы хотим проверить утверждение, что «урожайность нового сорта выше, чем у старого». Что такое H_0 и H_1 ?

$H_0: \mu = \mu_{\text{eski}}$; $H_1: \mu > \mu_{\text{eski}}$. Утверждение находится в альтернативной гипотезе, а не в нулевой.

□-значение

Значение p — первое без формулы

Вопрос: 40% фильмов имеют рейтинг PG-13? $H_0: \pi = 0,40$, $H_1: \pi \neq 0,40$. Выборка: $n = 100$, 34 наблюдаемых значения, $\hat{\pi} = 0,34$.



Протокол — завершен

1. Предположим, что π истинно: каждый фильм имеет рейтинг PG-13 с вероятностью 0,40. 2. «Создайте» 100 фильмов, используя это правило. 3. Повторите это 20 000 раз $\rightarrow$ нулевое распределение. 4. Подсчитайте результаты как наблюдаемые или более экстремальные.

Отклонение $|34 - 40| = 6$. Отклонение, большее или равное этому значению, составляет 5232 раза из 20000: $\hat{\pi} = 5232/20000 = 0,2616$. Точное биномиальное значение равно 0,2614.



Вопрос от аудитории

Формула не используется — просто вопрос «Что, если π истинно?» задан 20000 раз.

Определение значения $\hat{p}$ — и переход к формуле

Вероятность получения наблюдаемого результата или более экстремального результата при условии, что значение $\hat{p} = p_0$ истинно: $\hat{p} = P(\text{те же или более экстремальные данные} | \hat{p} = p_0)$.

Тот же вопрос, с четырьмя методами:

Метод $\hat{p}$

Моделирование (20 000) 0,2616
Точное биномиальное 0,2614
 $\hat{p}$ -критерий 0,2207 $\hat{p}$ -критерий + поправка 0,2616

$\hat{p}$ -критерий без поправки на 15,6% ниже точного значения; С поправкой разница составляет 0,1%.

σ -критерий для пропорции

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1 - p_0)}{n}}}$$

p_0 в знаменателе, а НЕ σ — мы вычисляем мировой код, где H_0 равен



$$\sigma = 0,34 - 0,40 = -1,2247$$

0,040770

Распространенная ошибка

Наиболее распространенная техническая ошибка: вычисление стандартной ошибки из $\hat{\sigma}_0$ в тесте. $\hat{\sigma}_0$ в интервале, $\hat{p}_0$ в тесте.

Ключ ко всей теме: μ равномерно распределен при μ_0



40 000 t-тестов, в которых μ_0 истинно. μ не отдаст предпочтение ни одному значению.

Теорема. Измерено: Доля $\mu < 0,05$ составляет 0,0482 и 0,0481; доля $\mu < 0,01$ составляет 0,0100 и 0,0093.

Распространенная ошибка


Следствие: Даже если μ_0 истинно, в одном из 20 тестов будет $\mu < 0,05$.

Вопрос аудитории

Этот факт объясняет все остальное на этой неделе: почему работает μ -хакинг и почему один «значимый» результат ничего не доказывает.

Ошибки и власть

Два типа ошибок — и они взаимозаменяемы




H_0 правильно H_0 неправильно

отклонено Тип I (α) правильно ($1 - \alpha$) не
отклонено правильно Тип II (β)

Распространенная ошибка

Если уменьшить α , β увеличится ($\alpha = 36$, $\beta = 106$): $\alpha = 0,10 \rightarrow$
степень 0,912; $\alpha = 0,01 \rightarrow 0,664$; $\alpha = 0,001 \rightarrow 0,386$. Только
 n улучшает оба параметра одновременно.

Мощность: Что мы видим?



$H_0: \chi = 100, \sigma = 12, \alpha = 0.05$. Пунктирная линия — типичное значение.

Целевое значение 0,80.

Требуемое значение n для мощности 80%


$$n \geq \left(\frac{z_{1-\alpha/2} + z_{1-\beta}}{d} \right)^2, \quad d = \frac{\delta}{\sigma}$$

δ	d	n
2	0,167	283
3	0,250	126
4	0,333	71
6	0,500	32
12	1,000	8

Вопрос аудитории

Когда эффект уменьшается вдвое, он увеличивается в четыре раза — опять же, закон $\sqrt{n}$ (7-я неделя). Мощность рассчитывается ДО начала исследования.

☐-хакинг



H_0 истинно везде: обнаружение «открытия» из чистого шума

вероятность

Распространенная ошибка

m	$1 - 0,95^m$
1	0,050
5	0,226
14	0,512
20	0,642
50	0,923

В 20 тестах «открытие» более чем вероятно.
Моделирование 0,6411 (теоретическое 0,6415).



Теорема Бонферрони: α/n для каждого теста. $n = 20$: $\alpha = 0,0025$; общая ошибка остается на уровне 0,0488. Подробнее — на 11-й неделе.

Вторая и третья формы: остановка и поиск

Нарушение правила остановки

Исследователь повторяет тест после каждого нового наблюдения и останавливается, когда $p < 0,05$. $p=0$ всегда истинно.

Среднее значение является истинной ошибкой первого типа.

10 → 30	0,172
10 → 100	0,282
10 → 200	0,348

Заявленное значение 0,05 на самом деле в 3-7 раз больше.

Поиск по подгруппам

Общий тест + деление пополам по 4 незначимым знакам = 9 тестов, все на одних и тех же данных.
Моделирование (чистый шум): 0,2624 — в 5,2 раза больше заявленного значения 0,05.

Теорема 1 $-0,959 = 0,370$ НЕ является ошибкой. Эти 9 тестов не являются независимыми, и зависимость делает формулу высокооценочной. На предыдущем слайде тесты были независимыми — там формула была точно такой же.

Вопрос аудитории

Единственная защита — предварительная регистрация: гипотеза, α , β , направление и план анализа составляются до сбора данных.

■ **ЧТО ЭТО?**

Распространенная ошибка

$\square = P(\text{данные} \mid \square0), \text{ но не } P(\square0 \mid \text{данные}).$

Это в точности ошибка прокурора из 3-й недели. Чтение условной вероятности наоборот.

Граница Селлге-Байарри-Бергера (2001) дает наиболее благоприятный случай: минимальный байесовский фактор = $-\square\square\ln\square$.

$\square \min$ Байесовский фактор $P(\square0 \mid \text{данные})$

0,05	0,4072	$\geq 0,289$
0,01	0,1252	$\geq 0,111$
0,001	0,0188	$\geq 0,018$

(Начальная вероятность принимается равной 0,5.)

Теорема: вероятность того, что □0 истинно, как минимум на 29% выше, чем вероятность ложности, когда $\square = 0,05$.

И это разумная оценка. На практике она обычно намного выше.

Распространенная ошибка

Начальная уверенность важна. Если гипотеза изначально сомнительна ($P(\square\square) = 0,10$):

$\square P(\square0 \mid \text{data})$	
0,05	0,786
0,01	0,530
0,001	0,145

Неправдоподобное утверждение нельзя доказать при $\square = 0,05$.

Истинная популяция: $\mu = 35,805$, $\sigma = 37,405$ известно — следовательно, $\mu_0 : \mu = 34$; истинная разница 1,805, коэффициент Коэна $d = 0,048$ (незначимо).

Вывод

30	0.264	0.792	незначительно
100	0.483	0.629	незначительно
400	0.965	0.334	незначительно
1000	1.526	0.127	незначительно
2000	2.158	0.031	ЗНАЧИМО

Эффект не изменился — увеличилось только n . При достаточно большом n любое отклонение от нуля становится «значимым».

Существует также обратная ошибка. ГИПОТЕЗА: реальная разница составляет 15 миллионов долларов ($d = 0,40$ — большая), но $n = 10$. $z = 1,268$, $p = 0,205$, степень 0,245. (Если σ неизвестно, используется $t9$, $p = 0,237$ — всегда указывайте, какое соглашение используется.)

«Незначительно» не означает «нет разницы», это означает «мы не смогли ее увидеть».

Правило теоремы. Никогда не указывайте p отдельно. Всегда указывайте все три параметра вместе:

размер эффекта + доверительный интервал + p

Заблуждение Почему это неправильно

« $\alpha = 0,05$ — вероятность того, что H_0 истинно». $\alpha = P(\text{данные} \mid H_0)$. Обратная величина составляет не менее 0,289. Ошибка прокурора (неделя 3). « $\alpha > 0,05$ — следовательно, H_0 истинно». «Недостаточно доказательств» $\neq$ «доказательства доказаны как отсутствующие». Даже при $\alpha = 0,40$ мощность при $n = 10$ составляет всего 0,245. « α мало — эффект большой». α не измеряет величину эффекта. При $n = 2000$, $\alpha = 0,048$ также дает $\beta = 0,031$. « $\alpha = 0,049$ и $\alpha = 0,051$ радикально отличаются». 0,05 — это условность, а не закон природы. α равномерно распределен ниже H_0 ; нет скачков вокруг границы. «Вы можете выбрать лучший из нескольких тестов». Вероятность «обнаружения» из чистого шума в 20 тестах составляет 0,64. Направление и α записываются заранее. «Я буду повторять тест, пока не получу достаточно данных». Это увеличивает ошибку первого типа с 0,05 до 0,35.

«Мы доказали H_0 ». Тест никогда не доказывает H_0 . Он только отвергает или не проходит его.

Краткое
содержание

Важно помнить

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \sim t_{n-1}$$

$$z = \sqrt{n}(\hat{\mu} - \mu_0) / \hat{\sigma} \quad (\mu_0, \hat{\sigma} \text{ эмес})$$

$$n \geq \left(\frac{z_{1-\alpha/2} + z_{1-\beta}}{d} \right)^2, \quad d = \frac{\delta}{\sigma}$$

Решение: $\mu < \mu_0 \Rightarrow$ отклонено. Столь же сильное:
Находится ли μ_0 вне интервала?

В трех предложениях

1. Тест находится по другую сторону доверительного интервала. Нет новой математики, есть новое решение.

2. μ — ответ на вопрос «Насколько необычны данные, если μ_0 истинно?» Ничего больше.

3. μ равномерно распределен при μ_0 — поэтому одно малое значение μ ничего не доказывает, и его легко найти путем поиска.

Следующий шаг

На этой неделе мы работали с одной выборкой. На 11-й неделе будет две: разница между двумя группами, парные наблюдения и критерий хи-квадрат для категориальных данных. Проблема множественных сравнений также полностью рассматривается там.

Основная литература

- Cetinkaya-Rundel M., Hardin J. Introduction to Modern Statistics (IMS, 2nd ed.), Chapters 11 and 17–19 — simulation-based testing first, formula later. Open source: openintro.org/book/ims
- Newbold P., Carlson W., Thorne B. Statistics for Business and Economics (9th ed.), Chapter 9.

Обязательная литература этой недели — обе краткие

- Wasserstein R., Lazar N. (2016). The ASA statement on p -values: context, process, and purpose. The American Statistician 70(2), 129–133. — six principles, 2 pages.
- Гринленд С. и др. (2016). Статистические тесты, значения p , доверительные интервалы и мощность: руководство по неверным интерпретациям. Европейский журнал эпидемиологии 31, 337–350. — 25 неверных интерпретаций значения p , по одному абзацу для каждой.

Дополнение

- Симмонс Дж., Нельсон Л., Симонсон У. (2011). Ложноположительная психология. Психологическая наука 22(11), 1359–1366. — Статья, показывающая, как работает взлом p .
- Селлке Т., Баярри М., Бергер Дж. (2001). Калибровка значений p для проверки точных нулевых гипотез. Американский статистик 55(1), 62–71.
- Иоаннидис Дж. (2005). Почему большинство опубликованных результатов исследований ложны. PLoS Medicine 2(8), e124.