

Ташкентский международный университет ·
Факультет экономики Проверка гипотез II

Неделя 11 · Двухвыборочный парный тест и критерий хи-квадрат · Лекции 1
и 2

Ташкентский международный университет · Факультет
экономики

2025/2026 учебный
год



От одной выборки к двум

Что было сделано на 10-й неделе?

Одна выборка. Одно среднее или одна доля.
Вопрос: «Равно ли μ такому-то числу?»

И как только у вас есть μ_0 , остальное — механика: построить нулевое распределение, найти наблюдаемые данные.

Что спрашивается на 11-й неделе?

«Различаются ли две группы?»

Этот вопрос почти всегда встречается на практике: лечение и контроль, старые и новые, мужчины и женщины, вариант А и вариант В.

На этой неделе H_0 означает «две группы одинаковы». Если это так, то метка («Ужас»/«Комедия») ничего не значит — её можно спутать.

Вся эта неделя основана на одной идее.

Распространённая ошибка. И самый важный вопрос на этой неделе не статистический, а вопрос проектирования: наблюдения парные или непарные? Неправильный ответ переворачивает вывод — мы увидим это сегодня.

Лекция 1 — Тест с двумя вариантами ответа 1.
Перетасовка меток: рандомизационный тест
для двух групп.

2. Разница двух средних: t-тест Уэлча
и почему он является стандартным.

3. Парный тест: когда и почему стандартные
ошибки становятся слишком малыми.

4. Разница двух долей; для таблицы 2×2 , $\chi^2 = \chi^2$.

Лекция 2 — Категориальные данные и множественное
тестирование 5. χ^2 -тест на соответствие — с законом
Бенфорда.

6. Тест на независимость χ^2 ;
ожидаемые частоты и условия.

7. Критерий Крамера ϕ —
насколько строг вопрос после χ^2 ?

8. Множественные сравнения: Бонферрони, Холма,
FDR — перспективы 10-й недели.

Предварительные условия CLO7. Сформулируйте гипотезу, выберите подходящий тест, проведите его и интерпретируйте результаты с указанием величины эффекта, доверительного интервала и p . Блум: Применение → Анализ → Оценка. Новая часть на этой неделе — «выбор».

Смешивание этикеток


Тест рандомизации: метка под 0 не имеет смысла

Вопрос: Различаются ли бюджеты фильмов ужасов и комедий? Выборка: 15 фильмов из каждого жанра (начальное значение LCG 20261101).

Условия: $\mu_H = 19\,000$, $\sigma = 17\,747$; $\mu_C = 32\,633$, $\sigma = 20\,739$ (млн \$). Разница $\mu_{fall} = -13\,633$.

Процедура (F153)

0: метка не имеет значения. Итак, поместите 30 значений в одну ячейку → перемешайте → назовите 15 случайных значений «Ужас» → запишите разницу. Повторите 20 000 раз.



Результат

$|разница| \geq 13,633: 1277/20000 \Rightarrow p_{rand} = 0,063850$. Критерий Уэлча $\hat{\sigma} = 0,063468$ — разница всего 0,60%: два совершенно разных пути, один и тот же ответ.

При $\alpha = 15$ $\hat{\alpha} = -13,633$ $\hat{\alpha} = 0,0639$ 95 % доверительный интервал: $[-28,085; 0,819]$ — в пределах нуля

Решение: α_0 не может быть отклонен.

$SE = 1,785$, $df = 385,56$, $\hat{\alpha} = -4,327$ $\hat{\alpha} = 1,93 \times 10^{-5}$
95 % CI: $[-11,234; -4,215]$

Это не было видно при $\alpha = 15$. Это было отчетливо видно при $\alpha = 811$. «Незначимо» никогда не означает «отсутствие различий». Это в точности та же проблема мощности, что и на 10-й неделе.

Вопрос к классу: Если бы мы остановились на $\alpha = 15$ и заявили, что «жанры не различаются», какую ошибку мы бы допустили? И кто бы заметил эту ошибку?

Два независимых выбора

Разность двух средних: откуда берется стандартная ошибка

С 6-й недели $\text{Var}(\bar{x} - \bar{y}) = \text{Var}(\bar{x}) + \text{Var}(\bar{y})$ — складывать, а не вычитать:

$$SE(\bar{x}_1 - \bar{x}_2) = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Степени свободы Уэлча (F130) и статистика (F131)

$$v = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2} \right)^2}{\frac{(s_1^2/n_1)^2}{n_1-1} + \frac{(s_2^2/n_2)^2}{n_2-1}}, \quad t = \frac{\bar{x}_1 - \bar{x}_2 - \delta_0}{SE}$$

v не является целым числом — это нормально.

Интервал (F132) и эффект (F135)

$$(\bar{x}_1 - \bar{x}_2) \pm 0.1 - 0.2 SE = (\bar{x}_1 - \bar{x}_2) / 0.1$$

Урожайность пшеницы, 1992-2018 гг. (т/га)

	n	$\bar{x}$	s
Узбекистан	27	3.604815	1.179486
Казахстан	27	1.026741	0.259923

Разница: 2.578074 т/га
Коэффициент дисперсии: 20.59

Два подсчета — одинаковый, неодинаковый


SE df v

Уэлч 0.232439 28.52 7.39 $\times 10^{-12}$
Объединенный 0.232439 52 2.58 $\times 10^{-15}$

Поскольку $n_1 = 27$, $n_2 = 27$ — это в точности то же самое. Отличается только число степеней свободы — и объединенный v в 2870 раз меньше.

95 % доверительный интервал (Уэлч): [2.1023; 3.0538] · Коэф. d = 3.019.

Почему тест Уэлча — это измеряемый ответ, а не убеждение



Условия. Каждый столбец: 20 000 повторений, π_0 истинно, $\alpha = 0,05$ (пунктирная линия). Метки: $\pi_1:\pi_2$ и $\pi_1:\pi_2$.

Объединенный тест дает сбой в обоих направлениях

Дисперсия в малой группе велика: ошибка первого типа составляет 0,2143 — в 4,3 раза больше, чем обещано. Тест не выполняет своих обещаний.

Дисперсия в малой группе невелика: 0,0001 — тест почти никогда не отклоняет гипотезу, то есть теряет мощность. Это тоже ошибка, но она незаметна.

Диапазон Уэлча: [0,0459; 0,0512]

Около 0,05 во всех шести случаях. Правило: всегда Уэлча. Предварительное тестирование дисперсий для его выбора не требуется — наоборот, само предварительное тестирование создает проблему множественных сравнений (Лекция 2).

Стоп: расчет верен, условие нарушено

Скрытая ошибка в примере с пшеницей. Эти два ряда являются временными рядами. Условие независимости гласит: «каждое наблюдение независимо от другого». Независимы ли последовательные годы?

Автокорреляция с задержкой 1:
Узбекистан: предел $0,9658 \pm 0,975/\sqrt{27}$
 $= 0,3772$ Казахстан: $-0,0003$

✗ Условие нарушено в ряду по Узбекистану.

Что делать? Нарушение только в одном ряду: в Узбекистане наблюдается сильный тренд роста, в то время как урожайность в Казахстане зависит от погоды и не имеет тренда.

Нарушения в одном ряду достаточно: значение ρ недействительно в формальном смысле.

Эффект настолько велик ($d = 3,02$), что вывод почти наверняка останется неизменным — но это нельзя утверждать, основываясь на значении ρ .


Вопрос аудиторки

Этот слайд выбран намеренно. Самая распространенная ошибка в статистике — не выбор неправильной формулы, а применение правильной формулы к данным, которые не соответствуют условию. После каждого теста: «Соответствуют ли условия?»

Парный тест

Ключевой факт недели: одинаковые данные, противоположный вывод

Реальные данные по Казахстану, урожайность пшеницы и ячменя, 1992–2018 гг. Каждый год — одна пара: одинаковая почва, погода и политика. $\bar{y} = 27$ пар; $\bar{y} = -0,154889$ т/га (у ячменя выше).



95 % ДИ: $[-0.2025; -0.1073]$ — вне нулевой гипотезы

✓ **H0**
отклоняется

Анализ 2: предположение о независимости (ошибка)

Оценка разницы точно такая же: -0.154889
 $SE = 0.077458$ — в 3,34 раза больше $\bar{y} = -1.9996$, $df = 50.61$, $\bar{y} = 0.050920$ 95% CI: $[-0.3104; 0.0006]$ — внутри нулевой гипотезы

✗ **H0** не отклоняется

Вопрос аудитории

Те же числа. Та же разница. Противоположное решение. Разница заключается лишь в ответе на один вопрос: являются ли наблюдения равномерными?

Почему парное распределение работает — это факт, а не магия

Дисперсия парных разностей (F138)

$$\text{Var}(\bar{d}) = \sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2$$

Это полная форма $\text{Var}(\bar{d}-0)$ из 6-й недели ($\rho = 0$).

Проверка числами

$0.067560 + 0.094433 - 2(0.923414)(0.259923)(0.307300) = 0.014479$; Наблюдаемое значение $\sigma_d^2 = 0.014479$, разница 2.95×10^{-17} . То же самое.

Определение. При $\rho = 0.9234$ дисперсия уменьшается в 11,19 раз: парное сопоставление устраняет общий эффект года.




Условия моделирования: $n = 27$ пар, истинная разница 0,30 SD, 20 000 повторений, $\alpha = 0,05$.

Предупреждение о двустороннем характере

$\rho = 0.9$: парная мощность 0,9156 против непарной 0,0138. Обратная ситуация при $\rho = -0.5$: 0,1394 против 0,2422. Но это не выбор: если дизайн парный, парный анализ обязателен.

Какой тест? — ответ на вопрос о дизайне исследования



Распространенная ошибка

Наиболее распространенная ошибка: подсчет дважды в парных данных. 27 пар = $n = 27$, а не $n = 54$; $df = 26$.

Вопрос аудитории

Тест не выбирается после данных. Дизайн эксперимента известен до сбора данных — следовательно, сам тест известен заранее. В этом заключается идея предварительной записи на 10-й неделе.

Две акции

Разница между двумя долями: проверка от 0, промежуточная от

Реальный вопрос: фильм «Прорыв» = мировые кассовые сборы > 2,5× бюджета (правило индустрии). Отличаются ли рейтинги PG-13 и R?

полезная суммарная

PG-13 358 896 0.399554 R
409 1113 0.367475

Разница:
0.032078

Две стандартные ошибки (F141-F144)

$$\text{пбир} = \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}} = 0,381782$$

$$SE0 = \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}} = 0,021806$$

$$SEIO = \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}} = 0,021831$$

Наиболее распространенная техническая ошибка недели

The Тест предполагает, что 0 истинно ($\pi_1 = \pi_2$) — поэтому общая доля оценивается путем объединения: SE0. Доверительный интервал не предполагает 0, и каждая группа использует свой собственный.

Здесь две стандартные ошибки почти равны (разница 0,000025), но когда π_1 и π_2 сильно различаются, они расходятся.

Результат

$$z = \frac{0,032078}{0,021806} = 1,471107 \quad p = 0,141262$$

95% доверительный интервал: [-0,010710; 0,074866] — в пределах нуля

Тест и интервал приводят к одному и тому же выводу: 0 не может быть отклонено. (Бинарное правило из 10-й недели.)

$\pi_1 + \pi_2 = 2009$ — большая выборка. Большое значение n не делает разницу «существенной»; оно лишь помогает увидеть существующую разницу. Здесь не на что смотреть.

Таблица 2 × 2: $\chi^2 = \chi^2$ — не совпадение

Те же данные, два разных символа

полезно бесполезно всего

PG-13 358 538 896 R 409 704
1113

всего 767 1242 2009

Так зачем нужны оба? χ^2 -тест показывает направление (+ или −) и может быть односторонним. σ^2 никогда не бывает односторонним — возведение в квадрат теряет направление. χ^2 -тест дает доверительный интервал для разницы. σ^2

этого не делает. Поэтому предпочтительнее использовать χ^2 -тест для таблиц 2 × 2. ► χ^2 применим к таблицам большего размера, чем 2 × 2, тогда как σ^2 -тест — нет.

Разница: $4,44 \times 10^{-15}$ — точность компьютера.

F152

Для таблицы 2 × 2 σ^2 и двухсторонний χ^2 -тест — это один и тот же тест, просто записанный по-разному.

Размер эффекта — не оставляйте χ^2 без изменений

Разница: +0,032078 (абсолютная)
Относительная: +8,73% Относительный риск RR = 1,0873
Отношение шансов OR = 1,1454 (F145)

Абсолютная разница — наиболее понятная мера для пропорций. OR — наиболее вводящая в заблуждение: 1,15 не означает «на 15% больше».

Хи-квадрат

Общая форма (F146)

$$\chi^2 = \sum \text{ всех ячеек } \frac{(\text{наблюдаемое} - \text{ожидаемое})^2}{\text{ожидаемое}}$$


Каждая ячейка вносит свой вклад.

Разница только в «ожидаемом»

Подгонка (F147): из теории ожидаемых значений; $\chi^2 = \chi^2(0)$, $df = n - 1$ — (оцененные параметры).

Независимость (F148): из самих ожидаемых данных; $\chi^2 = \frac{(\text{сумма по строкам})(\text{сумма по столбцам})}{n}$, $df = (n-1)(k-1)$ (F149).

Условие Каждая ожидаемая частота ≥ 5 (не наблюдается — ожидаемая). Если нарушено: объединить категории или использовать точный тест.



Условия

Заштрихованная область: верхние 5% для $df = 8$; критическое значение $\chi^2_{0.95}(8) = 15.5073$.

Три свойства

1. $\chi^2 \geq 0$ — сумма квадратов.
2. Отклонение всегда происходит в правом хвосте: малое значение χ^2 означает «хорошее соответствие».
3. $E(\chi^2) = df$ — мы измерим это на следующем слайде.

Тест на согласованность: закон Бенфорда — один файл, два ответа

Закон Бенфорда

Однозначное число в натуральных числах, охватывающее несколько порядков величины:
 $P(\pi = \pi) = \log_{10}(1 + \pi)$


$P(\pi=1) = 0,3010$, $P(\pi=9) = 0,0458$. Используется в аудите для выявления мошенничества.

Тот же файл, тот же тест

Столбец $\chi^2(df\ 8)$

Мировой доход 8,1242 0,4214 Бюджет
18,4609 0,0180 Внутренний доход 32,3800
0,0001

Доходы стабильны. Бюджет нестабилен.



Причина не в статистике — источник данных

84,96% бюджетов являются целыми кратными 1 миллиону, 50,43% — целыми кратными 5 миллионам; всего 267 различных значений на 2467 фильмов. В мировых доходах только 1,34% являются целыми кратными 1 миллиону, количество различных значений составляет 2436.

Бюджет объявлен и округлен число; выручка — это измеренное число.

Проверка независимости: ожидаемые частоты и условия

Наблюдаемые значения: рейтинг × жанр
(2458 фильмов)

Боевик. Комедия Драма Ужасы

G 0 41 3 5 0 PG 6 246 39 106 3 PG-13 178 62 266 339
51 R 174 14 292 479 154

Исходная таблица: Условие
нарушено

$\chi^2 = 1159,667$, $df = 12$, $p < 10^{-240}$ — но наименьшая ожидаемая частота = 4,1465 (1 из 20 ячеек меньше 5). В строке G всего 49 фильмов: категория очень разреженная.

Исправление: Мы объединяем G и PG

$\chi^2 = 1141,736$, $df = 8$, наименьшее ожидаемое значение = 37,9951 — вывод не изменился, но теперь он обоснован.

Крамер $\phi(F151)$: вопрос после χ^2

$$V = \sqrt{\chi^2 / (\min(n_r, n_c) - 1)} = \sqrt{\frac{1141,736}{2458 \cdot 2}} = 0,4819$$

$\phi \approx 0,1$ слабая · 0,3 умеренная · 0,5 сильная —
здесь сильная. ϕ^2 растет с χ^2 , ϕ — нет.

Где? — остатки (F150)

χ^2 просто говорит: «есть взаимосвязь»;
где $\phi^2 = (\chi^2 - \chi^2_{\text{ind}}) / \chi^2$ показывает.

наблюдаемый остаток ячейки

G/PG × Adventure 287 +27.1019 R
× Adventure 14 -11.7287 G/PG ×
Action 6 -7.3448

Источник: семейные приключенческие фильмы.

Откуда берется распределение χ^2 ? — давайте измерим

Давайте установим для эксперимента χ^2_0 значение true: строка и столбец действительно некоррелированы. $n = 300$ наблюдений, таблица 3×5 , 20 000 повторений (LCG, начальное значение 20261400). Мы вычисляем χ^2 каждый раз.

Результат — сравнение с теорией

теория моделирования

среднее значение 8,0353, число степеней свободы = 8, дисперсия 15,6764, 2-степени свободы = 16, 95% квантиль 15,4946, $P(\chi^2 > \text{crit})$ 0,0498, $P(\chi^2 > \text{crit})$ 0,05

Почему это важно

Распределение χ^2 не падает с неба: это сумма квадратов независимых нормальных величин (неделя 5, MLT).

Степени свободы. Ответ на вопрос «сколько ячеек свободны»: когда суммы строк и столбцов записываются в таблицу 3×5 , свободными оказываются только $(3 - 1)(5 - 1) = 8$ ячеек.

Приближение — не точное

Распределение χ^2 является приближением. Оно работает только тогда, когда n велико, а ожидаемые частоты достаточно велики. Если ожидаемые частоты малы, истинное распределение дискретно, и кривая χ^2 ему не соответствует — поэтому выполняется условие $n \geq 5$. Это в точности та же проблема «нормального приближения» из 7-й недели.

Множественные сравнения

Обещание на 10-й неделе: не один, а десять тестов

Реальная проблема: 5 жанров $\Rightarrow$ все пары $= (5 \cdot 2) = 10$ тестов. Вопрос: различаются ли жанры по своей доле полезности?

жанр n доля полезности

Ужасы	210	117	0.5571
Приключения	363	167	0.4601
Боевик	360	144	0.4000
Комедия	601	227	0.3777
Драма	933	304	0.3258

Начиная с 10-й недели (F154) $\square_0$ верно везде, но $P(\text{по крайней мере один значимый}) = 1 - 0.95^{10} = 0.4013$.

То есть: даже если нет разницы, по крайней мере один из 10 тестов с вероятностью более 40% является «значимым».

Три поправки Бонферрони (F155): $\square_* = \min(\square, 1)$. Простая, консервативная. Гарантия: $\text{FWER} \leq \square$.

Холма (F156): Отсортировать $\square$; умножить на $(\square - \square + 1)$ в степени $\square$; сделать монотонным. Точно такая же гарантия, но с большей мощностью. Всегда Холм вместо Бонферрони.

Бенджамини-Хохберга (F157): умножить на $\square/\square$ в степени $\square$. Гарантирует еще кое-что: $\text{FDR} \leq \square$ (F158) — доля ложноположительных результатов среди результатов, а не «по крайней мере один ложноположительный результат».

Вопрос аудитории

Они отвечают на разные вопросы. Правильный выбор — это не вопрос «какой из них более строгий», а скорее вопрос «сколько мне будет стоить ошибка».

Исправление изменяет вывод — в десяти парах


пар $\square$ Bonf. Holm BH

Драма-Ужасы 0.000000 0.000000 0.000000 0.000000
Комедия-Ужасы 0.000006 0.000059 0.000053 0.000021
Приключения-Драма 0.000006 0.000064 0.000053 0.000021
Боевик-Ужасы 0.000281 0.002808 0.001966 0.000702

Приключения-Комедия 0.011733 0.117329 0.070397 0.019999
Боевик-Драма 0.011999 0.119992 0.070397 0.019999
Ужасы 0.025108 0.251081 0.100432 0.035869
Комедия - Драма 0.037100 0.370999 0.111300 0.046375

Боевик - Приключения 0.102937 1.000000 0.205874 0.114375
Экшн-комедия 0.491972 1.000000 0.491972 0.491972

Значимо при $\square = 0.05$: нескорректировано 8/10 · Бонферрони 4/10 · Холм 4/10 · BH 8/10




Чтение графика

BH: Найти наибольшее $\square$, для которого $\square(\square) \leq \square/\square$ — отклонить все значения до этой точки. Бонферрони: те, которые находятся ниже горизонтальной линии. Линия BH имеет наклон, поэтому она находит больше значений.

Условия. Для тех же 10 пар бюджетов: 8/10 без корректировки, 8/10 с корректировкой Бонферрони. Корректировка не является штрафом.

Что гарантируют три метода — с помощью моделирования



Условия $\pi = 20$ тестов, $\pi = 30$ в каждом, эффект 0,80 SD, 10 000 повторений. Пунктирная линия = 0,05.

$k = 5$ (т.е. 5 из 20 имеют реальный эффект):

метод FWER FDR мощность

	нескорректированный	0.5371	0.1150	0.9879	
Бонферрони	0.0367	0.0075	0.8424	Холм 0.0475	
0.0095	0.8584	BH (FDR)	0.1988	0.0377	0.9497

Три вывода 1. Методы Бонферрони и Холма обеспечивают FWER ниже 0,05, но метод Холма делает это с большей мощностью (0,8584 и 0,8424). Метод Холма всегда предпочтительнее.

2. BH не учитывает FWER (0,1988) — и это не ошибка. Он учитывает FDR: $0,0377 \leq 0,05$.

3. Без поправки: даже когда $\pi=0$ истинно везде ($\pi=0$), вероятность ложного обнаружения составляет 0,6457.

Уникальное злоупотребление χ^2 -хакингом на этой неделе проявилось в трех формах на 10-й неделе: множественное тестирование, произвольная остановка и кластеризация.

На этой неделе появляется четвертая форма: выбор теста на основе результата.

► Уэлч дал $p = 0,06 \rightarrow$ попробовать объединенный тест
► Парный тест не сработал $\rightarrow$ считать его некоррелированным
► χ^2 незначимо $\rightarrow$ объединить категории «удобно»
► Скорректированный p большой $\rightarrow$ отказаться от корректировки

Почему это особенно опасно. Каждая из этих форм кажется оправданной, если рассматривать ее по отдельности. «Дисперсии казались равными». «Категория была слишком скудной». Никто не лжет.

Но если решение принимается после того, как был получен результат, значение p теряет свой смысл — потому что оно основано на предположении об «одном заранее определенном тесте».

Защита — три привычки

1. Выбирайте тест, исходя из плана исследования, а не из результата. План исследования известен раньше, чем данные.
2. Подсчитайте и опубликуйте количество проведенных тестов — скрытые тесты наиболее вредны.
3. Покажите как нескорректированный, так и скорректированный результат. Прозрачность, а не сокрытие — вот решение.

Краткое
содержание

1-5 1. Рассмотрение парных данных как независимых. В сегодняшнем примере это привело к увеличению p с $4,3 \times 10^{-7}$ до 0,0509 — вывод был обратным.

2. Подсчет n дважды в парных данных. 27 пар = $n=27$, а не $n=54$; $df = 26$.

3. Использование одной и той же стандартной ошибки для IO и теста в тесте пропорций. Тестовое p равно единице, интервал — это собственное p каждой группы.

4. Сравнение наблюдаемой частоты с 5. Условие относится к ожидаемой частоте.

5. Попытка сделать χ^2 односторонним. Возведение в квадрат теряет направление. Если направление необходимо — G -тест.

6-10 6. « χ^2 значимо $\Rightarrow$ сильная связь». Она усиливается с $\chi^2 n$. Сила — тест Крамера ϕ .

7. « χ^2 показывает причинно-следственную связь». Он даже не показывает, в какой ячейке она находится — для этого нужны остатки.

8. Сначала проверьте дисперсии, а затем выберите тест. Это множественные сравнения. Всегда используйте тест Уэлча.

9. «Корректировка искажает результат». В примере с бюджетом корректировка оставила 8/10 как 8/10. Это влияет только на предельные результаты.

10. « $p > 0,05 \Rightarrow$ группы равны». При $n = 15$, $p = 0,064$; при $n = 811$, $p = 0,0000193$. Эффект не изменился.

Какой тест когда

Условие Тест Эффект

Две независимые группы, количество
Уэлч $\square$ Коэн $\square$

Парные наблюдения, количество Парные $\square \square$

Двухпропорциональный $\square$ -тест ($\square$ one) разница, RR, OR

Одна категориальная, $\square^2$
соответствует теории —

Две категориальные $\square^2$ независимость Крамер $\square$

Условия сомнительны, $\square$ мало Рандомизация
является разницей само по себе

В трех предложениях

1. Дизайн выбирает тест, а не данные. Парные или независимые — этот вопрос должен быть известен до вычисления ответа.

2. $\square^2$ — одна идея ($\sum(\square - \square)^2/\square$), две «ожидаемые». И это говорит только о наличии связи; сила — $\square$, а остатки показывают разницу.

3. Если вы проводите несколько тестов, вам необходимо внести корректировки — и какие именно корректировки вам нужно внести, зависит от вопроса «сколько мне будет стоить ошибка», а не от статистики.

Следующие шаги

На этой неделе мы сравнивали группы. На 12-й неделе мы моделируем форму связи между переменными: простая линейная регрессия. Крамер ответил на вопрос «насколько сильна» переменная V — регрессия отвечает на вопрос «какого рода».

Основная литература

►Cetinkaya-Rundel M., Hardin J. Introduction to Modern Statistics (IMS, 2nd ed.), Chapters 20–23 (краткое изложение для двухвыборочных и категориальных данных). Открытый исходный код: openintro.org/book/ims ►Newbold P., Carlson W., Thorne B. Statistics for Business and Economics (9th ed.), Chapter 10 and 11.1–11.3. ►Heumann C., Schomaker M., Shalabh. Introduction to Statistics and Data Analysis, Chapter 10 (t-tests).

Обязательное чтение на этой неделе

►Делакр М., Лейкенс Д., Лейс К. (2017). Почему психологи должны по умолчанию использовать t-тест Уэлча вместо t-теста Стьюдента. *Международный обзор социальной психологии* 30(1), 92–101. — источник сегодняшней симуляции. ►Бенджамини И., Хохберг И. (1995). Контроль частоты ложных обнаружений. *Журнал Королевского статистического общества B* 57(1), 289–300. — Статья, породившая идею FDR (первые 4 страницы).

Дополнение

►Холм С. (1979). Простая процедура множественного тестирования с последовательным отклонением. *Scandinavian Journal of Statistics* 6(2), 65–70.
►Нигрини М. (2012). Закон Бенфорда: Применение в судебно-бухгалтерской экспертизе, аудите и выявлении мошенничества. Wiley. ►Вассерштейн Р., Лазар Н. (2016). Заявление ASA о значениях p — с 10-й недели, по-прежнему актуально.