

Ташкентский международный университет ·
Факультет экономики · Линейная регрессия

Неделя 12 · Метод наименьших квадратов, остатки и линейная регрессия ·
Лекции 1 и 2

Ташкентский международный университет · Факультет
экономики

2025/2026 учебный
год



Что мы сделали до сих пор

Неделя 6: r — сила и направление связи. Неделя 11: r^2 Крамера — сила категориальной связи.

Оба числа одинаковы. Оба отвечают на вопрос «насколько».

$r = 0,83$ не отвечает ни на один из этих вопросов.

Регрессия — ФОРМА зависимости

Вместо r используются два числа: наклон и точка пересечения с осью Y. Вместе они образуют линию — то есть, конкретный ответ для каждого x .

А вместе с линией появляется нечто новое: остатки. Половина этой недели посвящена остаткам — потому что это единственное, что показывает, где модель не работает.

Распространенная ошибка

На этой неделе нет выводов. t-критерий для наклона, доверительные интервалы и интервалы прогнозирования будут на 13-й неделе. Сегодня речь пойдет только о построении линии, ее чтении и о том, можно ли ей доверять.

Лекция 1 — Построение прямой 1. Метод наименьших квадратов: что минимизируется и почему?

2. Ручной расчет $\hat{\beta}_1$ и $\hat{\beta}_0$ на реальных данных; соотношение $\hat{\beta}_1 = \frac{\text{cov}(x,y)}{\text{var}(x)}$.

3. Остаток и его два тождества.

4. Что означает R^2 — и почему R^2 полезнее его.

Лекция 2 — Вера в прямую 5. Условия прямой, каждое из которых нарушается на примере из реальной жизни.

6. Влияние рычага, остаток и расстояние Кука — три других понятия.

7. Квартет Анскомба (из 6-й недели), теперь с остатками.

8. Регрессия к среднему значению — измеренное.

9. Экстраполяция: когда модель дает бессмысленный ответ.

Условия CLO8. Опишите взаимосвязь между двумя переменными с помощью линейной модели, интерпретируйте результаты, проверьте условия модели и укажите ее пределы. Bloom: Применение → Анализ → Оценка.

Метод наименьших квадратов

Что минимизируется — и почему?

Модель (F159)

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

β — множество простых чисел (неизвестно), b — выборочная оценка. Разница между греческой и латинской буквами не изменилась с 9-й недели.

Критерий (F160)

$$\min_{\beta_0, \beta_1} \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2$$

Решение (F161–F163):

$$b_1 = \frac{S_{xy}}{S_{xx}}, \quad b_0 = \bar{y} - b_1 \bar{x}$$

F162 — Переход к 6-й неделе

$b_1 = r \cdot s_y / s_x$ Наклон —
единичная форма корреляции.

Почему квадраты? Три причины, все три обоснованы.

1. Квадрат теряет знак — положительные и отрицательные отклонения не компенсируют друг друга.
2. Решение находится в замкнутой форме: приравнивание производной к нулю дает два линейных уравнения. Такой формулы для абсолютного значения не существует.
3. Если ε имеет нормальное распределение, метод наименьших квадратов совпадает с оценкой максимального доверия (неделя 9).


И признание: квадрат придает слишком большой вес большим отклонениям, поэтому метод наименьших квадратов нестабилен для выбросов (мы увидим это в разделе E). Минимизация абсолютного значения более стабильна, но она вычислительно сложна. Этот выбор сделан для удобства и должен быть указан именно так.

Казахстан, картофель, 2010-2018 гг.

x = год - 2010, y = урожайность (т/га), n = 9

год	x	y	y^2	xy
2010	0	14,319	15,5373	-1,2183
2011	1	16,718	16,1253	+0,5927
2012	2	16,593	16,7134	-0,1204
2013	3	18,152	17,3014	+0,8506
2014	4	18,425	17,8894	+0,5356
2015	5	18,550	18,4775	+0,0725
2016	6	19,038	19,0655	-0,0275
2017	7	19,416	19,6535	-0,2375
2018	8	19,794	20,2416	-0,4476

Условия: $\sum x = 4$, $\sum y = 17,889444$, $\sum y^2 = 60$, $\sum xy = 35,282000$
 $\bar{y} = 23,870096$, $\bar{x} = 0,588033$, $\bar{y} = 15,537311$, $\bar{x} = 0,932289$



Модель и ее интерпретация

$\hat{y} = 15,537311 + 0,588033 \cdot x$; $\sum (x - \bar{x})^2 = 60$ для $n = 0..8$.

b_1 : средняя годовая урожайность увеличилась на 0,5880 т/га. b_0 : значение модели в 2010 году составило 15,5373 т/га ($x = 0$ здесь имеет смысл — но не всегда!).

$\sum \text{ост} = -1,78 \times 10^{-14}$ (F166), $\sum \text{ост}^2 = -6,75 \times 10^{-14}$ (F167) — это не совпадение, это сами уравнения метода наименьших квадратов. Прямая проходит через $(\bar{x}, \bar{y})$ (F181).

2 и

Три суммы (F168-F171)

$SST = \sum (y_i - \bar{y})^2$ общее отклонение

$SSR = \sum (\hat{y}_i - \bar{y})^2$, объясняемое моделью

$SSE = \sum (y_i - \hat{y}_i)^2$ остаток

$SST = SSR + SSE$ — тождество

В нашем примере: $23,870096 = 20,746992 + 3,123104$; разница $7,11 \times 10^{-15}$.

R^2 (F172-F173)

$$R^2 = \frac{SSR}{SST} = 0,869162$$

В простой регрессии $R^2 = R^2$ (разница $1,11 \times 10^{-16}$). «86,9% изменчивости y обусловлено x ».

R^2 (F174-F175) — и почему это важно

$$s_e = \sqrt{\frac{SSE}{n-2}} = \sqrt{\frac{3,123104}{7}} = 0,667950$$

Единица измерения t/га — то же, что и y . $\bar{y} = 1,727357$; модель уменьшила стандартную ошибку на 61,33%.

$n-2$: были оценены два параметра.


Две модели, одинаковое значение R^2 , разная точность

картофель ~год R^2 (т/га)

Узбекистан	0,969364	1,502218
Казахстан	0,901928	1,208462

Разница в R^2 составляет всего 0,067435, но R^2 отличается в 1,2431 раза — и именно R^2 дает ошибку прогнозирования. R^2 — насколько модель использовала x ; s_e — ошибка прогнозирования. Только s_e отвечает на вопрос «Насколько точно я делаю прогноз?». Всегда указывайте оба параметра.

Одна культура, пять стран: диапазон R² от 0,00 до 0,93



страна β_1 β_2 β_3

Таджикистан	0,10340	0,9262	0,2362
Узбекистан	0,13486	0,8237	0,5051
Казахстан	0,01411	0,1857	0,2392
Туркменистан	-0,04259	0,1750	0,7485
Кыргызстан	-0,00189	0,0029	0,2825


Три вопроса к классу

1. В Кыргызстане $\beta_2 = 0.0029$. Означает ли это, что «модель плохая» или «роста нет»? (Последнее — и это ЦЕННЫЙ результат.)
2. В Туркменистане $\beta_1 < 0$. Снизилась ли производительность? (Модель говорит об этом — но $\beta_2 = 0.175$, слишком шумно.)
3. В Таджикистане β_2 самое высокое значение. Значит ли это, что сельское хозяйство там наиболее стабильно? (Нет — речь идет о β_2 TREND.)


Остатки

График остатков выявляет ОШИБКУ в данных

выручка



остатки



Условия

$\hat{y} = 2467 \cdot x - 0,705390 + 2,726829 \cdot x^2 = 0,489295 \cdot x^2 = 104,246435$ млн долл. Красные точки — это прямая линия ниже.

Что представляет собой красная линия?

31 фильм имел мировые кассовые сборы, равные нулю, и все 31 из них имели нулевые кассовые сборы на внутреннем рынке. Самый крупный из них — «Аквамен» (2018), бюджет 160 миллионов долларов, 0 кассовых сборов. Это невозможно.

Таким образом, ноль — это не «отсутствие дохода», а «отсутствие данных». Это было обнаружено с помощью графика остатков, а не статистического теста.

А теперь честная часть

Мы их удаляем: $\hat{y} = 2,726829 \rightarrow 2,739510$ — изменение всего на 0,4650%. 31 из 2467 не сильно изменил результат.

Но поправка все еще УСЛОВНАЯ — в следующий раз $\Delta = 30$, и тогда будет достигнута одна такая точка (раздел E).

ЛИНИЯ: четыре условия, четыре вопроса

Условия и инструмент их проверки

Инструмент проверки условий

L Линейность $\hat{\beta}$ против $\hat{\beta}$ — нет формы

I Независимость $\hat{\beta}$ против порядка;
запаздывание-1; метод Дарбина-Уотсона

N Нормальность QQ-график (не тест!)

E Равная дисперсия $\hat{\beta}$ против $\hat{\beta}$ — нет веера

ЗАЧЕМ нужны условия — понятный ответ

Для вычисления β_0 и β_1 условия не требуются. Метод наименьших квадратов всегда дает число.

Для $\hat{\beta}$, прогнозирования и вывода на 13-й неделе (t-тест, доверительный интервал) необходимы определенные условия. Если условие нарушено, наклон все равно рассчитывается — просто ему нельзя доверять.

Порядок важности — не равен

1. **L** — наиболее важный. Если он нарушен, модель отвечает на неправильный вопрос.

2. **I** — очень важный. Если он нарушен, $\hat{\beta}$ и все значения $\hat{\beta}$ неверны (обычно очень малы).

3. **E** — важный. Если он нарушен, оценка является разумной, но оценка точности неверна.

4. **N** — наименее важный. Если $\hat{\beta}$ велико, то центральная предельная теорема (неделя 7) делает это ненужным.

Распространенная ошибка

Студенты обычно делают наоборот: они проверяют нормальность распределения и не проверяют линейность. Самое важное условие проще всего увидеть — просто посмотрите на диаграмму.

Условие I: Возвращено предупреждение за 11-ю неделю



Узбекистан Казахстан

ρ^2 0.8237 0.1857 lag-1 corr.
0.789704 -0.293276 предел
0.377195 0.377195 DW 0.387164
2.365583 условие НАРУШЕНО
выполнено

Что это значит?

Предел $\pm 0.975/\sqrt{27}$. Дурбин-Уотсон (F180) независим ≈ 2 ; теоретическое $2(1 - \rho) = 0.420592$ — наблюдаемое 0.387164.


В серии данных по Узбекистану положительное отклонение в одном году сохраняется и в следующем. Таким образом, 27 наблюдений не являются 27 независимыми данными.

Условия. Та же модель (пшеница ~год), те же годы. Остатки слева образуют волны; остатки справа — случайные скачки.

Вопрос аудитории

На 11-й неделе ТОЧНО такая же серия нарушила условие независимости — тогда в двухвыборочном тесте, сегодня в регрессии. Это самая часто повторяющаяся идея курса: условие важнее формулы, и один и тот же дефект данных повторяется в каждом методе.

Условие Е: логарифм не теряет свою веерообразную форму — он инвертируется



Условия

$$n = 2\,436 \cdot b_1 = 1,148411 \cdot R^2 = 0,466680 \cdot s_e = 0,695197$$

F183 — интерпретация логарифмической модели

$\eta_1 = 1,1484 \Rightarrow$ если бюджет увеличивается на 1 процент, выручка увеличивается в среднем на 1,1484 процента (эластичность). $\eta_1 > 1$: выручка растет быстрее, чем бюджет.

остаточное стандартное отклонение модели, соотношение кварталов бюджета

исходная модель 34.01 58.78 75.76 178.20 5.2395
log-log 1.0196 0.7302 0.5156 0.3706 2.7513

Это не ожидаемый результат

В исходной модели стандартное отклонение увеличивается с бюджетом (в 5,24 раза). В логарифмической модели стандартное отклонение уменьшается с бюджетом (в 2,75 раза).

То есть логарифм не потерял свой веер — он перевернулся вверх дном и почти вдвое уменьшил свою степень. Условие Е нарушено в обеих моделях.

Причина экономическая: фильм стоимостью 1 миллион долларов может собрать как 0,1 миллиона, так и 100 миллионов — относительный результат очень изменчив. Фильм с большим бюджетом относительно более предсказуем.

Вопрос от аудитории

Правило: вращение — не волшебная палочка. Это меняет то, какие три параметра являются шумовыми, но не устраняет шум. График остатков перерисовывается после каждого преобразования. И значение R^2 логарифмической модели нельзя сравнивать со значением R^2 исходной модели — они объясняют разные значения y .

**Точки
соприкосновения**

Рычаг, остаток, расстояние Кука — три других параметра


Три определения

$\text{stud}^2 = \frac{1}{n-2} \sum (e_i^2)$, $\text{stud}^2 = \frac{1}{n-2} \sum (e_i^2)$ — насколько далеко вдоль x (независимо от y) · stud^2 — насколько далеко от линии · stud^2 — насколько смещается линия без точки. Предел равен $\frac{4}{n}$.

Только третий фактор — «воздействие».

Большое кредитное плечо + малый остаток $\Rightarrow$ отсутствие воздействия. Малое кредитное плечо + большой остаток $\Rightarrow$ малое воздействие. Большое кредитное плечо + большой остаток $\Rightarrow$ риск. $\sum h_i^2 = 2$ всегда; среднее $h = \frac{2}{n}$.

Таджикистан, картофель




Две диаграммы совершенно разные

Рычаг имеет U-образную форму: крайние годы имеют наибольший рычаг — 1992, $h = 0,140212$, и это определяется без учета y . Расстояние Кука резко возрастает за один год: 1995, $\text{stud}^2 = 0,724102$, предел $\frac{4}{27} = 0,148148$.

1992 год имеет наибольший рычаг, но расстояние Кука составляет всего 0,002065. Значение $h = 0,098087$ для 1995 года — немного выше среднего ($\frac{2}{n} = 0,074074$). Впечатляет не эффект рычага, а стандартизированный остаток = 3,649147.

Два важных момента, один и тот же диагноз, ДВА РАЗНЫХ правильных ответа



Условия в Таджикистане: 1994 = 11 167, 1995 = 27 900, 1996 = 10 770 т/га. Более чем в два раза выше, чем у соседей.

Картофель в Таджикистане, 1995 год

b1 (т/га в год) 0,468036 0,564322 R2
0,460020 0,712811 sé 4,104564
2,863862

Изменение b1 +20,5723 %

Две точки, два разных решения

Таджикистан, 1995 год. Период гражданской войны (1992–1997). Механизм, объясняющий двойной скачок и падение значения в следующем году, отсутствует. Вероятно, это ошибка в источнике. ⇒ Проверьте источник; исправьте, если подтвердится, в противном случае удалите и запишите.


Рис в Казахстане, 1992 год ($h = 0,140212$, наибольшее влияние и наибольший эффект). 1992 год = 3,992, затем падает до 2,193 к 1995 году и медленно восстанавливается. Это реальная история: крах советской ирригационной системы. ⇒ Сохранить точку, изменить модель.

Вопрос аудитории

Статистическая этика. Удаление выброса «для улучшения результата» — это форма «р-хакинга» в регрессионном анализе из 11-й недели. Правило одно: решение принимается на основе источника данных, а не результата — и сообщаются оба варианта.

**Анскомб и возвращение к среднему
значению**

Квартет Анскомба — с 6-й недели, теперь с остатками




	b_0	b_1	R^2	s_e
I	3.0001	0.5001	0.6665	1.2366
II	3.0009	0.5000	0.6662	1.2372
III	3.0025	0.4997	0.6663	1.2363
IV	3.0017	0.4999	0.6667	1.2357

диапазон b_1 0.0004 · Диапазон s_e 0.0005

IV — предельное состояние

$\hat{h} = 19$ Влияние точки $h = 1,0000$ равно равно 1; остаток равен $-1,78 \times 10^{-15}$, что равно равно 0. Линия проходит через неё, поэтому расстояние Кука не определено (0/0) — не «большое», но бессмысленное. Без этой точки $\hat{h} = 0$; $\hat{h}$ не изменяется в оставшихся 10 наблюдениях, поэтому наклон не может быть рассчитан. Все $\hat{b}_1$ получено из одного наблюдения — $\hat{b}_1 = 0,6667$ этого не указывает.

Возврат к среднему значению: измеренное, а не указанное



Условия: 25 строк (5 стран × 5 культур), остатки от тренда стандартизованы. $n = 650$ пар.

Гальтон (1886) — и почему это не биология

$r = 0,464954$ — положительное значение. То есть, ожидается, что за хорошим годом последует еще один хороший год.

Однако экстремальные значения возвращаются к среднему значению.

группа n текущая следующая

$z > 1$	96	+1,5817	+0,6719
$z < -1$	83	-1,5269	-0,7200

Теория говорит число ЗАРАНЕЕ (F182)


$E(\text{следующее} + 1 | \text{текущее}) = r \times \text{текущее} = 0,464954 \times 1,5817 = 0,7354$ Наблюдаемое значение: 0,6719. Разница 0,0635.

Возвращение к среднему значению не означает, что «верхняя группа стала хуже». Это просто следствие $r < 1$. Для этого нет причин.

Распространенная ошибка

Ложный вывод об «эффективности». Если «программа помощи» применяется к 20% наихудших результатов, и они улучшают свои показатели в следующем году, это не доказывает, что программа сработала. В таблице выше показано «улучшение» от -1,5269 до -0,7200 даже без какой-либо программы. Это самое убедительное доказательство в пользу идеи контрольной группы на первой неделе.

Экстраполяция: когда модель дает бессмысленный ответ



год x статус

2014 17,8894 данные в 2018
20,2416 данные в 2025
24,3578 экстраполяция 2050
39,0586 экстраполяция 2100
68,4603 бессмысленный

Модель не предупреждает

Модель говорит 68,46 т/га за 2100 год. Сегодняшний мировой рекорд составляет ≈ 45 –50 т/га.

Модель дала бессмысленный ответ и не показала никакого знака — потому что это просто прямая линия. $R^2 = 0,869162$ также этого не демонстрирует.

Правило: модель действительна только в интервале, где наблюдаются данные. Здесь $x \in [0; 8]$.

Второй тип экстраполяции

Модель была построена для казахстанского картофеля. Если мы применим ее к Узбекистану: RMSE = 12,514502 т/га, а собственная R^2 модели равна 0,667950.

То есть, в 18,7357 раз хуже. Интервал x был правильным — объект был неправильным.

Краткое
содержание

1-5 1. « R^2 высокое $\Rightarrow$ модель верна». Во всех четырех уравнениях Анскомба $R^2 = 0,666$; только одно из них является допустимым.

2. « R^2 низкое $\Rightarrow$ модель плохая». В Кыргызстане результат $R^2 = 0,0029$: отсутствие тренда.

3. Путаница между R^2 и $sé$. R^2 безразмерная величина и не дает точности прогнозирования. Точность — это $sé$.

4. Всегда интерпретировать b_0 . Если $\bar{x} = 0$ не находится в диапазоне данных, $\bar{x}_0$ — это просто часть линии.

5. «Наклон показывает причинно-следственную связь». Нет. Это вся тема 13-й недели.

6-10 6. Считайте $\bar{x} \sim \bar{y}$ и $\bar{y} \sim \bar{x}$ одним и тем же $\bar{x}_1$. $\bar{x}_1 = \bar{x}_2$, не равно. Две разные линии.

7. Называйте большой рычаг «влиятельным». Наибольший рычаг в Таджикистане был в 1992/2018 годах, а влиятельная точка — 1995 год.

8. Автоматически удаляйте выбросы. Решение принимается исходя из происхождения данных, а не из результата.

9. Проверьте нормальность распределения, не проверяйте линейность. Самое важное условие легче всего увидеть — см. диаграмму.

10. Экстраполяция. $\hat{y}(2100) = 68,46$ т/га. Модель не предупреждает — вы предупреждаете.

Процедура регрессионного анализа

1. Диаграмма рассеяния. Линейная ли она? Есть ли выбросы? 2. Постройте прямую: β_1 , β_0 . 3. Интерпретируйте β_1 в единицах. 4. Соедините β_2 и β_1 . 5. Диаграмма остатков: L и E. 6. Остатки по порядку: I. QQ: N. 7. Расстояние Кука: есть ли влиятельная точка? 8. Прогнозирование — только в диапазоне данных. 9. Что не доказано — скажите.

В трех предложениях

1. Построение прямой — самая простая часть. Формулы всегда дают число, даже если данные недействительны.
2. Ценность модели заключается в остатках, а не в β_2 . Они показывают, где модель не работает — и иногда обнаруживают ошибки в данных (31 фильм).
3. Каждая модель ограничена интервалом и объектом. Линия не знает этого предела.

Следующий шаг

Сегодня мы вычислили $\beta_1 = 0,5880$. Но эта выборочная оценка — если мы возьмем еще 9 лет, она даст другое число.

На 13-й неделе: стандартная ошибка для β_1 , t-критерий и доверительный интервал; интервал прогнозирования; и наконец — корреляция и причинно-следственная связь, парадокс Симпсона, смешение факторов.

Основная литература

►Cetinkaya-Rundel M., Hardin J. Introduction to Modern Statistics (IMS, 2nd ed.), Chapter 7 (linear regression) and Chapter 24. Open source: openintro.org/book/ims ►Newbold P., Carlson W., Thorne B. Statistics for Business and Economics (9th ed.), 11.1–11.5. ►Heumann C., Schomaker M., Shalabh. Introduction to Statistics and Data Analysis, Chapter 11.

Обязательная литература этой недели — обе краткие

►Anscombe F. (1973). Graphs in statistical analysis. Американский статистик 27(1), 17–21. — 5 страниц, и самая цитируемая работа в истории статистики. ►Галтон Ф. (1886). Регрессия к посредственности в наследственном росте. Журнал Антропологического института 15, 246–263. — Именно отсюда происходит слово «регрессия»; первых 6 страниц достаточно.

Дополнение

►Кук Р. Д. (1977). Выявление влиятельных наблюдений в линейной регрессии. Технометрика 19(1), 15–18. ►Дурбин Дж., Уотсон Г. (1951). Проверка на серийную корреляцию в регрессии методом наименьших квадратов II. Биометрика 38(1/2), 159–177. ►Канеман Д. (2011). Мышление, быстрое и медленное, глава 17 («Регрессия к среднему») — пример похвалы и критики пилотов.