

Ташкентский международный университет · Факультет экономики Выводы в регрессионном анализе; корреляция и причинно-следственная связь

Неделя 13 · Тест на наклон, два интервала и три ловушки · Лекции 1 и 2

Ташкентский международный университет · Факультет
экономики

2025/2026 учебный
год



Как закончилась 12-я неделя?

$\hat{\beta}_1 = 0,588033$ — Урожайность картофеля в Казахстане увеличивалась в среднем на это количество т/год каждый год.

Но это выборочная оценка. Если мы возьмем еще девять лет, получится другое число. Насколько другое?

Структура недели

Лекция 1 — первый вопрос. Немного новой математики: SE($\hat{\beta}_1$) и t-критерий, оба из недель 9–10.

Лекция 2 — второй вопрос. Новой математики не так много, но здесь собраны самые сложные идеи всего курса.

Два вопроса сегодняшнего дня — и они разные

1. «Насколько я доверяю $\hat{\beta}_1$?» $\Rightarrow$ стандартная ошибка, t-критерий, доверительный интервал.
2. «Имеет ли $\hat{\beta}_1$ причинно-следственную связь?» $\Rightarrow$ это совершенно другой вопрос, и одной лишь статистики на него ответить нельзя.

Распространенная ошибка

Предупреждение. После Лекции 1 у вас есть наклон $\hat{\beta} < 0,001$, и он выглядит очень надежным. Лекция 2 показывает, как легко сделать неверный вывод даже в этом случае.

Малый $\hat{\beta}$ означает «не совпадение». Это не означает «причинно-следственная связь».

Лекция 1 — Насколько мы уверены в прямой 1. $SE(\beta_1)$ и три фактора, от которых она зависит.

2. t-критерий и доверительные интервалы для наклона.

3. Критерий наклона = корреляционный критерий = ANOVA $\square$.

4. Доверительный интервал и интервал прогнозирования — разница.

5. Тестирование с помощью бутстрапа и рандомизации.

6. Какова может быть ошибка вывода, если условие нарушено.

Лекция 2 — корреляция и причинно-следственная связь 7. Смешивающий фактор: три условия, два кандидата.

8. Парадокс Симпсона — две опубликованные действительные таблицы.

9. Смещение отбора и ограничение диапазона.

10. Коллайдер — случай, когда стратификация вредит.

11. Почему причинно-следственные диаграммы и рандомизация работают.

Условия CLO7 и CLO8. Правильно вывести и интерпретировать наклон; объяснить пределы причинно-следственного вывода из наблюдательных данных. Блум: Анализ $\rightarrow$ Оценка.

**Вывод относительно
склона**

SE(β1) — и третий фактор часто забывают

Стандартная ошибка (F187)

$$SE(\beta_1) = \frac{s}{\sqrt{S_{xx}}}, \quad S_{xx} = \sum (x_i - \bar{x})^2$$

Три способа уменьшить его: 1. β маленький — модель хорошо подходит. 2. β большой — он растет с σ². 3. σ² рассеянный — и это почти всегда забывают.

В нашей модели

β = 0.667950, σ² = 60 SE(β1) =
0.667950/√60 = 0.086232
SE(β0) = 0.410547 (F187)

Мы измеряем третий фактор: то же β, то же σ²

Значения β (β = 9) Соотношение SE σ²

0, 1, ..., 8 (наша)	60.00	1.0000	только
3-5 (сжатый)	4.00	3.8730	только 0 и 8
(ребра)	128.00	0.6847	

Сжатие β увеличивает стандартную ошибку в 3,87 раза. Но округление до ребер уменьшает ее до 0,68 — при том же β, том же σ².

Распространенная ошибка

Это проблема проектирования, а не вычислений: вы выбираете, где взять β, при проектировании эксперимента.

Но есть два ограничения. (а) Расширение β приводит к экстраполяции (неделя 12). (б) Если вы берете только ребра, вы не можете проверить линейность — между двумя точками всегда будет прямая линия.

Тест, интервал — и три теста — это один вопрос

Тест наклона (F185-F186)

$$t = \frac{\beta_1 - \beta_1(0)}{SE(\beta_1)}, df = n - 2$$

Для $H_0: \beta_1 = 0$: $t = 0.588033$
 $= 6.819199$

$p = 0.00024883 \Rightarrow$ отклонено.

$t_{0.975(7)} = 2.364624$ 95 % CI: [0.384127; 0.791940] —
ноль за пределами.

**Интерпретация условий: урожайность
увеличилась в среднем на 0,5880 т/га в год;
точность $\pm 0,2039$ т/га. Всегда указывайте
интервал — это правило действует с 9-й
недели.**

Три теста, один вопрос

Статистика F

Наклон $t = 6.81919887$ 0.00024883 Корреляция (F188) $t =$
6.81919887 0.00024883 ANOVA (F189) $F = 46.50147329$
0.00024883


$F = 46.50147300$; разница с t равна 0,00. Разница между
наклоном и корреляцией t равна 0,00 (одно и то же число).

«Нужен ли наклон?» и «Нужен ли коэффициент корреляции?» — это один и тот
же вопрос, написанный на трех разных языках.

Распространённая ошибка

Примечание: это верно только для моделей с одной объясняющей переменной. В
многомерной регрессии F проверяет всю модель, а t проверяет один коэффициент — и
они легко могут дать противоречивые результаты.

Два интервала: где находится линия и где находится следующее наблюдение



Условия Внутри (синий) — 95% доверительный интервал для среднего значения отклика; снаружи (желтый) — интервал прогнозирования. Оба расширяются по мере удаления от $\bar{x}$: формы песочных часов.

Разница в одном члене (F190 и F192)

$$SE_{\text{mean}} = \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}}$$

$$SE_{\text{predict}} = \sqrt{1 + \frac{(x^* - \bar{x})^2}{S_{xx}}}$$

Дополнение 1 — собственная случайность нового наблюдения; Знание линии не исключает её.

При $x^* = \bar{x}$, $\bar{x} =$


Среднее значение $SE = 0,222650$, предсказанное значение $SE = 0,704082$, отношение = 3,162278 раз.

При $x^* = 0$ (выброс): стандартные ошибки равны 0,410547 и 0,784000; IO [14,5665; 16,5081], BO [13,6834; 17,3913].

Распространенная ошибка

Наиболее распространенная ошибка — это указание среднего интервала при прогнозировании урожайности за один год: он примерно в три раза уже и, следовательно, кажется в три раза более надежным.

☐☐: один стремится к нулю, другой — нет



☐ SEmean SEforecast

9	0,222650	0,704082
45	0,099572	0,675331
900	0,022265	0,668321
9000	0,007041	0,667988

Самое важное предложение этой недели может быть таким:

Имея бесконечное количество данных, мы прекрасно знаем линию — SEmean → 0.

Но мы все еще не можем с уверенностью сказать, каким будет урожай в следующем году: SEforecast → ☐☐ = 0,667950 и не опустится ниже этого значения.


Почему это не недостаток модели?

☐☐ — не недостаток модели, а совпадение обстоятельств. Погода, рынки, политика — их нет в ☐, и никакой размер выборки не может их исключить.


«Чем больше данных у нас есть, тем точнее наши прогнозы» — это отчасти верно: линия определена, но прогноз почти полностью неопределен.

Два независимых теста: бутстрап и рандомизация

Бутстрап (F194)



Рандомизация (F195)



Условия: 20 000 повторений, начальное значение 20261301.
Стандартная ошибка бутстрапа = 0,112797 против формулы 0,086232 (отношение 1,3081). Процентиль Ю [0,373266; 0,793133] · $\hat{\rho}$ -Ю [0,384127; 0,791940].


Условия

$\hat{\rho}=0$: $\hat{\rho}$ и $\hat{\rho}^*$ не связаны $\Rightarrow \hat{\rho}$ может быть смешанным. Случаи, когда $|\hat{\rho}^*| \geq 0,588033$: $1/20\,000$, $\hat{\rho} = 0,000050$. $\hat{\rho}$ -тест $\hat{\rho} = 0,000249$ — тот же вывод.

Вопрос аудитории

Здесь бутстрап не является альтернативой t-интервалу — $n = 9$ слишком мало, а формула стандартной ошибки бутстрапа в 1,31 раза больше стандартной ошибки. Это проверка: если три совершенно разных пути приводят к одному и тому же выводу, то вывод не следует из выбора формулы.

Какова будет погрешность вывода, если условие нарушено — давайте измерим



Условия $\rho = 0$ истинно (истинный наклон равен нулю), $n = 27$, остатки AR(1), 20 000 повторений. $\rho = 0,0527$; $\rho = 0,90,6207$ — то есть, в большинстве случаев ложноположительный результат.

Ряд узбекской пшеницы на 12-й неделе

Остатки с задержкой 1 = 0,789704 (граница 0,377195) — условие нарушено.

Эффективный размер выборки (F199): $n_{\text{eff}} = n \cdot (1 - \rho)$

$$= 27 \cdot \frac{0,210296}{1,789704} =$$

3,172590. 27 лет приблизительно равны 3,17 независимым наблюдениям.

Коэффициент коррекции стандартной ошибки $\sqrt{(1 + \rho)/(1 - \rho)} = 2,917258$. Простая стандартная ошибка = 0,012480 → скорректированная 0,036408.

Изменился ли вывод?

Простой пример: $\rho = 10,806238$, $\rho = 6,556 \times 10^{-11} \Rightarrow$ отклоняем. Исправленный пример: $\rho = 3,704245$, $df = 1,1726$, $\rho = 0,138445 \Rightarrow$ не отклоняем.

В этом примере вывод ИЗМЕНИЛСЯ. Нарушаемое условие не нарушает $\rho = 1$, а нарушает веру в него — и здесь она полностью разрушена.

Корреляция и причинно-следственная связь

Существует связь. Что дальше?

Если β и γ связаны, существует как минимум пять объяснений (F201)



1. $\beta \rightarrow \gamma$ — необходимый нам ответ
2. $\gamma \rightarrow \beta$ — обратная причинно-следственная связь
3. $\beta \leftarrow \gamma \rightarrow \beta$ — мешающий фактор
4. систематическая ошибка отбора — на кого мы смотрим
5. совпадение

Значение β теряет только свой ПЯТЫЙ параметр

$\beta = 0,00024883$ — это означает «не совпадение».

Три других объяснения остаются неизменными, независимо от того, насколько мало β . Если увеличить β , γ уменьшится, и мешающий фактор останется на этом уровне.

Три структуры, одна точка зрения



Вопрос аудитории

В данных все три выглядят одинаково: третья переменная связана как с β , так и с γ . Только знания предметной области могут определить, какая именно это переменная — сами данные никогда.

Фактор, искажающий результаты: два правдоподобных кандидата, два разных результата

Вопрос и необработанный ответ

Отличаются ли фильмы с рейтингом PG-13 и R по прибыльности? («Прибыльность» = мировые сборы > 2,5× бюджета.)

Доля прибыли от рейтинга

PG-13 358 892 0,401345 R 409 1097 0,372835

Разница в необработанных данных = 0,028510 (в пользу PG-13).

КАНДИДАТ 1: бюджет — правдоподобно, но НЕ

Средний бюджет: PG-13 43,78 млн долларов, R 23,85 млн долларов (разница 83,58%).

✓ бюджет ~ рейтинг: $\beta = 0,280993$, $\sigma = 2,06 \times 10^{-37}$

✗ бюджет ~ полезность: $\beta = 0,041462$, $\sigma = 0,0645$ — не значимо

Второе условие не выполняется ⇒ бюджет не является искажающим фактором. В любом случае, если рассматривать это послойно, разница составляет 0,028510 → 0,034713 — изменение незначительное, как и ожидалось.

КАНДИДАТ 2: жанр — ДА

✓ жанр ~ рейтинг: $\beta_2 = 85,3574$, $\sigma = 1,27 \times 10^{-17}$

✓ жанр ~ полезность: $\beta_2 = 41,2280$, $\sigma = 2,41 \times 10^{-8}$

жанр не является следствием рейтинга (жанр указан в сценарии, рейтинг — когда фильм готов)

жанр PG-13 R разница

Боевик 0,4181 0,4012 +0,0169 Приключения 0,4194 0,2857 +0,1336 Комедия 0,3849 0,3819 +0,0030 Драма 0,3620 0,3067 +0,0553 Ужасы 0,6667 0,5395 +0,1272

Взвешенная (F197) разница = 0,044433 против исходной 0,028510 ⇒ +55,85%.

Неожиданное направление — и это реально

Обычно коррекция уменьшает разницу. Вот она: фильмы с рейтингом R более полезны в низких жанрах (драма), а PG-13 — в высоких. Жанр маскировал разницу — «отрицательная предвзятость».

Парадокс Симпсона — во-первых: есть ли он в наших данных?

Определение (F198)

Если общий вывод перевернут на всех уровнях, то это парадокс Симпсона.

Наиболее экстремальное проявление мешающего фактора: коррекция не уменьшает результат, а переворачивает его.

Систематический поиск

Мы проверили тройки в обоих реальных наборах данных (□, □, группа):

Проверено троек: 104. Найдено полных переворотов: 0

В наших данных нет парадокса Симпсона.

И это также результат

Парадокс Симпсона возможен, но не обязателен. Поскольку в учебниках он встречается так часто, кажется, что это явление происходит на каждом шаге — на самом деле это не так.

Правильный вывод: «без стратификации невозможно определить», а не «всегда наоборот».

Поэтому ниже приведена ОПУБЛИКОВАННАЯ реальная таблица

Обе таблицы действительны, обе с указанием источника:

1. Берклиевский университет, 1973 — прием в аспирантуру. Бикель, Хаммел, О'Коннелл, Science 187(4175), 398–404 (1975). Частичная обратная интерпретация и тонкая интерпретация.

2. Исследование лечения камней в почках, 1986 г. Чариг и др., BMJ 292(6524), 879–882. Полное обратное изменение.

Беркли, 1973: самый известный реальный пример


Факультет Мужской Женский кто arz.
процент arz. процент выше

A	825	62,06 %	108	82,41 %	ЖЕНЩИНЫ
B	560	63,04 %	25	68,00 %	ЖЕНЩИНЫ
C	325	36,92 %	593	34,06 %	мужчины D
417	33,09 %	375	34,93 %	ЖЕНЩИНЫ E	
191	27,75 %	393	23,92 %	мужчины F	
373	5,90 %	341	7,04 %	ЖЕНЩИНЫ	

ИТОГО 2691 44,52 % 1835 30,35 % МУЖЧИНЫ

Распространенная ошибка

Женщины занимают более высокие позиции в четырех из шести факультетов; Общий результат составляет 14,1645 процентных пунктов в пользу мужчин.



Причина

Корреляция (процент приема, процент женщин) = $-0,785794$: Женщины чаще подавали заявки на факультеты с более низким процентом приема. Факультет является искажающим фактором: он влияет как на то, кто куда подает заявки, так и на процент приема.

Важное замечание

Это не означает, что «дискриминации нет»: общее число не указывает на дискриминацию на уровне факультетов, а лишь на нее. Почему женщины подают заявки на эти факультеты — это отдельный вопрос, и он не отражен в данных.

Почечный камень, 1986: полное удаление

А (открытая операция) В (чрескожная операция) ст/общий процент ст/общий процент

Малый камень 81/87 93,1 % 234/270 86,7 % Большой камень 192/263 73,0 % 55/80 68,8 %

ИТОГО 273/350 78,0 % 289/350 82,6 %

Теорема

А лучше в обеих группах (+6,4 и +4,3 процентных пункта); В лучше в целом (+4,6). Ни одно из чисел не неверно — оба верны.

Причина: Размер камня является искажающим фактором

Метод А использовался для удаления крупных камней в 75,14% случаев. Метод В использовался для удаления мелких камней в 77,14% случаев.

Удаление крупных камней, как правило, сложнее: показатель успеха 72,01% против 88,24% для мелких камней.


Врачи выбирали метод А в тяжелых случаях — поэтому А выглядит «плохо».

У этой ловушки есть название

Искажение результатов из-за показаний — самая распространенная ловушка в медицине.

Какой ответ правильный? Ответ является составным: размер камня определяет, какой метод необходим пациенту. Общее число не принадлежит никому.

Смещение выборки: рассматриваются только победители



Термины. Красный — 10% самых высокооплачиваемых. Пунктирная линия — регрессия, скорректированная только с учетом этих показателей.

выбор ☐ 1 ☐

все фильмы	2436	2.739510	0.700195
лучшие 50%	1218	2.408297	0.591148
лучшие 25%	609	1.942877	0.468804
лучшие 10%	244	1.085625	0.246692
лучшие 5%	122	0.240133	0.055240

Причина не изменилась


Наклон 2.7395 → 1.0856 (0.3963 раза), корреляция 0.7002 → 0.2467.

Изменился только состав участников исследования. Это ограничение диапазона.

Вопрос аудитории

«Мы изучили наиболее успешные компании и обнаружили общую характеристику» — именно такой подход к исследованиям допускает подобную ошибку. Неуспешные компании могут обладать той же характеристикой; они не включены в выборку.

Коллайдер: случай, когда наложение слоев ВРЕДНО



Условия Красная пунктирная линия — определение «прибыльности»: выручка = 2,5 × бюджет. Синяя — прибыльная, желтая — убыточная.

«Прибыльность» — результат ОБЕИХ переменных

прибыльная = [выручка > 2,5 × бюджет] — зависит как от бюджета, так и от выручки. Поэтому это коллайдер.

группа ☐ 1 ☐

все	2436	2.739510	0.700195	полезные	959
	3.875674	0.824915	бесполезные	1477	1.538807
	0.864880				

Корреляция в обеих частях сильнее, чем общая (0.8249 и 0.8649 против 0.7002) — это признак коллайдера.

Почему — геометрия видна

Разделительная линия наклонная. Каждая половина облака, пересеченная наклонной линией, простирается параллельно этой линии — поэтому связь в обеих половинах усиливается.

Вопрос аудитории

Правило: наложение слоев необходимо для отвлекающего фактора; вредно для фактора, создающего коллайдер. И в данных они выглядят одинаково.

Почему рандомизация работает — давайте измерим это

Эксперимент (гипотетический мир, мы знаем правду)

$X \rightarrow Y$ и $X \rightarrow Z$, но эффект $X \rightarrow Z$ равен нулю.

$N = 200, 20\,000$ повторений, начальное значение 20261500.

Два случая: (а) наблюдение — Z естественным образом зависит от X ; (б) эксперимент — Z назначается случайным образом.

Теорема

метод средней оценки |оценка| > 0.1

наблюдение 0.640649 1.000000 случайный эксперимент
0.000130 0.155800

Истинный эффект = 0. Наблюдательное исследование всегда даст ненулевой результат около 0.6406.

Почему эксперименты работают

Рандомизация обрезает Z от X . Ось $X \rightarrow Z$ исчезает, поэтому путь $X \leftarrow Z \rightarrow Y$ исчезает.

И самое главное: это работает, даже если мы не измеряем Z . Стратификация корректирует только известные и измеряемые факторы; рандомизация корректирует все.

Но эксперименты не всегда работают

Производительность нельзя назначать случайным образом. Вредные последствия для людей нельзя рандомизировать.

Именно поэтому необходимы наблюдательные исследования — и именно поэтому главная цель этой недели — знать о подводных камнях.

Предварительные условия. Можно делать причинно-следственные выводы из наблюдательных данных, но для этого требуются дополнительные гипотезы, которые берутся из полевых исследований, а не из данных. (Недели 14-15 и последующие курсы.)

Краткое
содержание

1-5 1. « $p < 0,001 \Rightarrow$ причина». p не учитывает случайность — один из пяти случаев.

2. Вместо интервала прогнозирования приводится средний интервал. В нашем примере он в 3,16 раза уже.

3. «Больше информации $\Rightarrow$ более точное прогнозирование». Они определяют линию; прогнозирование останавливается на $\hat{y}$.

4. Мысль о том, что $SE(\hat{y})$ зависит только от x . Дисперсия y так же важна.

5. Использование простой SE даже при нарушении условия. $r = 0,79$, $n = 27$, что на самом деле означает $r_{\text{eff}} = 3,17$.

6-10 6. «Парадокс Симпсона всегда случается». Мы проверили 104 тройки и не нашли ни одной.

7. «Исправьте» любую третью переменную. Бюджет не был искажающим фактором; исправление коллайдера навредило бы.

8. «Исправление всегда уменьшает эффект». Жанр увеличил его на 55,85%.

9. Изучайте только успешных. В 10% лучших $\hat{y}$ упал с 0,70 до 0,25.

10. «Данные Беркли доказывают отсутствие дискриминации». Это показывает только, откуда взялось общее число.

Что следует сообщить

1. Единицы b_1 с 2. $SE(b_1)$ и 95% доверительным интервалом 3. t , df и p 4. R^2 и $se(\text{неделя } 12)$ 5. Какое условие L-I-N-E было протестировано и результат 6. Прогноз — с указанием интервала 7. Какие факторы, влияющие на результат, были учтены 8. Что не было доказано и почему

В трех предложениях

1. $SE(b_1)$ зависит от трех факторов, а третий — дисперсия x — является вопросом проектирования, а не расчета.

2. Знание линии и знание следующего наблюдения — это две разные вещи, и разница между ними никогда не исчезает.

3. Малый p отвергает объяснение, но только если оно таковое. Чтобы исключить остальные четыре, вам нужен план исследования — и если план исследования основан на наблюдениях, вы должны указать, что вы не доказали.

Следующий шаг

Неделя 14: Лабораторная работа по проекту данных — полный анализ от вопроса до заключения, рекурсивный отчет и описание использования ИИ.

Проект 12 — это результат этой недели: что не было доказано и почему.

Основная литература

►Cetinkaya-Rundel M., Hardin J. Introduction to Modern Statistics (IMS, 2nd ed.), chapters 24–26 (inference in regression). Open source: openintro.org/book/ims ►Newbold P., Carlson W., Thorne B. Statistics for Business and Economics (9th ed.), 11.4–11.8.

Обязательная литература этой недели — обе краткие

►Bickel P., Hammel E., O'Connell J. (1975). Sex bias in graduate admissions: data from Berkeley. *Science* 187(4175), 398–404. — 7 pages; Оригинал сегодняшней таблицы. ►Чариг К., Уэбб Д., Пейн С., Уикхэм Дж. (1986). Сравнение методов лечения почечных камней... *British Medical Journal* 292(6524), 879–882. — 4 страницы.

Дополнение

►Симпсон Э. Х. (1951). Интерпретация взаимодействия в таблицах сопряженности. *JRSS B* 13(2), 238–241. ►Эрнан М., Робинс Дж. Причинно-следственная связь: Что если. — открытый доступ; Глава 6 (причинно-следственные диаграммы), актуальная для этой недели. ►Каннингем С. Причинно-следственная связь: Микстейп. — открытый доступ; Глава 3 (направленные графы) с примерами коллайдеров. ►Розенбаум П. (2017). Наблюдение и эксперимент. — Введение в логику наблюдательных исследований.