

TOSHKENT XALQARO UNIVERSITETI · IQTISODIYOT FAKULTETI

Semestrlik loyiha — 5-bosqich: Ma'lumotni tozalash

STAT201 · 5-hafta · Uzluksiz taqsimotlar va normal taqsimot

CLO1, CLO3 · Blum: Qo'llash–Baholash · Formativ baholash · 2025/2026

Eng muhim jumla — birinchi bo'lib o'qing

Tozalash — ma'lumotni “yaxshiroq” qilish emas. Tozalash — bu *qarorlar ketma-ketligi*, va har bir qaror natijani o'zgartiradi. Shu sababli bu bosqichning mahsuloti tozalangan fayl emas, **tozalash bayonnomasi**: nima qilindi, nima uchun, va natija qanday o'zgardi.

Oltin qoida: *hech narsa jimgina o'chirilmaydi.* Har bir olib tashlangan qator, har bir to'ldirilgan bo'shliq va har bir tuzatilgan qiymat bayonnomada bitta satr sifatida qayd etiladi. Bayonnomasiz tozalash — takrorlanmaydigan tahlil.

1. Loyihaning yo'l xaritasi: qayerdamiz

4-bosqichda ma'lumot pasportini topshirdingiz va fayl qo'lingizga tegdi. **Endi fayl bilan ishlash boshlanadi.** 6-bosqich (tavsifiy tahlil), 7-bosqich (model tanlash) va 10-bosqich (regressiya) to'g'ridan-to'g'ri shu haftada qabul qilgan qarorlaringizga tayanadi.

№	Bosqich	Muddat	Topshiriladigan natija
3	O'zgaruvchilarni aniqlash	4-hafta	O'zgaruvchilar jadvali
4	Ma'lumot olish — 1-nazorat nuqtasi	5-hafta	Ma'lumot pasporti + fayl
5	Tozalash va sifat bayonnomasi	6-hafta	Kod + tozalash bayonnomasi + sifat hisoboti
6	Tavsifiy tahlil va vizualizatsiya	7-hafta	4 ta grafik + talqin
7	Ehtimollik modeli va tanlanmaning sifati	9-hafta	Model tanlovi va <i>shart tekshiruvi</i>
8	Nuqtaviy va intervalli baholash	10-hafta	Ishonch oraliqlari

Loyiha yakuniy bahoning **10%**ini tashkil qiladi. 5-bosqich *formativ*: ball qo'yilmaydi, yozma fikr-mulohaza beriladi. Ammo bu bosqichning mahsuloti yakuniy hisobotning **Ma'lumot va usul** bo'limiga deyarli o'zgarishsiz ko'chadi va o'sha yerda *ball bilan* baholanadi.

2. Nima uchun aynan bu haftada

Bu hafta siz normal modelning **markazda aniq, quyruqda noto'g'ri** bo'lishini ko'rdingiz. Tozalash qarorlari ham xuddi shunday ishlaydi — ammo teskari tomondan:

Tozalash qarori	Markazga ta'siri	Quyruqqa ta'siri
Bo'sh qiymatni o'rtacha bilan to'ldirish	O'rtacha o'zgarmaydi — ta'sir sezilmaydi	Dispersiya kamayadi , quyruq siqiladi, 99-protsentil pastga siljiydi
“Chetlashgan” kuzatuvlarni olib tashlash	Median deyarli o'zgarmaydi	Quyruq yo'q qilinadi — aynan qaror qabul qilinadigan joy
Dublikatlarni olib tashlash	<i>n</i> kamayadi, markaz odatda barqaror	Takrorlangan ekstremal qiymat quyruqni sun'iy <i>og'irlashtirgan</i> bo'lishi mumkin
Nol va manfiy qiymatlarni chiqarish	Sezilmasligi mumkin	Chap quyruq kesiladi; logarifm “ishlab ketadi”, ammo <i>ma'lumot o'zgargani</i> uchun

Bosqichning markaziy g'oyasi

Tozalash qarorlari **markazni deyarli o'zgartirmaydi, quyruqni esa tubdan o'zgartiradi.** Va qaror — 5-haftada ko'rganingizdek — quyruqda yashaydi. Shu sababli sifat hisobotida *o'rtacha oldin va keyin* kifoya qilmaydi: 95- va 99-protsentil hamda qiyshilik ham ko'rsatilishi shart.

3. Nimani topshirasiz

Topshirish shartlari

- **D1 — Tozalash kodi:** .R / .Rmd / .ipynb. Kod *xom* fayldan boshlanadi va *tozalangan* faylni yozadi. Xom fayl **hech qachon** qayta yozilmaydi.
- **D2 — Tozalash bayonnomasi** (6-bo'limdagi jadval, har bir qaror uchun bitta satr).
- **D3 — Sifat hisoboti:** oldin/keyin jadvali (7-bo'lim) + 250–400 so'zlik izoh.
- **D4 — Nazorat ro'yxati** (8-bo'lim), to'ldirilgan.
- **D5 — Tozalangan fayl:** UTF-8, .csv. 25 MB dan katta bo'lsa — namuna (1 000 qator) + havola.
- **Muddat: 6-hafta, juma, 23:59** — Moodle. Fayl nomi: STAT201_L5_Familiya_Ism.zip.
- **Baholanmaydi**, ammo *majburiy*. Yozma fikr-mulohaza 5 kun ichida qaytariladi.
- **Sun'iy intellekt:** kod yozish va tahrir uchun foydalanish mumkin. **Tozalash qarorlarini SI' ga qildirish taqiqlanadi** — aynan shu qism kelgusida baholanadi.

4. Ifloslikning besh turi

Tur	Qanday aniqlanadi	Odatiy tuzoq
1. Yetishmayotgan qiymatlar	Har bir ustun bo'yicha NA soni va ulushi; NA lar <i>qaysi qatorlarda</i> to'planganini tekshirish	NA har doim NA deb yozilmaydi: –99, 0, “yo'q”, bo'sh satr, “n/a” — ularni <i>avval</i> NA ga aylantirib
2. Chetlashgan kuzatuvlar	Quti diagrammasi, IQR qoidasi, z-baho, saralangan ro'yxatning boshi va oxiri	Chetlashgan kuzatuv ≠ xato. Uni olib tashlash — <i>qaror</i> ; avtomatik amal emas
3. Dublikatlar	To'liq takroriy qatorlar; <i>kalit</i> bo'yicha takror (masalan mamlakat + yil)	To'liq bir xil bo'lmagan dublikat: bir xil kalit, turli qiymat — qaysi birini saqlash <i>qaror</i> talab qiladi
4. Tur va format xatolari	Ustun turi (chr yoki dbl); sana formati; o'nli ajratgich; kodlash	Son matn sifatida saqlangan (“1 200”, “1,5”, “12%”); sana ikki xil formatda; UTF-8 emas
5. Nomuvofiq toifa va birliklar	unique() bo'yicha barcha toifa nomlari; birlik ustunlari; masshtab	“Toshkent”, “toshkent”, “Toshkent” — uch xil toifa; mln va mlrd aralashgan; tutuq belgisi turlicha yozilgan

O'zbek yozuvidagi tutuq belgisi — eng ko'p uchraydigan format tuzog'i

Bitta toifa nomi uch xil belgi bilan yozilishi mumkin: 0'zbekiston (U+02BB, *to'g'ri*), 0'zbekiston (ASCII apostrof), 0'zbekiston (U+2019 tipografik apostrof). Kompyuter uchun bular **uch xil toifa**.

Ikkinchi tuzoq: LC_CTYPE=C lokalida R kod ichidagi o'zbekcha satrni CSV dagi qiymat bilan *teng emas* deb hisoblashi mumkin — va *hech qanday xato bermasdan* bo'sh jadval qaytaradi.

Qoida (2-haftadan): toifa nomlarini kod ichida literal yozmang. Ularni unique() orqali fayldan oling va *pozitsiya* bo'yicha tanlang. Tozalash bosqichida belgilarni birxillashtirib va buni bayonnomaga yozing.

5. Har bir tur bo'yicha qaror qabul qilish

5.1. Yetishmayotgan qiymatlar. Avval nima uchun yetishmayotganini so'rang:

Mexanizm	Ma'nosi	Maqbul qaror
Tasodifiy (MCAR)	Yo'qolish boshqa hech narsa bilan bog'liq emas	Qatorni olib tashlash xavfsiz (ulush kichik bo'lsa)
Shartli tasodifiy (MAR)	Yo'qolish <i>boshqa</i> ustunga bog'liq (masalan kichik davlatlarda hisobot yo'q)	Olib tashlash siljish kiritadi; bayroq ustuni qo'shing
Tasodifiy emas (MNAR)	Yo'qolish <i>o'z qiymatiga</i> bog'liq (yuqori daromadlar ko'rsatilmaydi)	Eng xavfli holat; to'liq tan oling va cheklovlariga yozing

O'rtacha bilan to'ldirish — ehtiyot bo'ling. $\bar{x}$ bilan to'ldirish o'rtachani saqlaydi, ammo *dispersiyan* kamaytiradi: m ta qiymat to'ldirilsa, s^2 taxminan $\frac{n-m-1}{n-1}$ koeffitsiyentga qisqaradi. Natijada 95- va 99-protsentil ichkariga siljiydi — ya'ni *quyruq*

buziladi. Bu haftaning mavzusi shuni aytadi: qaror quyruqda yashaydi. **Agar to'ldirsangiz, dispersiyaga ta'sirini o'lchang va yozing.**

5.2. Chetlashgan kuzatuvlar. Uch savolga ketma-ket javob bering:

1. **Bu xatomi?** Manbaga qayting: 250 o'rniga 2500 yozilganmi? Birlik boshqami? Agar *isbotlangan xato* bo'lsa — tuzating (yo'qotmang) va bayonnomaga yozing.
2. **Bu boshqa jarayonmi?** Masalan inqiroz yili, urush, qurg'oqchilik. Bunday kuzatuv *haqiqiy* — uni olib tashlash tahlilni buzadi. Uni *belgilang* (bayroq ustuni) va tahlilni ikki marta bajaring.
3. **Bu shunchaki katta qiymatmi?** O'ngga qiyshiq taqsimotda katta qiymatlar *normal holat*. Ularni olib tashlash — taqsimotni sun'iy ravishda normalga aylantirish.

Qoidalarining chegarasi. IQR qoidasi ($Q_1 - 1,5 \text{ IQR}$, $Q_3 + 1,5 \text{ IQR}$) simmetrik taqsimot uchun mo'ljallangan; kuchli o'ngga qiyshiq ma'lumotda u *sog'lom* kuzatuvlarni ham belgilaydi. $|z| > 3$ qoidasi esa $\bar{x}$ va s ga tayanadi — ular chetlashgan kuzatuvning o'zidan ta'sirlanadi. **Har ikki qoida ham signal, hukm emas.**

5.3. Dublikatlar. Ikki bosqichda tekshiring: (i) to'liq takroriy qatorlar; (ii) *kalit* bo'yicha takror (kuzatuv birligini aniqlaydigan ustunlar to'plami). Ikkinchisi muhimroq: bir xil kalit, turli qiymat — bu ma'lumot manbasidagi ziddiyat. Qaysi birini saqlaganingizni va *nima uchun* (oxirgi yangilangan? to'liqroq?) yozing.

5.4. Tur va format. Har bir ustunning turini oshkora tekshiring. Sonli ustun matn sifatida o'qilgan bo'lsa, sabab odatda: bo'shliq ("1 200"), o'nli vergul ("1,5"), foiz belgisi, valyuta belgisi yoki "—" bo'sh qiymat o'rnida. **Avtomatik aylantirishga tayanmang** — avval nima sababdan matn bo'lganini aniqlang.

5.5. Toifa va birliklar. `unique()` ni har bir kategorik ustunda bajaring va *barcha* qiymatlarni ko'zdan kechiring. Boshi/oxiridagi bo'shliqlarni olib tashlang, katta-kichik harfni birxillashtiring, tutuq belgisini bir shaklga keltiring. Birliklarni bitta masshtabga keltiring va **ustun nomiga birlikni yozing** (`byudjet mln_usd`).

6. Tozalash bayonnomasi (shablon)

Har bir qaror uchun **bitta satr**. Bayonnoma kod bilan mos kelishi shart: har bir satrga kodda bitta blok to'g'ri keladi.

Nº	Muammo turi	Qayerda	Qaror va sababi	Ta'sir qilgan qator	Qaytarib bo'ladimi	Kod satri
1	Yetishmayotgan qiymat	daromad	–99 qiymati NA ga aylantirildi; kodlash kitobida "ma'lumot yo'q"	34	ha	12–14
2						
3						
4						
5						

Birinchi satr — namuna, uni o'z qaroringiz bilan almashtiring. Bayonnomada kamida **beshta** satr bo'lishi kutiladi. Agar ma'lumotingiz haqiqatan toza bo'lsa, buni ham *tekshiruv natijasi* sifatida yozing: "dublikat izlandi — topilmadi" ham bitta satr.

7. Sifat hisoboti: oldin va keyin

Ko'rsatkich	Oldin	Keyin	Izoh (nima uchun o'zgardi)
Qatorlar soni n			
Yo'qotilgan qatorlar ulushi			
Yetishmayotgan qiymatlar soni			
O'rtacha $\bar{x}$			
Median			
Standart og'ish s			
Qiyshqlik			
95-protsentil			
99-protsentil			
Minimum / maksimum			

Hisobotda javob berilishi shart bo'lgan uch savol

- (1) Qaysi ko'rsatkich *eng ko'p* o'zgardi — markaziy ko'rsatkichmi yoki quyruq ko'rsatkichimi? Nima uchun?
- (2) Yo'qotilgan qatorlar *tasodifiy* taqsimlanganmi? Ular qaysi guruh, yil yoki toifada to'plangan? (Agar to'plangan bo'lsa — bu **siljish** manbai va cheklavlarga yoziladi.)
- (3) Agar bitta qarorni *teskarisiga* o'zgartirsangiz (masalan chetlashgan kuzatuvlarni saqlasangiz), 99-protsentil qanchaga o'zgaradi? *Bitta* son bering — bu sizning tahlilingizning tozalashga sezgirligi.

8. Nazorat ro'yxati (to'ldiring va topshiring)

✓	Bajarilgan ish
☐	Xom fayl <i>o'zgarishsiz</i> saqlangan; tozalash alohida faylga yozadi
☐	Kod xom fayldan boshlanib, tozalangan faylni yozadi (bir marta ishga tushirish yetarli)
☐	Har bir ustunning turi tekshirilgan va kerakli joyda aylantirilgan
☐	Yashirin NA kodlari (−99, 0, “yo'q”, bo'sh satr) izlangan va aylantirilgan
☐	Har bir ustun bo'yicha NA soni va <i>ulushi</i> hisoblangan
☐	NA lar qaysi guruhlarda to'plangani tekshirilgan
☐	To'liq dublikatlar tekshirilgan
☐	Kalit bo'yicha dublikatlar tekshirilgan
☐	Har bir kategorik ustunda <code>unique()</code> bajarilgan va ro'yxat ko'zdan kechirilgan
☐	Tutuq belgisi (U+02BB / U+02BC) birxillashtirilgan
☐	Boshi/oxiridagi bo'shliqlar olib tashlangan
☐	Birliklar bitta masshtabga keltirilgan va ustun nomiga yozilgan
☐	Sana ustunlari bitta formatga keltirilgan
☐	Chetlashgan kuzatuvlar <i>belgilangan</i> , avtomatik o'chirilmagan
☐	Har bir chetlashgan kuzatuv uchun uch savolga javob berilgan (xatomi / boshqa jarayonmi / katta qiymatmi)
☐	Fizik jihatdan imkonsiz qiymatlar tekshirilgan (manfiy yosh, > 100 % ulush)
☐	Tozalash bayonnomasida kamida 5 satr bor
☐	Sifat hisoboti jadvali to'liq to'ldirilgan
☐	Uch savolga (7-bo'lim) yozma javob berilgan
☐	Tozalangan fayl UTF-8 da saqlangan
☐	Kod <i>qaytadan</i> ishga tushirilib, natija bir xil chiqqani tekshirilgan

9. Formativ rubrika (ball qo'yilmaydi — fikr-mulohaza beriladi)

Mezon	Kuchli	Rivojlanmoqda	Yetarli emas
Muammolarni aniqlash	Beshala tur ham tizimli tekshirilgan; yashirin NA kodlari topilgan; kalit bo'yicha dublikat qarang	Asosiy turlar tekshirilgan, biri yoki ikkitasi o'tkazib yuborilgan	Faqat NA qarang; toifa va tur tekshirilmagan
Qarorlarning asosiligi	Har bir qaror sababi bilan; chetlashgan kuzatuvlar uchun uch savolga javob; MCAR/MAR/MNAR muhokamasi	Qarorlar bor, sabablar qisman	“Chetlashgan kuzatuvlarni o'chirdim” — sababsiz
Bayonnoma	≥ 5 satr; kod satrlari bilan bog'langan; qaytariladigan bo'lgani ko'rsatilgan	Satrlar bor, ammo kod bilan bog'lanmagan	Bayonnoma yo'q yoki umumiy tavsif
Sifat hisoboti	Barcha ko'rsatkichlar; quyruq ko'rsatkichlari alohida ; uch savolga javob; sezgirlik soni berilgan	Markaziy ko'rsatkichlar bor, quyruq yo'q	Faqat <i>n</i> oldin/keyin
Takrorlanuvchanlik	Xom fayl saqlangan; kod bir marta ishga tushirilib to'liq natija beradi; qayta ishga tushirilgan	Kod ishlaydi, ammo qo'lda qadamlar bor	Fayl qo'lda tahrirlangan; kod yo'q
Halollik	Yo'qotilgan ma'lumot ulushi va uning mumkin bo'lgan siljishi oshkora aytilgan	Yo'qotish aytilgan, siljish muhokama qilinmagan	Yo'qotish yashirilgan yoki hisobga olinmagan

10. Talabalar ko'p uchratadigan xatolar

Xato	Nima uchun noto'g'ri	To'g'ri yo'l
Faylni Excel'da qo'lda tahrirlash	Qadam takrorlanmaydi va hech kim (jumladan siz) nima o'zgarganini bilmaydi	Har bir o'zgarish kodda; xom fayl tegilmaydi
Chetlashgan kuzatuvlarni avtomatik o'chirish	Ular ko'pincha <i>eng qimmatli</i> kuzatuvlar; quyruq yo'qoladi, qaror buziladi	Belgilang, uch savolga javob bering, tahlilni ikki marta bajaring
Bo'shliqlarni o'rtacha bilan to'ldirish va bu haqda yozmaslik	Dispersiya kamayadi, 99-protsentil ichkariga siljiydi	To'ldirsangiz — ta'sirni o'lchang va bayonnomaga yozing
NA faqat NA deb yoziladi deb hisoblash	−99, 0, “yo'q”, bo'sh satr — hammasi yashirin NA	Kodlash kitobini o'qing; noodatiy qiymatlarni sanang
Toifalarni ko'zdan kechirmaslik	“Toshkent” va “toshkent” — ikki xil toifa; guruhlash natijasi buziladi	Har bir kategorik ustunda <code>unique()</code>
Toifa nomini kod ichida literal yozish	Lokal tuzog'i: taqqoslash <i>jimgina</i> bo'sh natija beradi	<code>unique()</code> dan olib, pozitsiya bo'yicha tanlash
“Ma'lumotim toza” deb tekshirmaslik	Tozalik — tekshiruv natijasi, taxmin emas	Tekshiruvni bajaring va <i>natijasini</i> bayonnomaga yozing
Yo'qotilgan qatorlar ulushini aytmaslik	30 % qator yo'qolgan tahlil — boshqa bosh to'plam haqidagi tahlil	Ulushni yozing va yo'qotish tasodifiy bo'lganini tekshiring

11. Namunaviy bayonnoma satrlari

Zaif: “Chetlashgan kuzatuvlarni olib tashladim.”

Kuchli: “daromad ustunida $Q_3 + 3 \text{ IQR}$ dan yuqori 6 ta qiymat belgilandi. Manbaga qaytib tekshirildi: 4 tasi haqiqiy (yirik korxonalar), 2 tasi birlik xatosi (mlrd o'rniga mln). Ikkitasi tuzatildi, to'rttasi *saqlandi* va yirik bayrogi qo'shildi. Tahlil bayroq bilan va bayroqsiz ikki marta bajariladi (kod: 45–58-satrlar).”

Zaif: “Bo'sh kataklarni to'ldirdim.”

Kuchli: “hosildorlik ustunida 12 ta (4,4 %) qiymat yo'q; ular 1993–1995 yillarga to'plangan — demak yo'qolish tasodifiy emas (MAR). To'ldirish *bajarilmadi*; o'sha qatorlar saqlanib qoldi va tahlilda NA sifatida chiqariladi. Bu qaror cheklovlarga yozildi (kod: 22–27-satrlar).”

Zaif: “Dublikatlarni o'chirdim.”

Kuchli: “Kalit (mamlakat, yil) bo'yicha 3 ta takror topildi; uchalasida ham qiymat *har xil* edi. Manbaning yangilanish sanasi bo'yicha oxirgi yozuv saqlandi; farq qiymatlari alohida faylga yozib qo'yildi (ziddiyatlar.csv). Kod: 31–40-satrlar.”

12. Takrorlanuvchanlik va akademik halollik

- **Xom fayl daxlsiz.** U alohida papkada (data/xom/) saqlanadi va hech qachon qayta yozilmaydi. Tozalangan fayl — data/toza/.
- **Bir marta ishga tushirish qoidasi.** Kodni yangi seansda to'liq ishga tushiring: natija bir xil chiqishi shart. Chiqmasa — qadam kodda emas, qo'lda bajarilgan.
- **Qaytarilish.** Har bir qaror uchun “qaytarib bo'ladimi?” ustuni to'ldiriladi. Qaytarib bo'lmaydigan qaror (masalan qatorni butunlay o'chirish) alohida asoslanadi.
- **SI siyosati.** Kod yozdirish va xatolarni topish — ruxsat. **Qaysi qatorni o'chirish, qaysi qiymatni to'ldirish haqidagi qarorni SI ga qildirish taqiqlanadi;** model ma'lumotingizni ko'rmaydi va kontekstni bilmaydi. Foydalanish W05-si-topshiriqlari dagi shakl bo'yicha oshkor qilinadi.
- **Ma'lumot halolligi.** Yetishmayotgan qiymatni “taxmin qilib” yozish — ma'lumotni soxtalashtirish. To'ldirish faqat oshkora usul bilan va bayonnomada qayd etilgan holda bajariladi.

Aloqador materiallar. W05-lab-R.Rmd / W05-lab-Python.ipynb (3- va 4-topshiriqlar: chetlashgan kuzatuvlar quyruqqa qanday ta'sir qiladi) · W05-keys.tex (markaz va quyruq) · 1-hafta materiallari (barqarorlik, IQR, quti diagrammasi) · Wickham & Grolemund, *R for Data Science*, “Data transformation” va “Tidy data” boblari · McKinney, *Python for Data Analysis*, 7-bob (“Data Cleaning and Preparation”).